

地理空间人工智能 GeoAI

城乡规划与地理学领域的人工智能

2024年5月

□ 方法应用的三个阶段

- 构建一个体系化的框架，了解新方法；
- 以一种工具理性的方式，使用新方法；
- 基于自己对现象的认识，改进新方法。

□ 研究案例的选择

- 议题：人类活动；
- 数据特征：短时间高频变化……

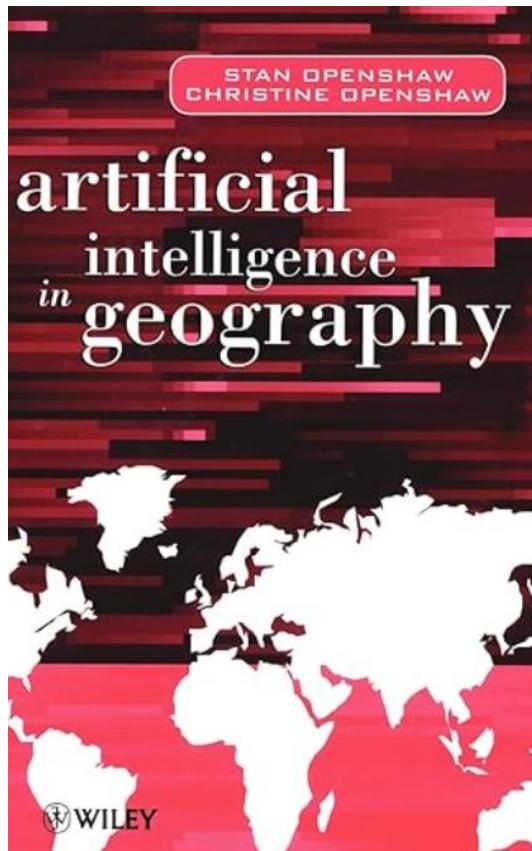
理解地理空间人工智能（GeoAI）的发展需要思考如下问题：

- 为什么城乡规划与地理相关的研究需要人工智能？ — Why？
- 与传统方法相比，可以用人工智能更好地解决哪些城乡规划与地理学问题？ — What？
 - 人工智能的应用是怎样解决上述问题的？ — How？
- 随着人工智能与 GeoAI 的应用，涌现出哪些新的问题？ — What？
 - 人工智能的应用是怎样解决上述问题的？ — How？
- GeoAI 在未来可能会有什么样的应用？ — Where & Then

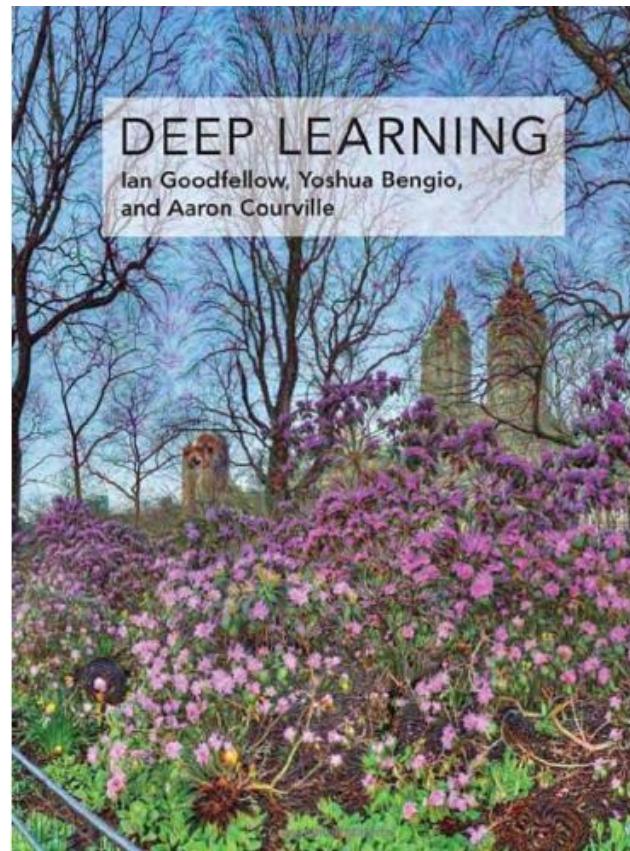
分享大纲

- 城乡规划与地理领域的关注点与经典议题
- 地理空间人工智能：概念与案例
- 地理空间人工智能的城市应用
- 城市系统中地理空间人工智能的问题与挑战

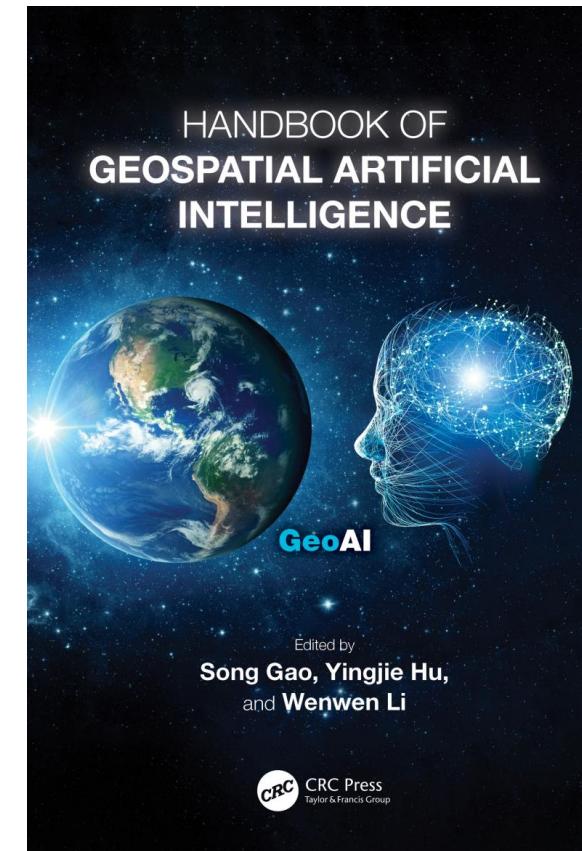
推荐阅读的书目



S. Openshaw & C. Openshaw, 1997



<https://www.deeplearningbook.org/>
Goodfellow et al, 2016



Gao et al, 2023

口 主线：针对地理过程中**依赖性、异质性、多尺度、多要素、时空动态**等特点，发展面向**复杂地理过程**的地理数据时空数据统计分析与挖掘方法。



城乡规划与地理学领域的 关注点与议题

地理现象的空间性：自相关性与异质性

□ 地理现象的空间性：传统的分析研究方法建立在样本独立性的前提下，不适合研究者对具有空间性的地理现象进行理解与建模。

□ 空间自相关性（地理学第一定律）

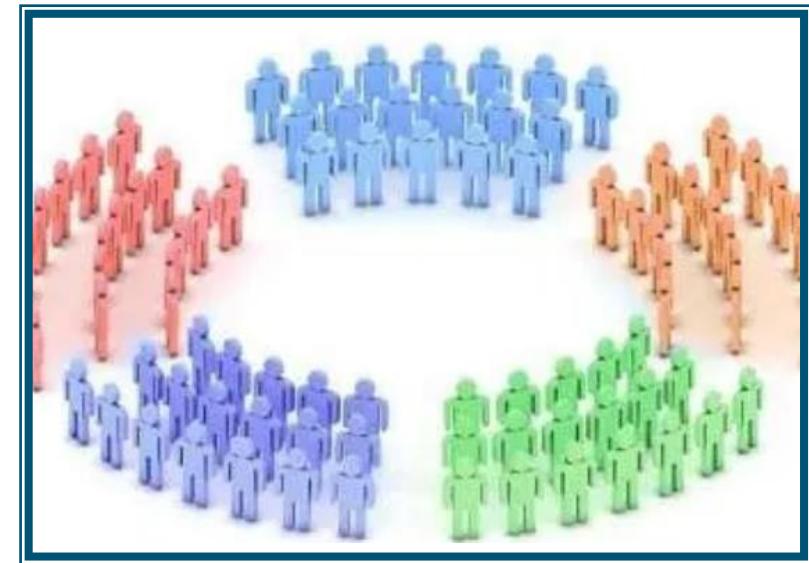
万物皆有联系，但是距离近的地理现象联系更加紧密。

—— Waldo R . Tobler , 1970

□ 空间异质性（地理学第二定律）

地理现象具有不可控的空间变化。

—— Michael F . Goodchild , 2004



物以类聚，人以群分

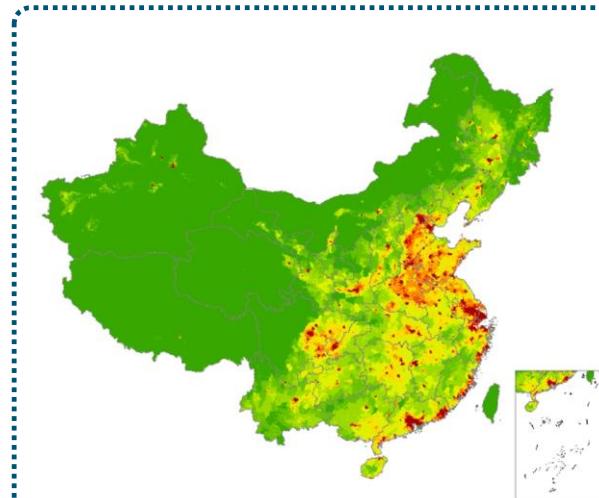
地理现象的空间性：自相关性与异质性

均质与非均质

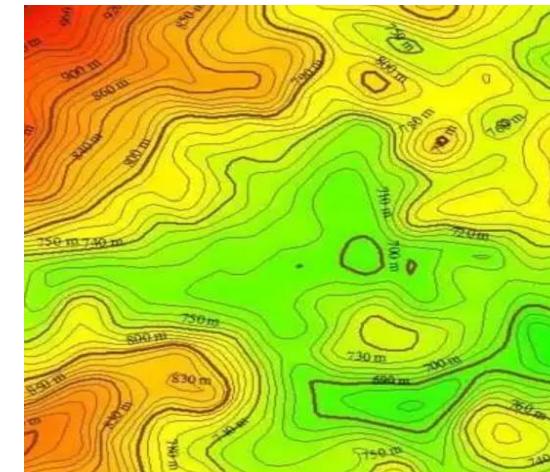
- **均质**: 属性值在不同空间范围内出现的概率是相同的;
- **非均质**: 属性值在不同时空范围内出现的概率是不同的，主要用于描述地理变量在空间与时间维度的变化情况。



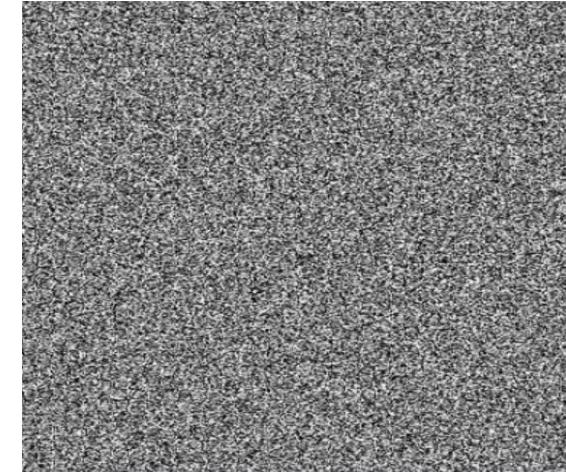
均质的地理对象：农田



差异程度不同



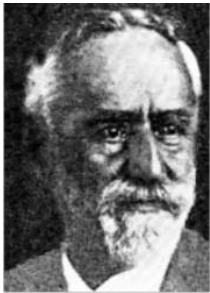
有规律的扰动



无规律的扰动：噪点

地理现象的空间性：自相关性与异质性

- 基于地理现象的空间性，研究者需要认识到**现象/行为在空间（Space）与场所（Place）之间的相似性与不同性。**



- 认识地理区域之间的**相互差异**及其在**空间上的关联**。

——A. Hettner, 1927



- 解释地表**空间变异特征**，概括地理现象的**空间格局**。

——R. Hartshorne, 1959



地理现象的空间性：尺度

从一个简单的案例说起：**辛普森悖论 (Simpson's Paradox)**

男生		女生		
申请人数	录取率	申请人数	录取率	
合计	8442	44%	4321	35%

从该学校的录取率来看，是否存在性别歧视？

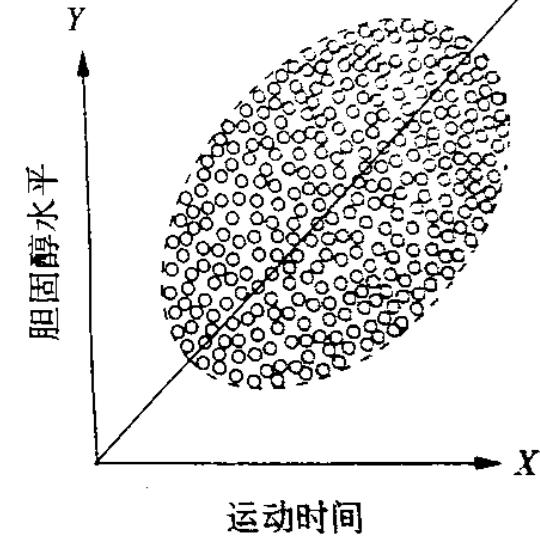
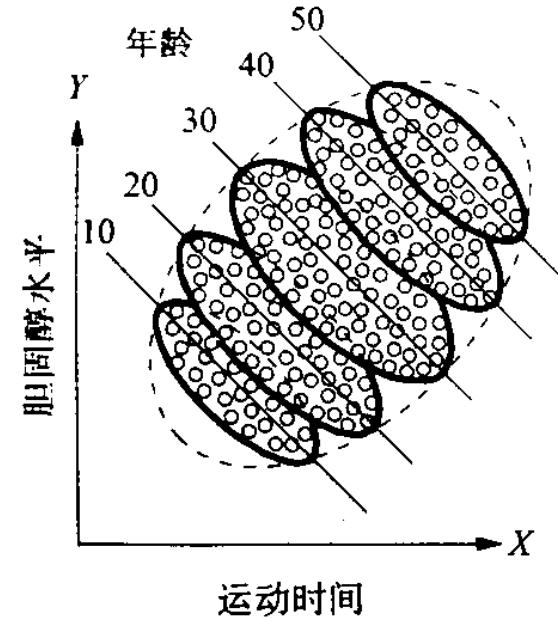
男生		女生		
申请人数	录取率	申请人数	录取率	
A学院	825	62%	108	82%
B学院	560	63%	25	68%
C学院	325	37%	593	34%
D学院	417	33%	375	35%
E学院	191	28%	393	24%
F学院	373	6%	341	7%

从该学校分学院的录取率来看，是否存在性别歧视？

地理现象的空间性：尺度

图示中的辛普森悖论

假设要研究运动时长对人体内胆固醇水平高低的影响。在左图中，我们在每个年龄组中观察到了下降的趋势，证明运动确实会降低人体内胆固醇含量；而右图中却会观察到相反的结论。



城乡规划与地理学研究空间，但是却没有天然的空间分析单元，有可能出现如下问题：

- 可变面积单元 (MAUP)
- 生态学谬误

地理现象的空间性：尺度

可变面积单元问题 (MAUP) : 随着尺度的变化，自相关性与分异性都会发生变化。



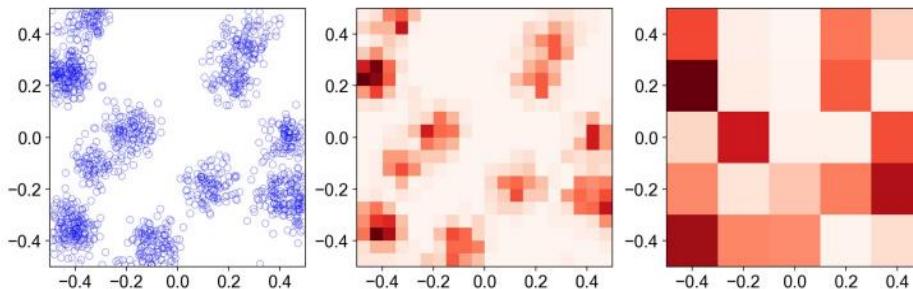
Environment and Planning A, 1984, volume 16, pages 17-31

Ecological fallacies and the analysis of areal census data

S Openshaw

Department of Geography, University of Newcastle upon Tyne, Newcastle upon Tyne NE1 7RU, England
Received 7 June 1982; in revised form 23 December 1982

Abstract. In many countries census data are only reported for areal units and not at the individual level. This custom raises the spectre of ecological fallacy problems. In this paper, a 10% sample census (from the United Kingdom) and individual census data (from Italy) are used to provide an empirical demonstration of the nature and magnitude of these problems. It is concluded that ecological fallacy effects are endemic to areal census data, although their magnitude is perhaps not as large as might have been expected. The principal difficulty is that there is at present no way of predicting in advance the degree of severity likely to be associated with particular variables and particular techniques. Finally, a suggestion is made concerning how the potentially serious practical consequences can be reduced.



21 Régions (RE)



22 Large squares (LS)



341 Employment Areas (EA)

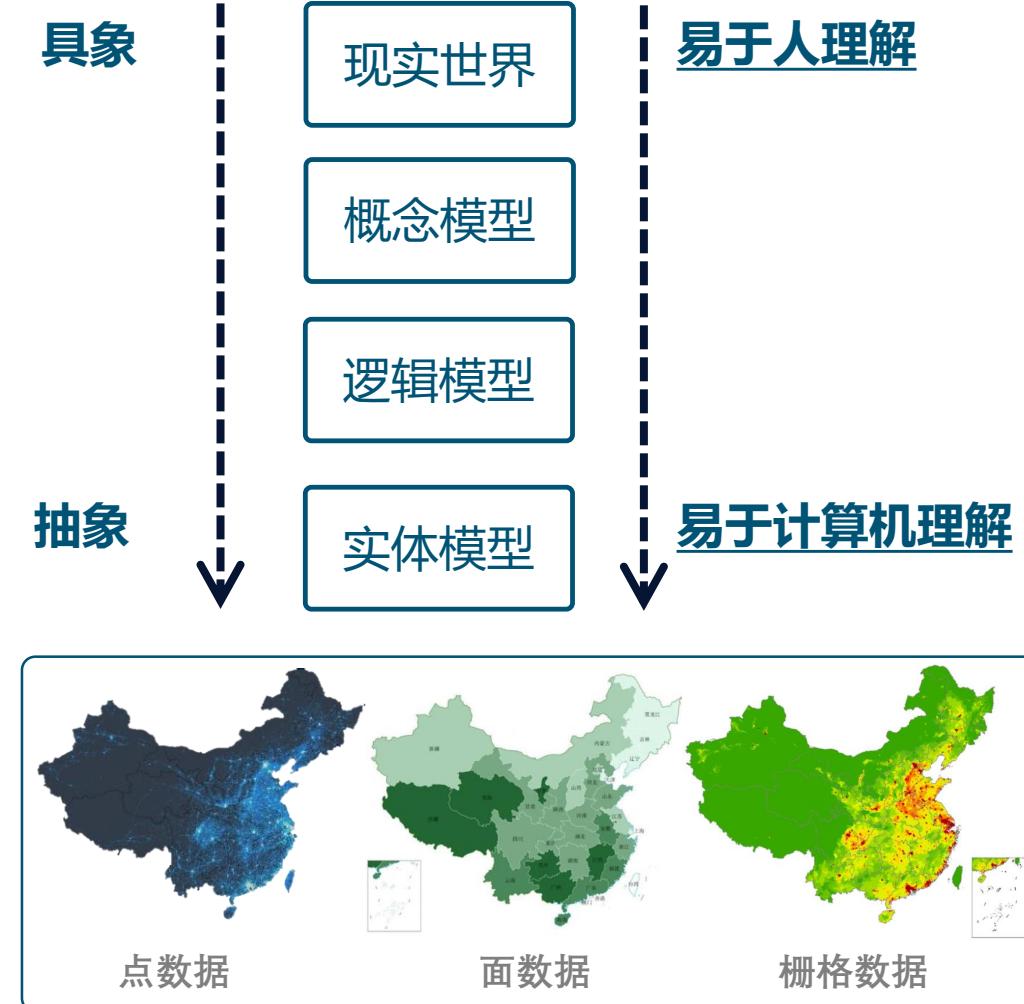


341 Small squares (SS)

scale effect (size)
zoning effect (shape)

空间性的表达方式：什么样的数据？

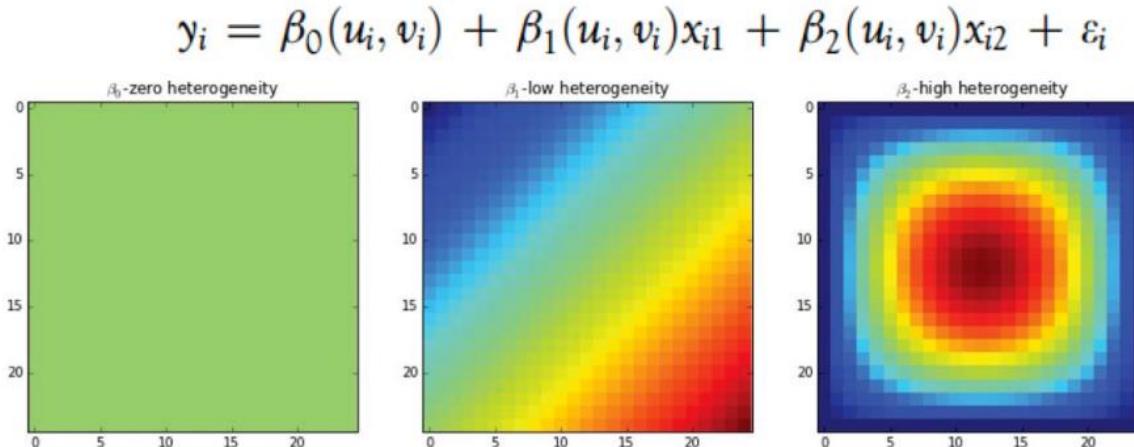
- 场模型、对象模型、网络模型…
- 空间聚焦型数据、空间延展型数据…
 - **空间聚焦型数据：**空间聚合时不可累加（气温、高程等），其满足空间稳态假设，采样规则，属性单调，常常用于趋势面分析、表面建模等任务中；
 - **空间延展型数据：**空间聚合时可以累加（人群活动），不满足空间稳态假设，采样不规则，属性丰富，常常用于相关分析、回归预测等任务中。



如何认识与地理位置相关数据的空间特征？如何挖掘其空间规律？

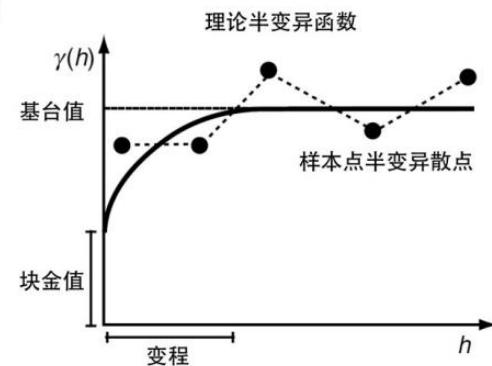
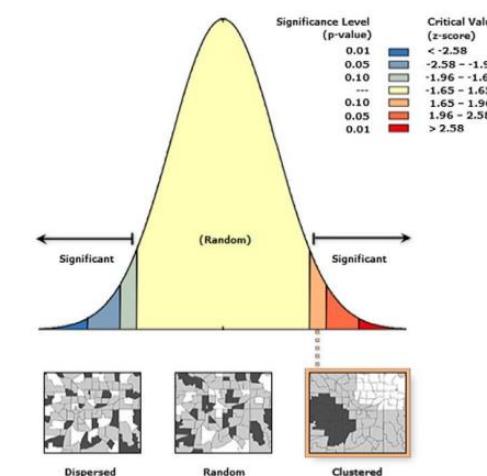
□ 需要考虑地理现象的哪些特征？

- 地理学第一定律（空间自相关）；
- 地理学第二定律（空间异质性）；
- 地理学第三定律（配置的相似性）…



□ 有哪些常用的建模方法？

- 空间统计学；
- 地统计…



Tobler, W. R. (1970). A Computer Movie Simulating Urban Growth in the Detroit Region. *Economic Geography*, 46, 234–240.

Goodchild, M. F. (2004). The validity and usefulness of laws in geographic information science and geography. *Annals of the Association of American Geographers*, 94(2), 300-303.

Zhu, A. X., Lu, G., Liu, J., Qin, C. Z., & Zhou, C. (2018). Spatial prediction based on Third Law of Geography. *Annals of GIS*, 24(4), 225-240.

如何对地理现象的空间性进行建模？

□ 空间权重矩阵

- 描述 n 个个体之间的空间依赖关系。

□ 构建方法

- 先验指定；
- 基于邻接关系，基于距离，...



空间权重矩阵示意

□ 案例一：皮尔逊相关系数 & 莫兰指数的计算

Moran's autocorrelation coefficient is an extension of Pearson product-moment correlation coefficient to a univariate series.

□ 皮尔逊相关系数: $\rho = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$

□ 莫兰指数 Moran's I: $I = \frac{n \sum_i \sum_{i \neq j} w_{ij} (Y_i - \bar{Y})(Y_j - \bar{Y})}{(\sum_i \sum_{i \neq j} w_{ij}) \sum_i (Y_i - \bar{Y})^2}$

□ 案例二：教室各区域影响力的建模

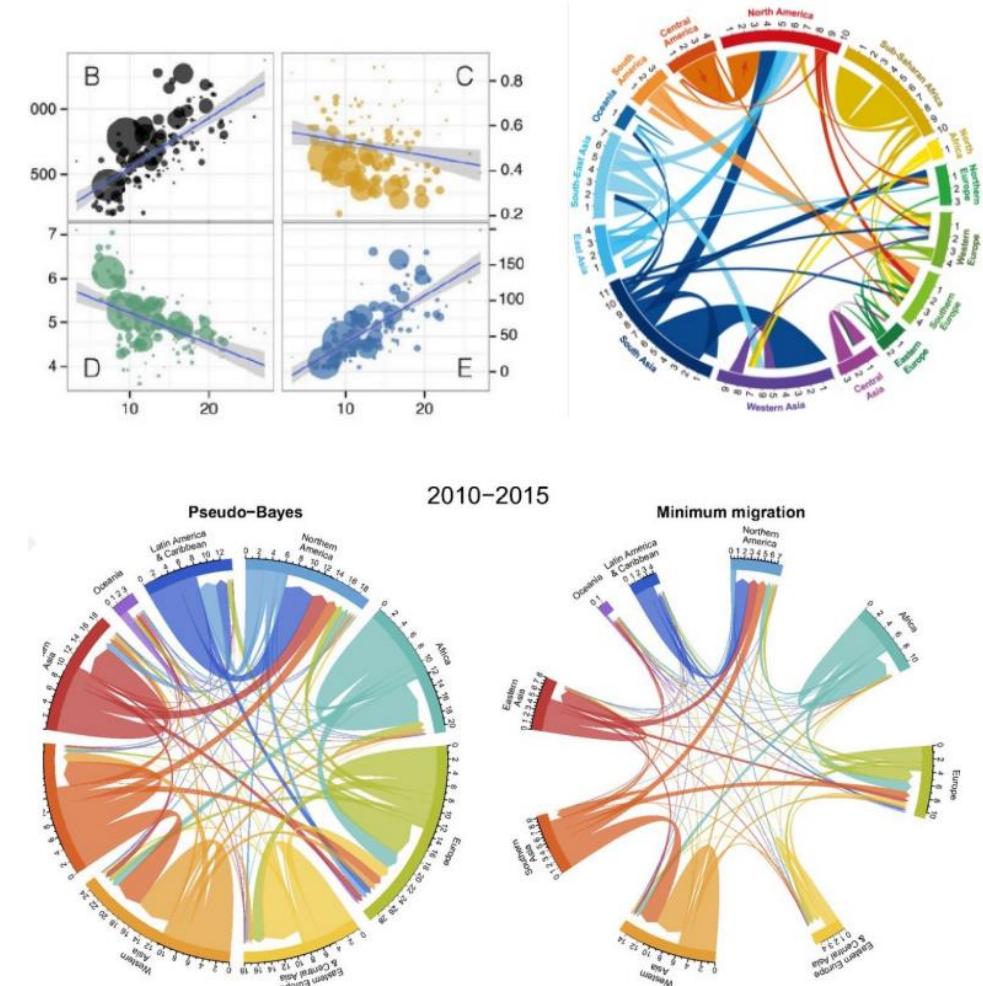
- 空间相关性使得讲台的影响力不仅受授课者的影响，还与教室其他区域的属性密切相关。
- 假设不同区域的影响是均质的: $Y_i = \sum_{i \neq j} \beta Y_j + \mu_i$
- 假设不同区域的影响存在差异: $Y_i = \sum_{i \neq j} W_{ij} Y_j + \mu_i$

为什么要进行时空预测？

□ 时空切片下的数据不完备性：

- 稀疏且缺失的空间分布；
- 难以观测的空间交互；
- 度量的错位：
 - 尺度、采样、地理语境 等等

洲际移民的流量分布状况→

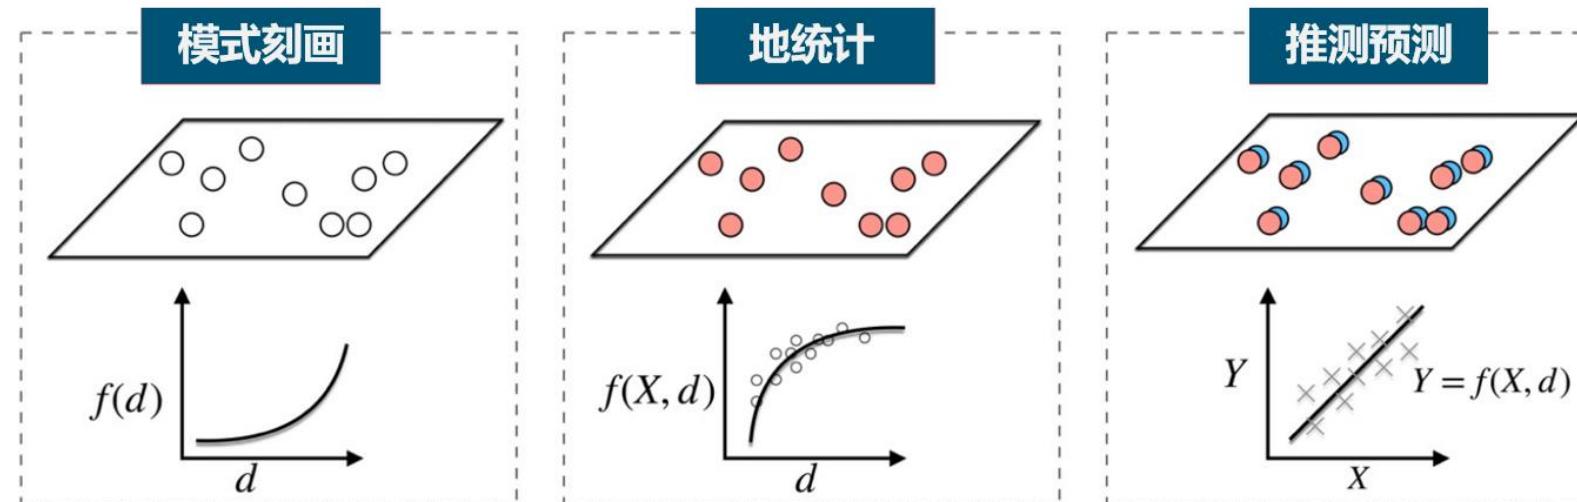


Abel, G. J., & Sander, N. (2014). Quantifying global international migration flows. *Science*, 343(6178), 1520-1522.

Azose, J. J., & Raftery, A. E. (2019). Estimation of emigration, return migration, and transit migration between all pairs of countries. *Proceedings of the National Academy of Sciences*, 116(1), 116-122.

未来：发展面向非平稳、时空动态的地理现象表达、建模与推测方法

- 传统的GIS表达模型无法使算法理解多样的地理现象；
 - 样本异质性、局部异质性、全局异质性、趋势异质性、各向异质性、分层异质性……
- 基于空间平稳假设的经典统计与空间计量方法无法对复杂的空间机理进行建模；
- 不完备的时空信息使算法限制了研究者准确推测预测地理现象发展趋势的能力。



地理空间人工智能： 概念与案例

□ 地理空间人工智能：概念与案例

- 人工智能与机器学习简介
- 地理空间人工智能
- 地理空间与人工智能的内在联系
 - 地理现象的表达
 - 地理现象的建模
 - 时空趋势的预测
- 地理空间人工智能面对的若干新议题

人工智能、机器学习与深度学习

- 人工智能
- 机器学习
- 深度学习

人工智能、机器学习与深度学习
三个概念之间的关系 →

人工智能

可以感知、推理、行动与适应的程序

机器学习

可以随着数据量增加
不断改善性能的算法

深度学习

机器学习算法的子集
其内核基础是一种名
为多层感知机的算法，
可以从大量数据中优
化性能学习得到规律

机器学习的任务

分类任务 Classification

□ 如何让机器知道一个叉子是一个叉子而非汽车？



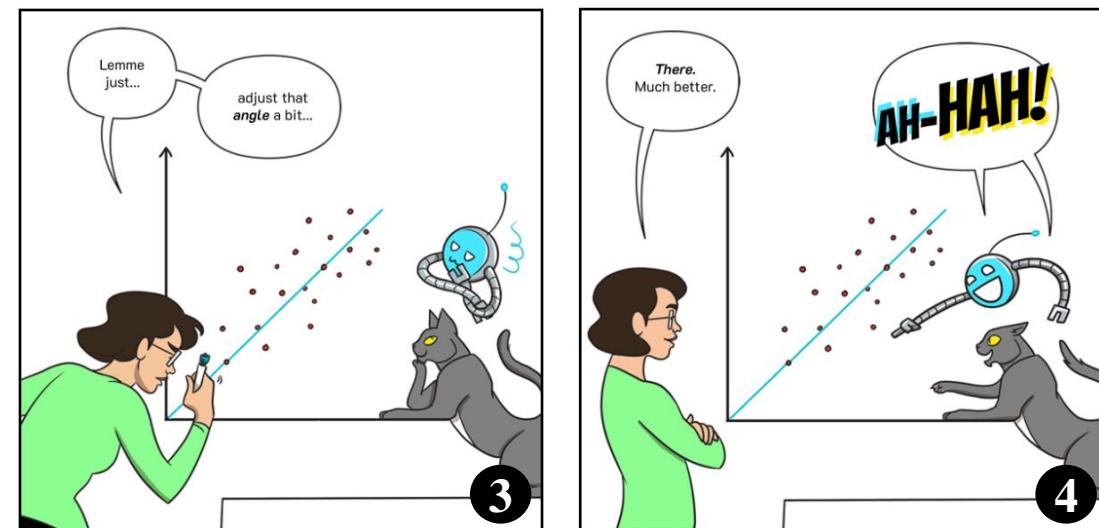
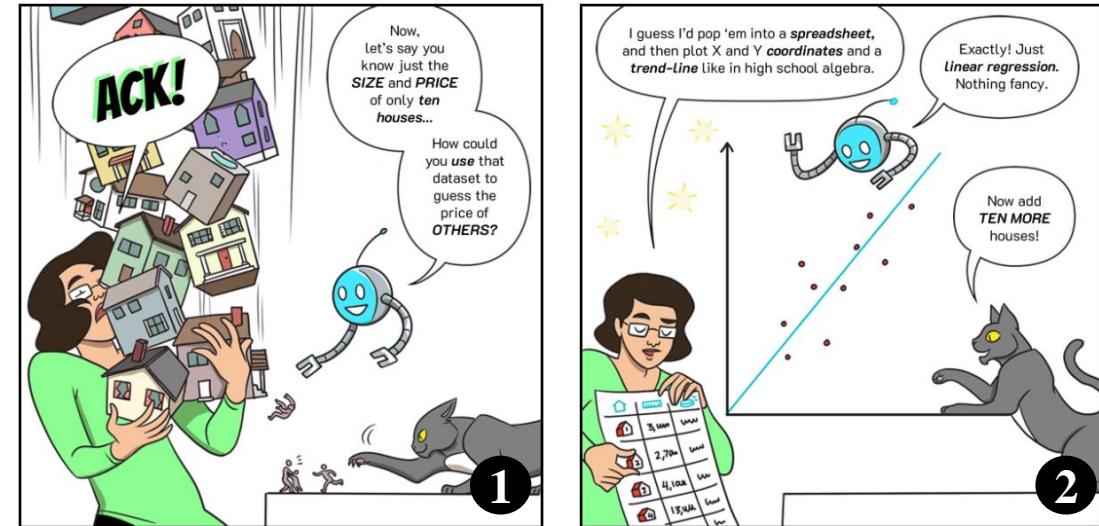
分类任务：一个直觉上的认知

<https://cloud.google.com/products/ai/ml-comic-1>

机器学习的任务

回归任务 Regression

- 如何根据房屋的大小来预测其价格?

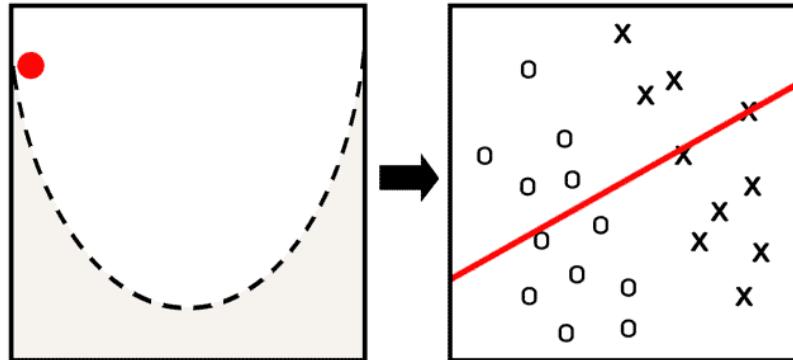


回归任务：一个直觉上的认知
<https://cloud.google.com/products/ai/ml-comic-1>

机器学习的任务

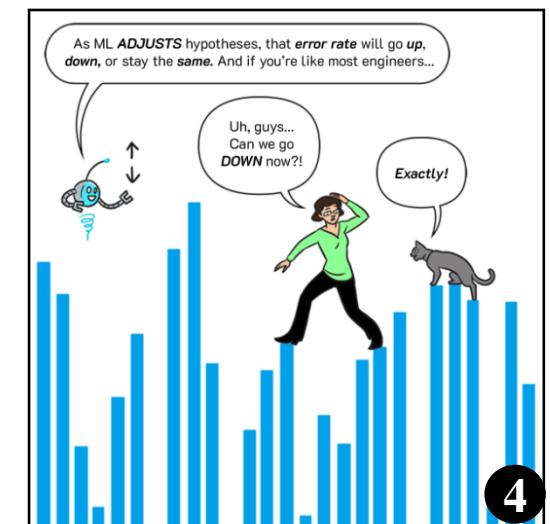
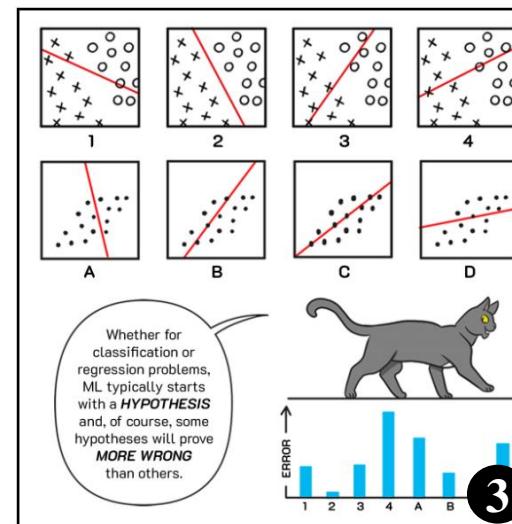
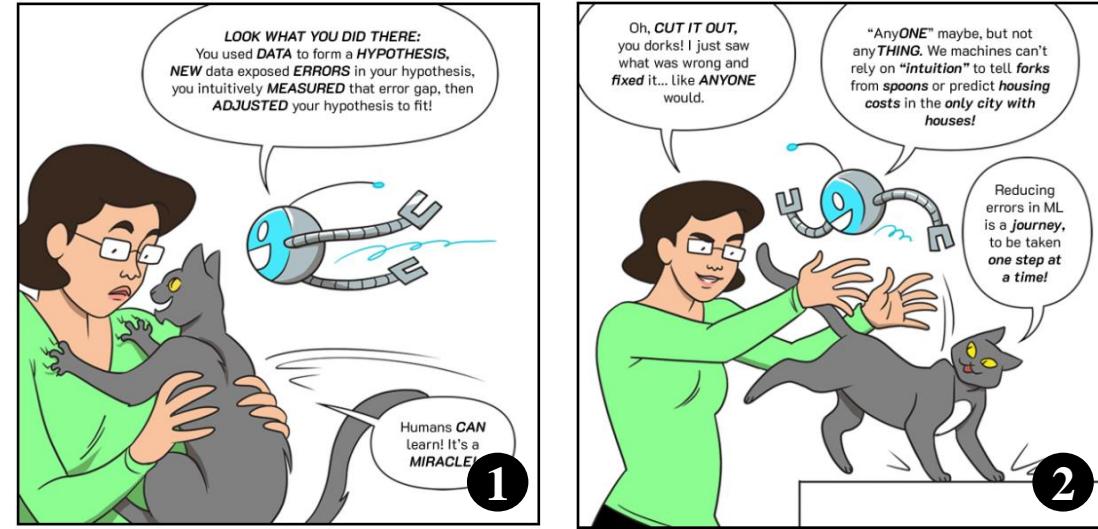
学习？优化？

- 机器学习“学”到了什么？它是如何做决策的？
- 损失函数：预测值与真实值之间的误差；
- 不同类型的机器学习算法在优化器的帮助下，不断地缩小预测值与真实值之间的差异，不断地减小损失函数的值，**从而最终学到“一条线”**。



← 机器“学习”的过程

机器“学习”：一个直觉上的认知 →
<https://cloud.google.com/products/ai/ml-comic-1>



机器学习的一般步骤

机器学习的一般步骤

- 明确机器学习任务类型
- 数据收集
- 数据预处理
- 选择训练的模型
- 模型优化
- 模型评估
- 模型部署

分类任务的一般步骤

- 数据收集
 - 数据标注
- 数据预处理
- 选择并训练模型
 - KNN、Logistic回归
- 模型评估：分类精度
- 模型部署

回归任务的一般步骤

- 数据收集
 - 明确解释变量与响应变量
- 数据预处理
- 选择并训练模型
 - 线性回归
- 模型评估：预测精度
- 模型部署

明确任务
类型

数据
收集

数据
预处理

模型
选择

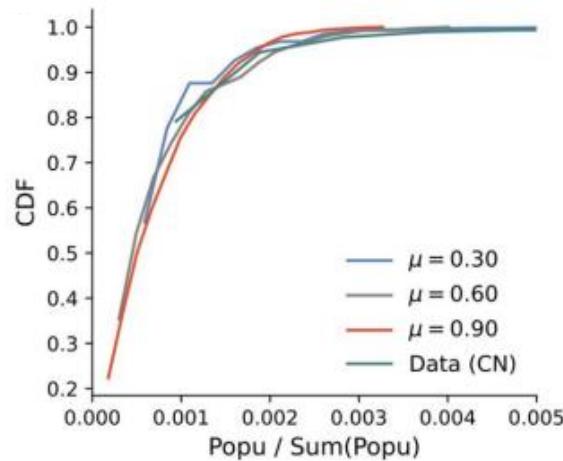
模型
优化

模型
评估

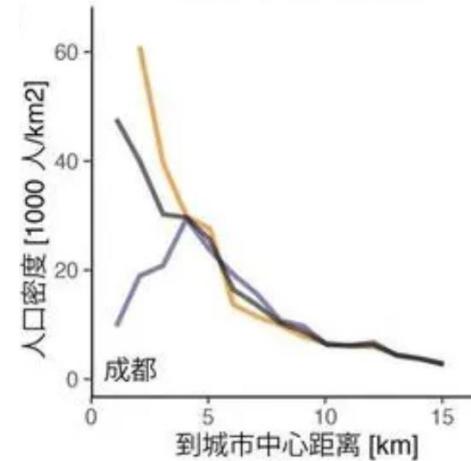
模型
部署

非线性关系

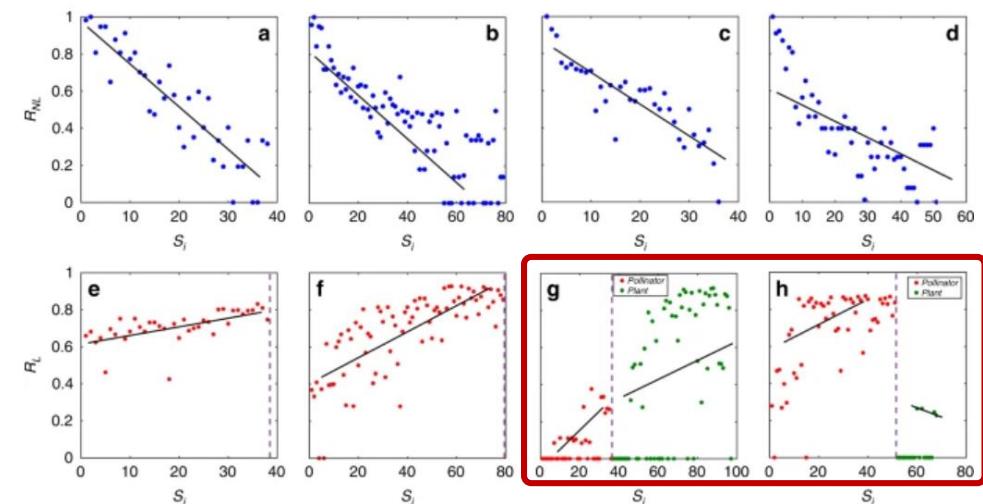
- 上文提及，机器学习的结果可以理解为“一条线”，那这条线能否是曲线？能否是折线？



人口分布的亚线性规律



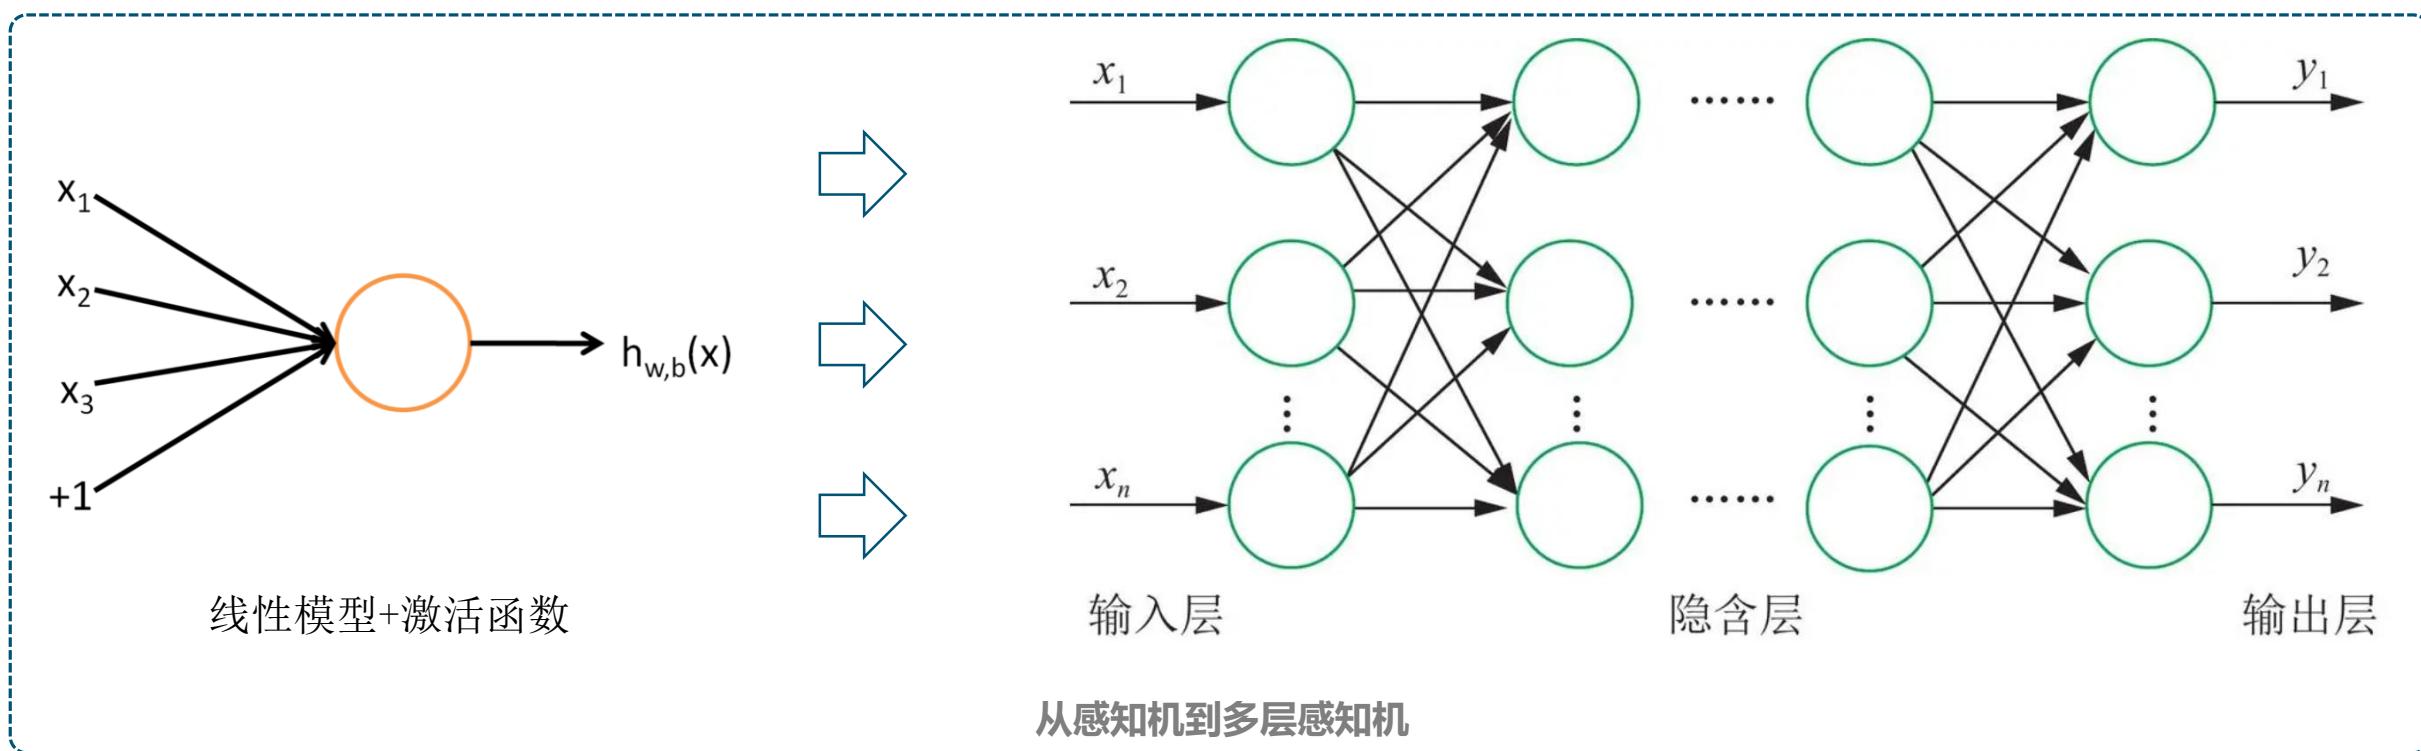
人口密度 - 距中心区距离的非线性规律



- 复杂的经济社会现象往往都是非线性的；
- 传统的线性回归模型显然无法学到响应变量与解释变量之间的非线性关系；
- 深度学习模型的出现，为计算机程序理解非线性关系提供了方案。

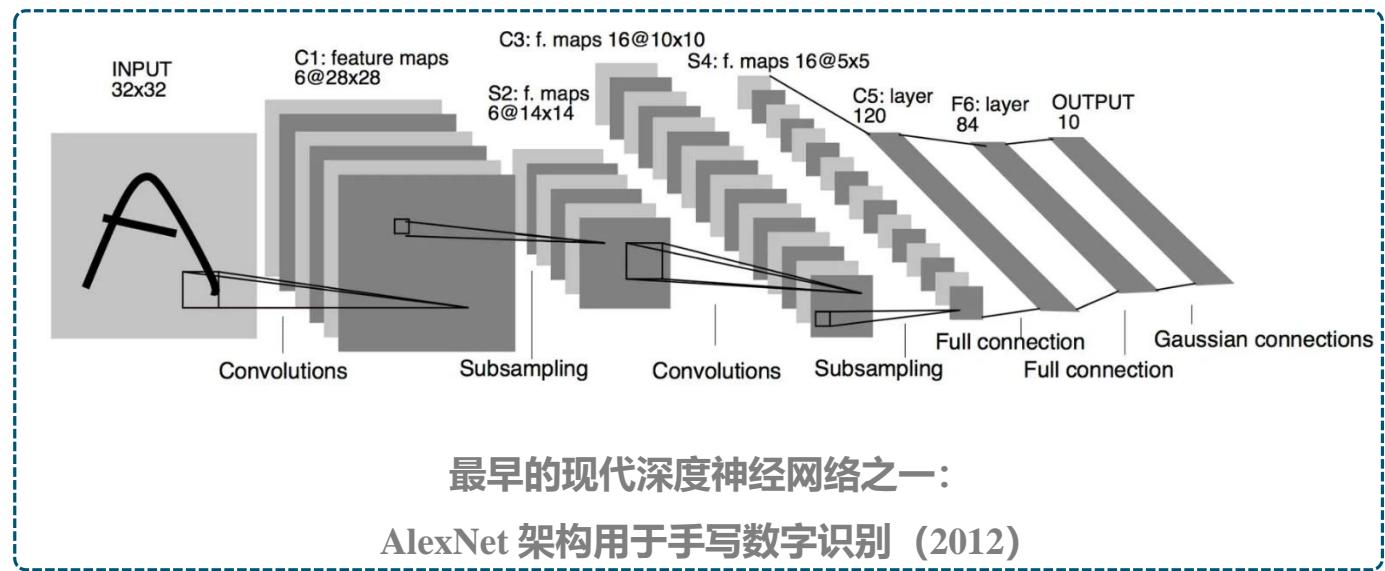
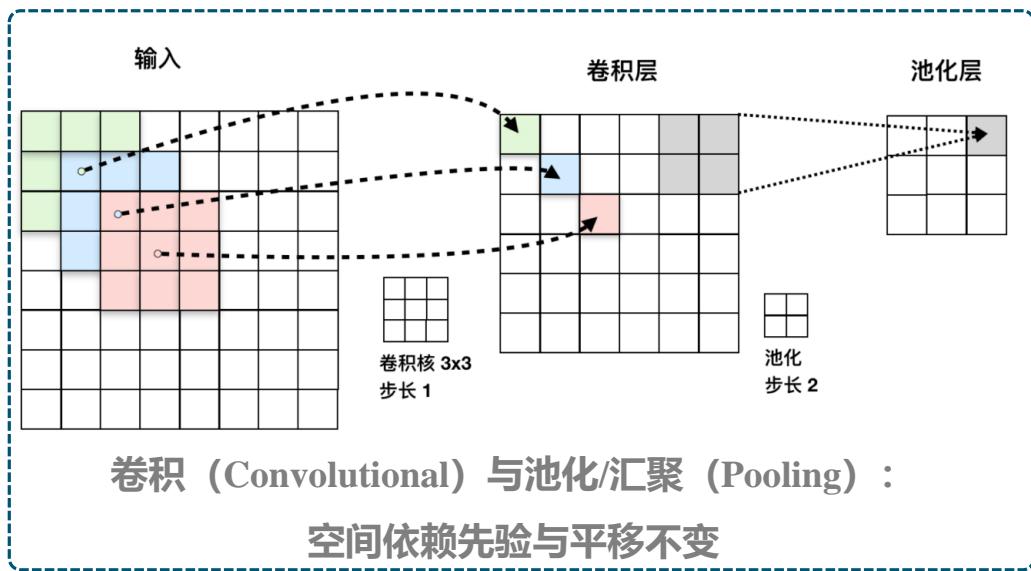
多层感知机 (Multilayer Perceptron, MLP)

- 隐含层可以做很多层，可以通过增加模型的层数来增强模型的识别能力；
- 激活函数使得模型具有学习数据中非线性特征的能力。



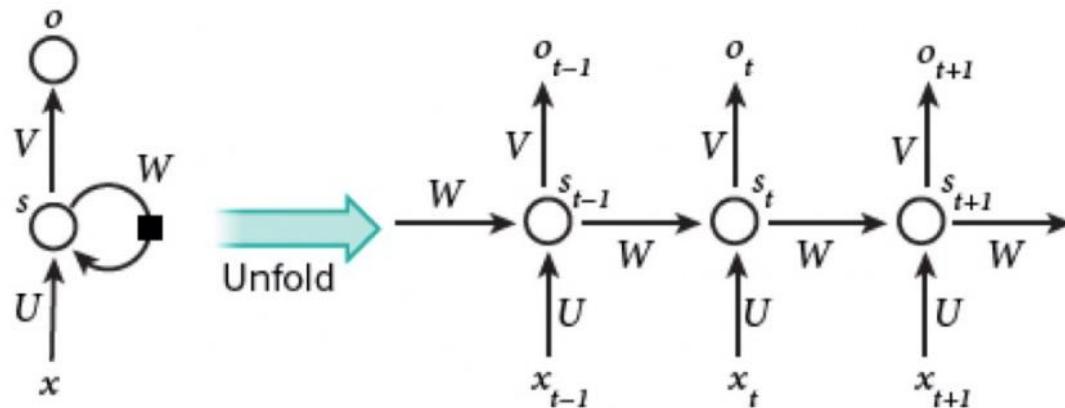
卷积神经网络 (Convolutional Neural Networks, CNN)

- 卷积神经网络建立在1) **局部地物高度相关**和2) **局部特征不随空间位置的变化而变化**, 综合利用局部连接、共享权重、池化规则和多层隐含神经网络, 能够自动地提取图像的深层次特征;
- 此类型模型常被应用至计算机视觉 (Computer Vision, CV) 领域的任务之中。
 - LeNet, AlexNet, UNet, ResNet, ...

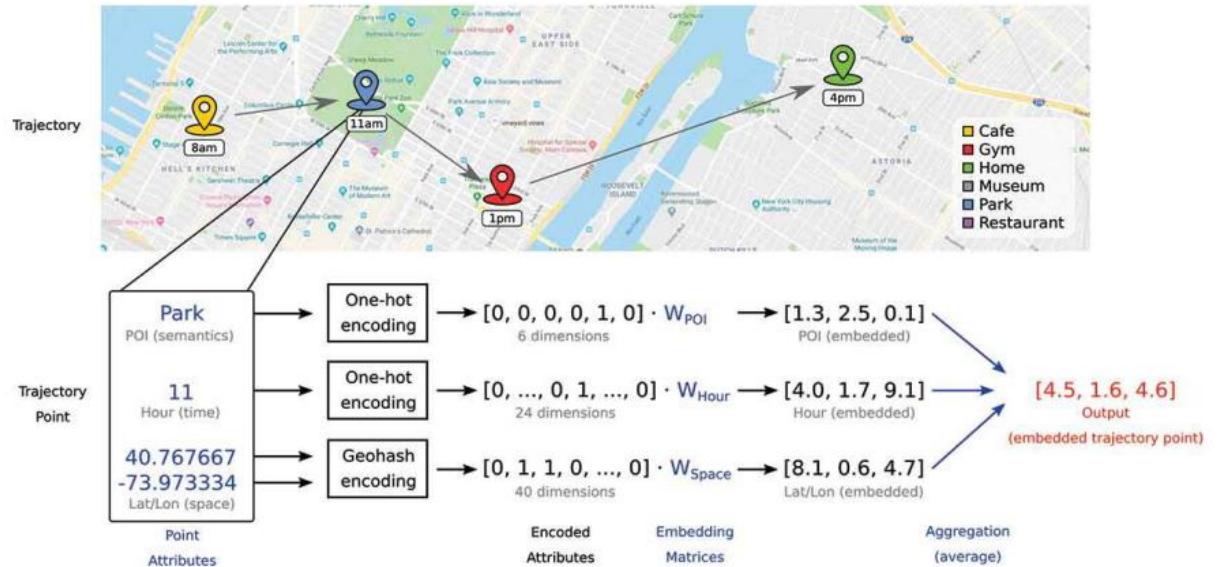


序列模型与循环神经网络 (Recurrent Neural Network, RNN)

- 用于处理时间信息，学习序列数据中的前后时间依赖，常用于自然语言处理任务之中；
 - RNN, LSTM, GRU.etc
- 在城乡规划与地学领域之中，通常用于交通态势预测、轨迹嵌入、轨迹分类等议题之中。



循环神经网络 (RNN) 的原理：捕获数据的时间自相关



LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444.

May Petry, L., Leite Da Silva, C., Esuli, A., Renso, C., & Bogorny, V. (2020). MARC: a robust method for multiple-aspect trajectory classification via space, time, and semantic embeddings. International Journal of Geographical Information Science, 34(7), 1428-1450.

深度学习的典型模型

Transformer

□ 核心：注意力机制

□ 主要结构

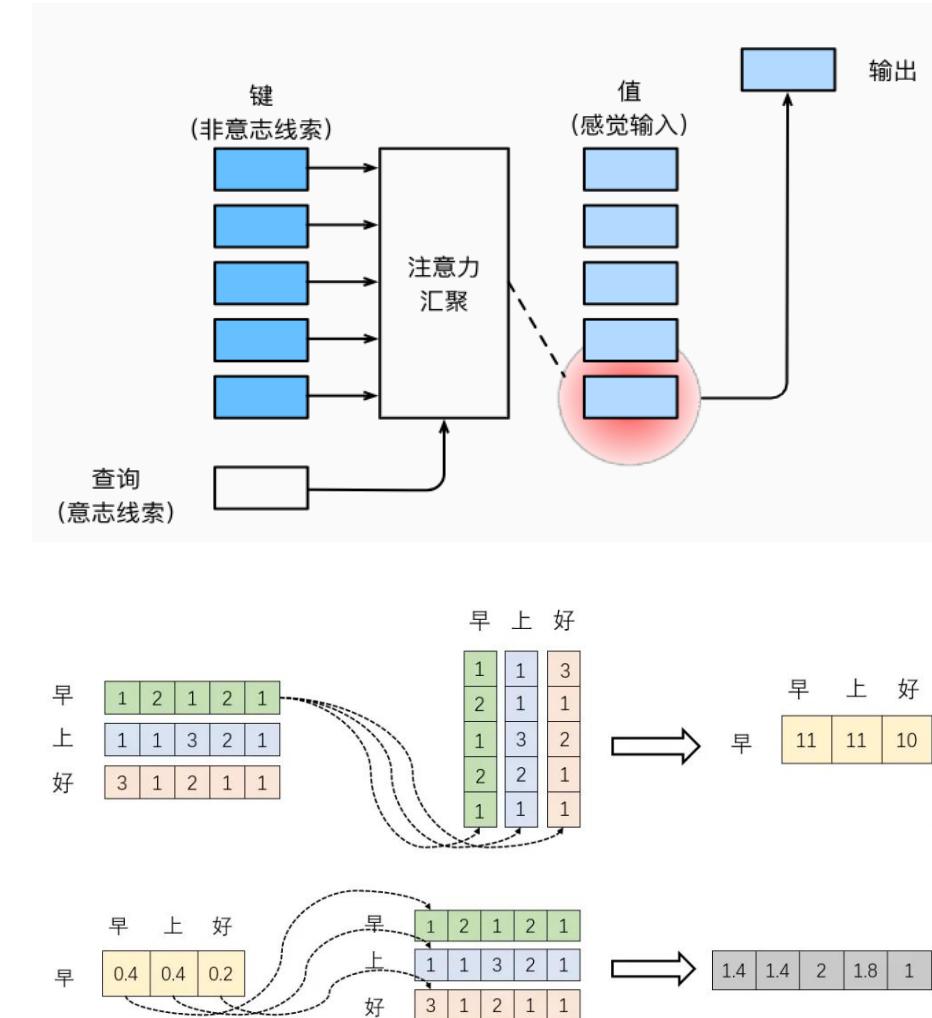
□ 嵌入 (Embedding)：连续且稠密的向量，表达轨迹点在何处，以及这个轨迹点有什么特征；

□ 查询 (Query) & 键 (Key)：用于衡量轨迹点之间的相关性；

□ 值 (Value)：根据键得到更贴合任务目标的嵌入/最匹配的值。

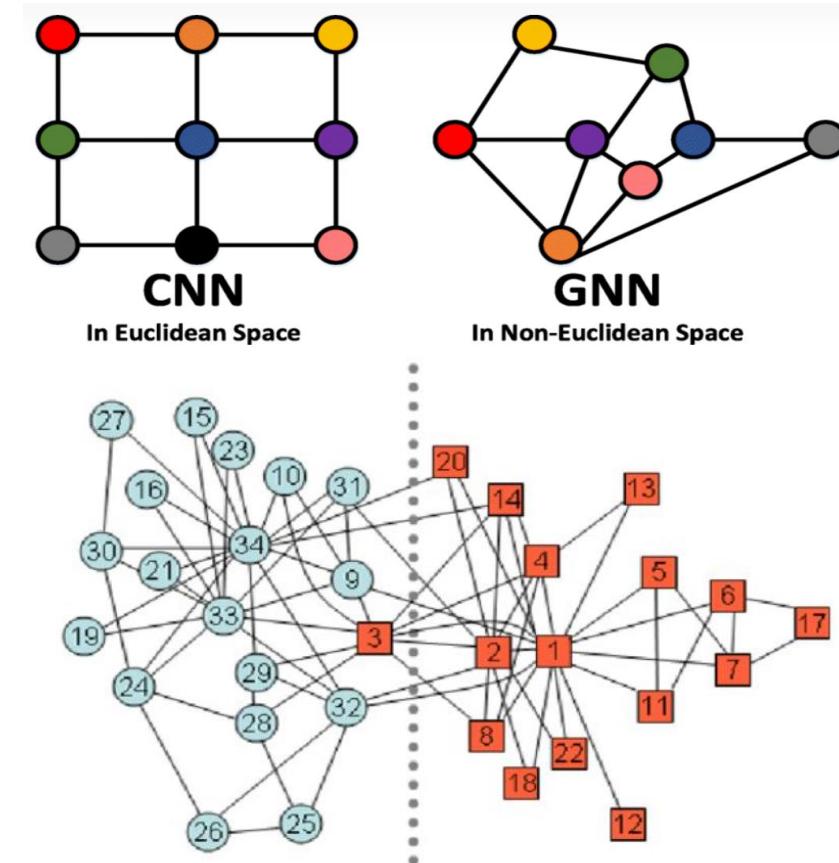
□ **输出：更准确的“表示” (Representation)。**

注意力机制：实例→



图神经网络 (Graph Neural Network, GNN)

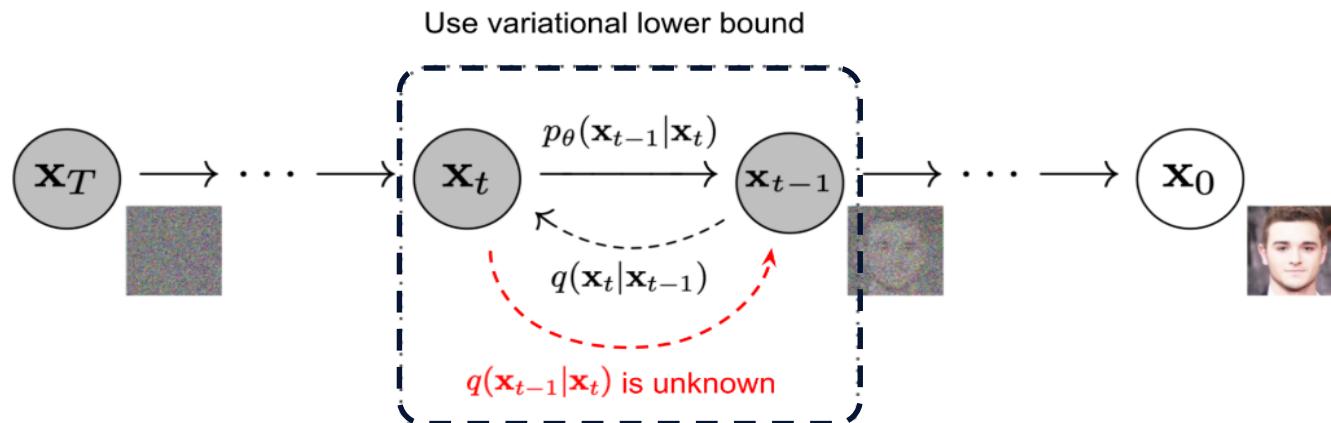
- 图结构数据与以图象为代表的二维规则网格数据不同，它是非欧几里得空间数据，**没有固定的坐标表示**。这类数据非常常见，比如社交网络、交通网络等；因此，图神经网络在地理时空分析、社交网络分析等多个方面都有广泛的应用；
- **图卷积神经网络是图神经网络的重要代表**，它通过类似于“卷积”的聚合操作使图中的节点可以聚合自身与邻居的节点特征来形成新的特征；
- 与CNN相比，GNN不仅可以用于规则网格，也可以用于不规则数据；同时，它可以考虑更远的邻域和多尺度信息。



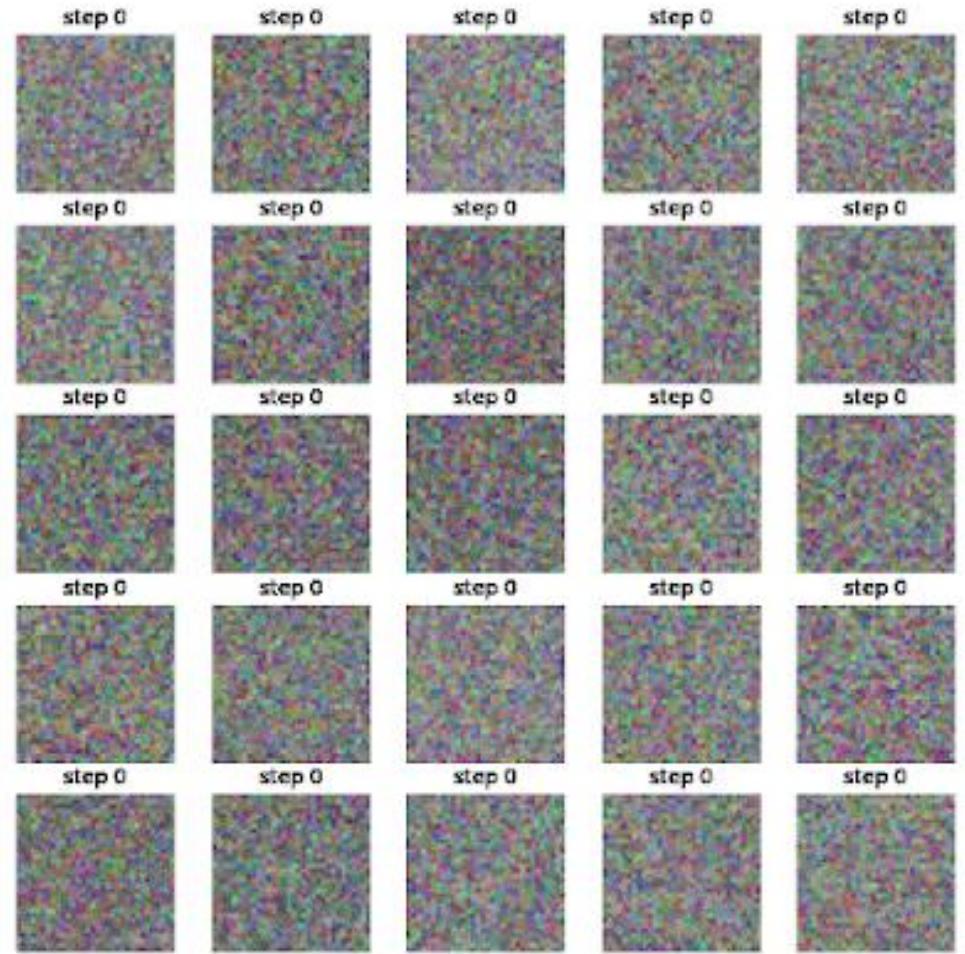
社交网络建模与分析的经典案例：
Zachary's Karate Club

生成模型

- 用于生成与训练数据相似的数据；
 - GAN, VAE, Diffusion Model, ...
- 在城乡规划与地学领域之中，通常用于规划方案生成、轨迹生成等议题之中。



扩散模型 (Diffusion Model) 的工作原理：前向扩散与逆向恢复



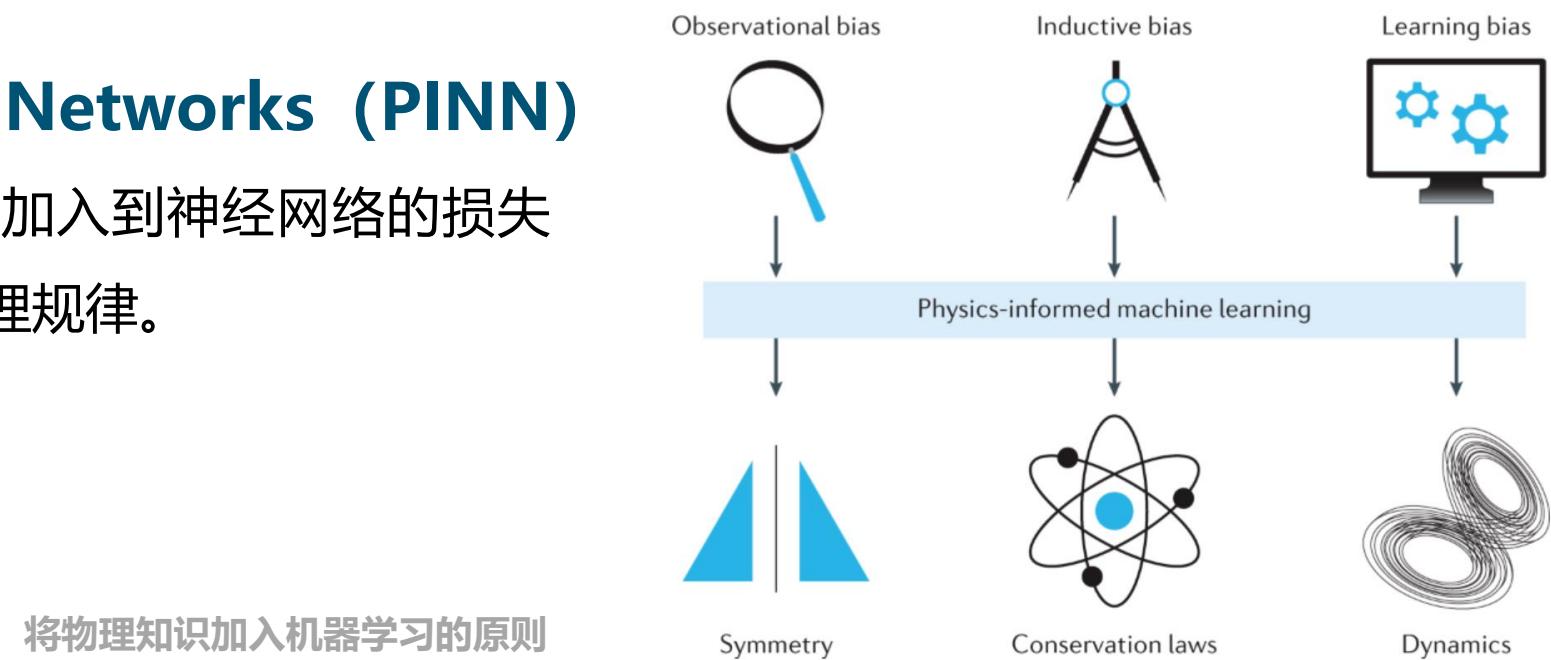
扩散模型 (Diffusion Model) 的工作过程

纯数据驱动的模型表现往往比较差

- **解决方案：**在模型中引入经验、物理或者数学理解所产生的先验知识；
- PINN网络是其中性能优异的算法之一，可以为人工智能算法融合地学先验知识解决城市社会问题提供一定的借鉴。

Physics-Informed Neural Networks (PINN)

- 通过把物理方程迭代前后的差值加入到神经网络的损失函数之中，使得训练结果满足物理规律。

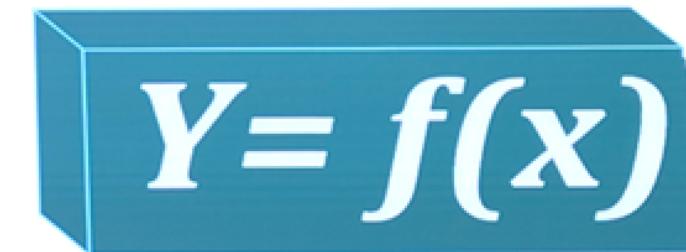


地理空间人工智能 (Geospatial Artificial Intelligence, GeoAI)

- 地理空间人工智能是地理空间领域的知识与人工智能技术相结合的成果；
- 其目的是为了支持地理科学领域数据密集型的科学发现 (Data-intensive scientific discovery in geographical science) 。



机理模型



时空分析模型

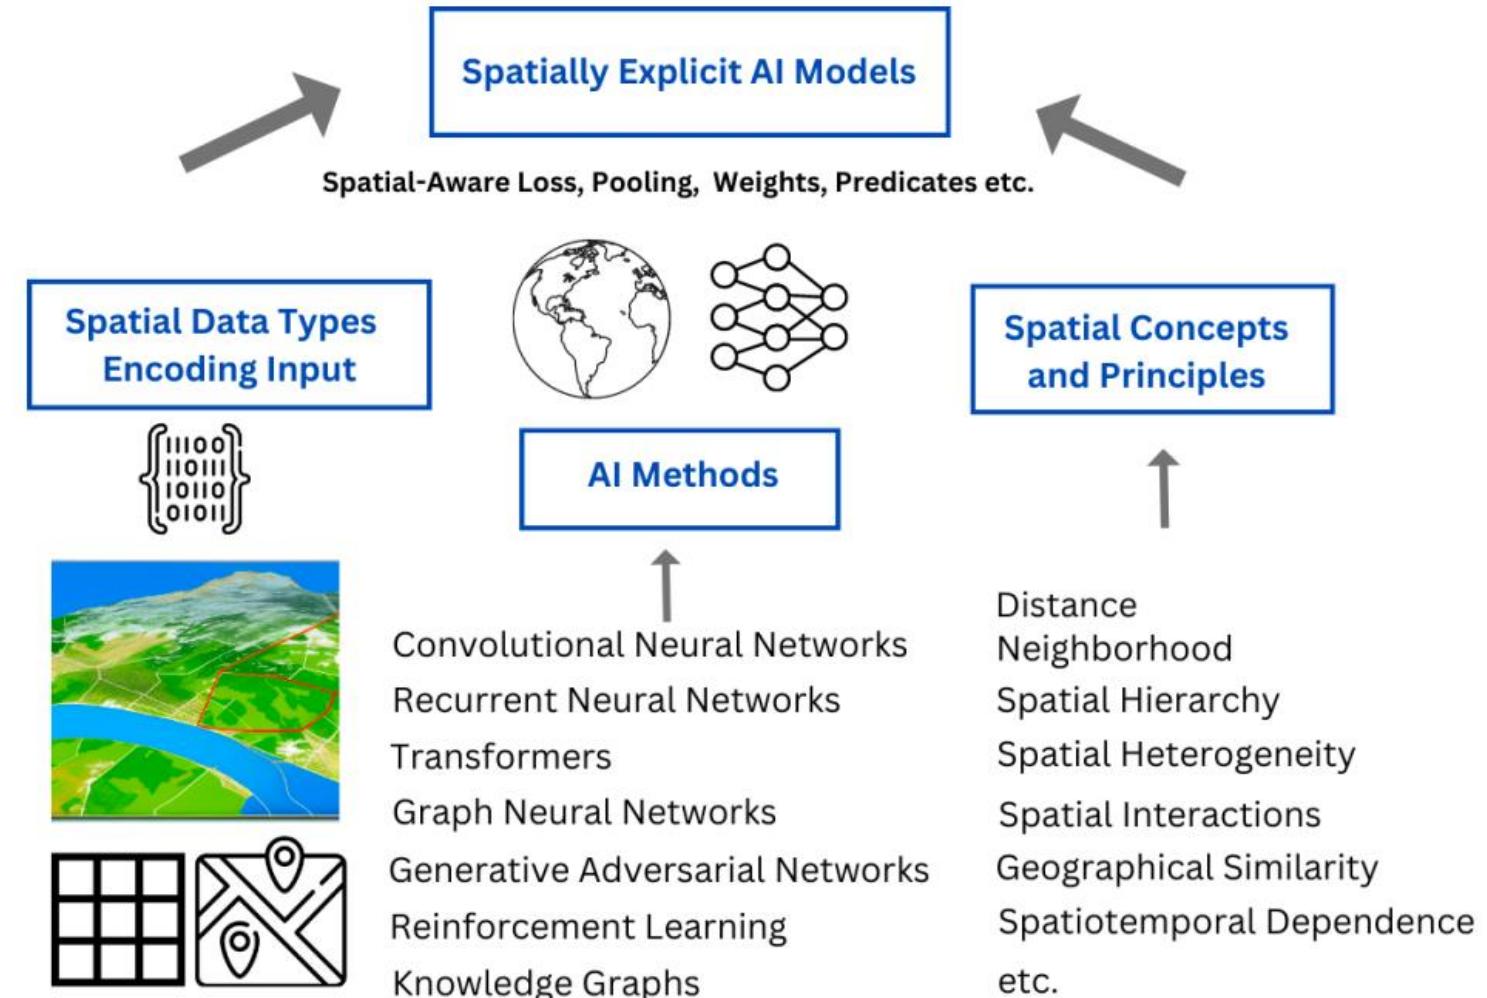
对于地理空间数据的理解应该如何被加入至人工智能技术之中？

- 人工智能技术的蓬勃发展为城市研究者理解并建模城市现象提供了丰富的工具。
 - 捕获数据的空间邻域信息：CNN；
 - 捕获数据的时间前后依赖：RNN, LSTM, Transformer；
 - 理解不规则数据的拓扑结构：GNN；
 - 将研究对象视作可以自主行动的智能体：**强化学习**（Reinforcement Learning, RL）。
- 上述对各种类型数据建模与理解的方式该如何与地学知识结合？
 - **设计空间显式（Spatial Explicit）的人工智能模型。**

空间显式模型的检验

- 不变性检验
- 在所研究现象的迁移下，空间显式模型的结果**并非不变**。

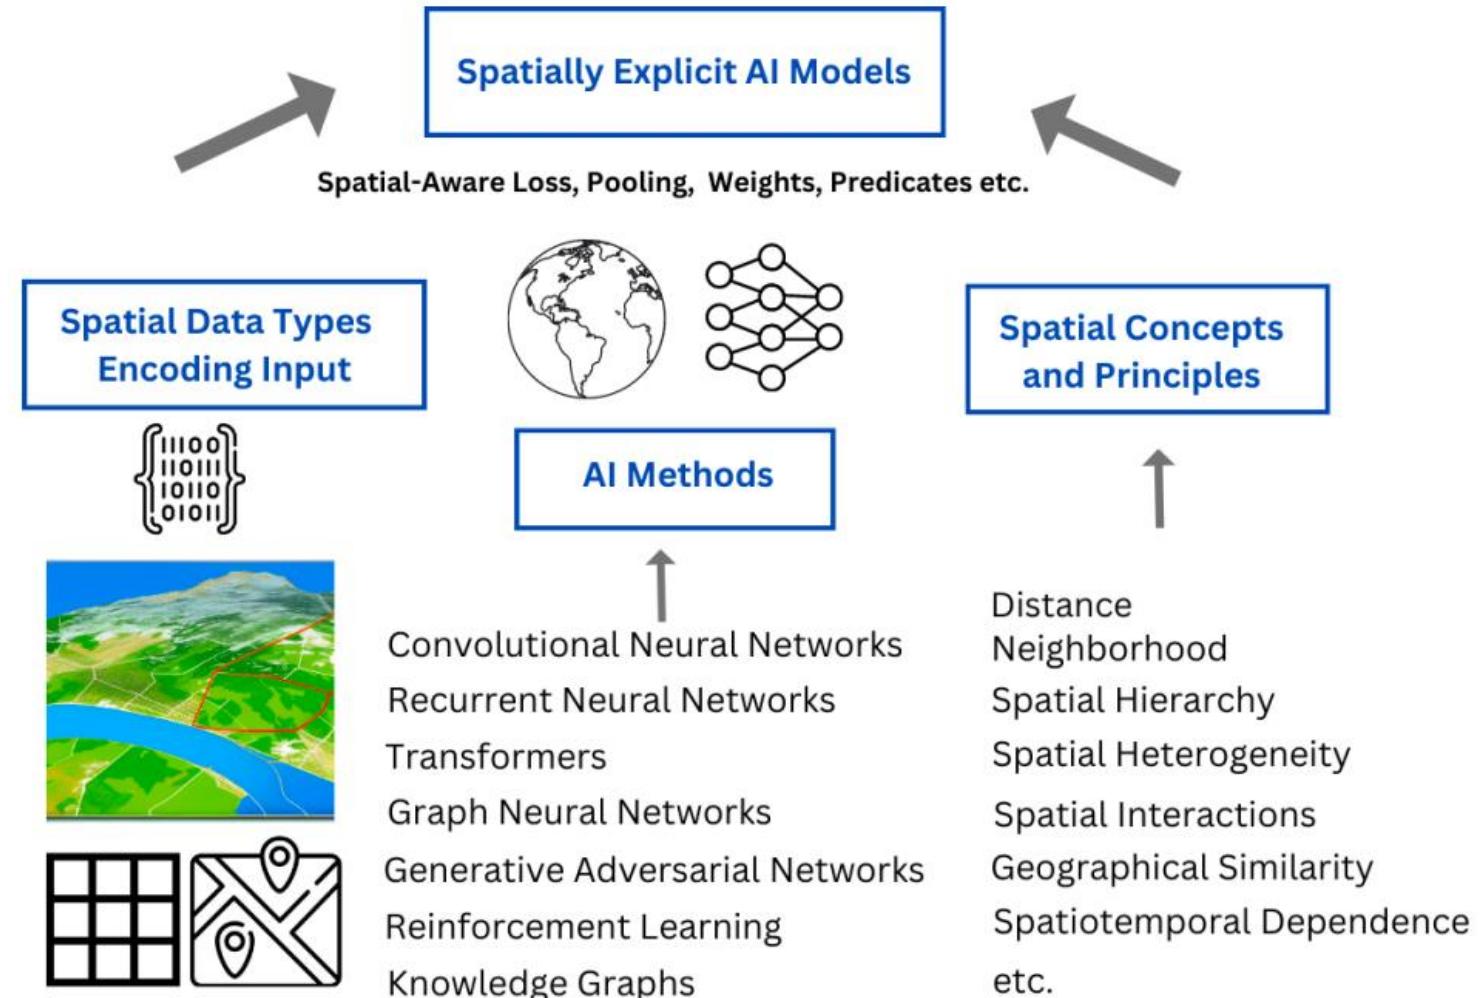
- 表征检验
- 空间显式模型在其实现中包含了所研究现象的**空间表征形式**（可以采用整合地理坐标、空间关系、地名等形式）。



空间显式模型的检验

- 公式化检验
- 空间显式模型在其**概念和公式**中明确使用了**空间概念**，例如考虑空间邻域和方向、把空间属性引入深度学习模型的损失函数设计。

- 结果检验
- 模型输入和输出结果的**空间结构**
(形式) 不同。



发展 GeoAI 的愿景是什么？

- **认知视角：**从个体（Individual）层面与聚合（Aggregated）层面理解人类认知系统以及其决策过程；
- **工程视角：**使得计算机程序具有理解、处理与生成与人类行为数据的能力。



GeoAI 有哪些优势？

- **便捷的数据表示：**可以处理多种不同类型的数据形式；
- **考虑空间依赖：**显式地将邻域变异与相关结构、距离衰减等复杂的空间效应纳入至模型的设计之中；
- **宽松的模型假设**
- **可以预测与解释未知的知识：**较之传统的地理模式的归纳总结，采用GeoAI有助于研究者发现未知的知识；

GeoAI 中的空间表示学习 (Spatial Representation Learning)

□ 如何让算法认知事物→如何让算法认知地理对象

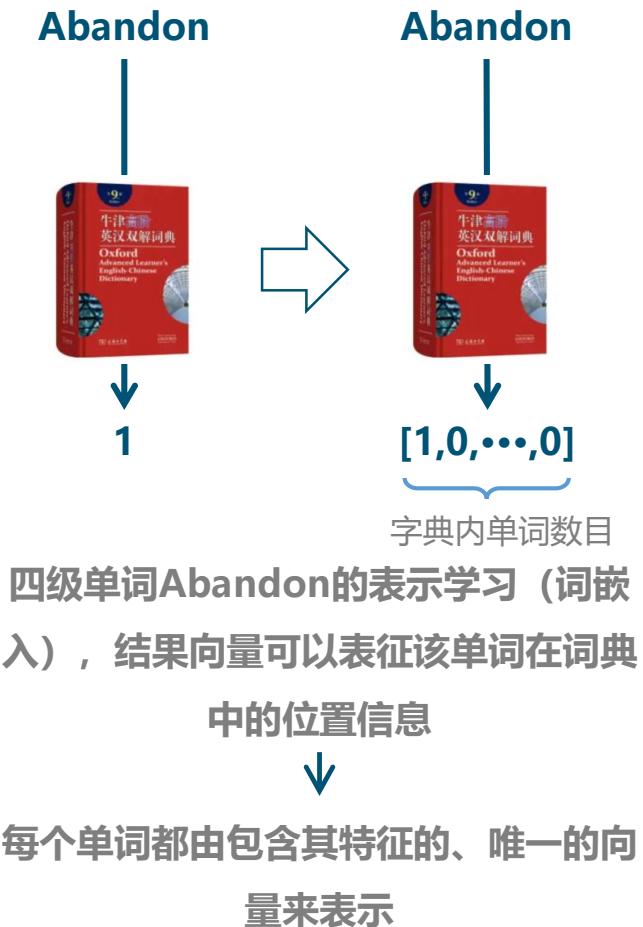
□ 传统的研究问题：输入什么样的数据？特征工程

- 哪些特征可以使模型认定这是一辆汽车？
- 我们需要根据房子的哪些特征来预测其价格？

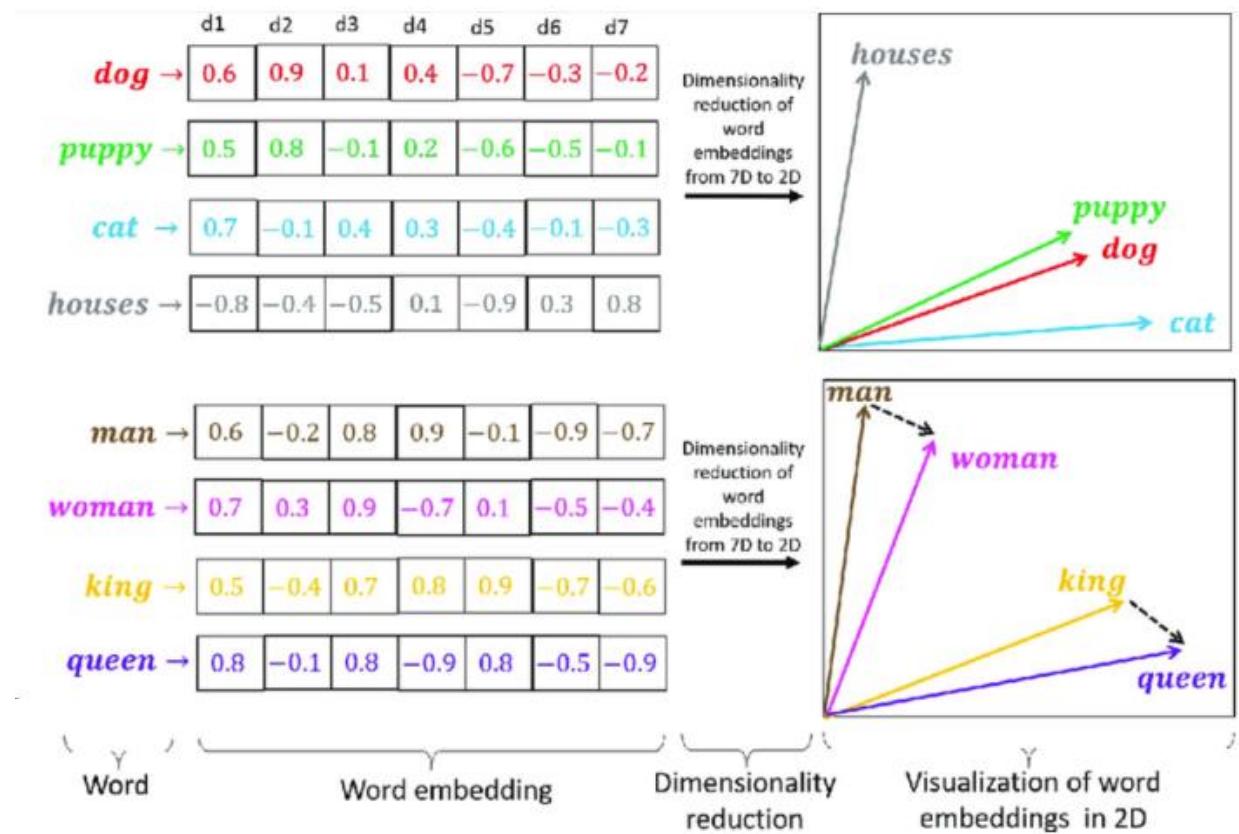
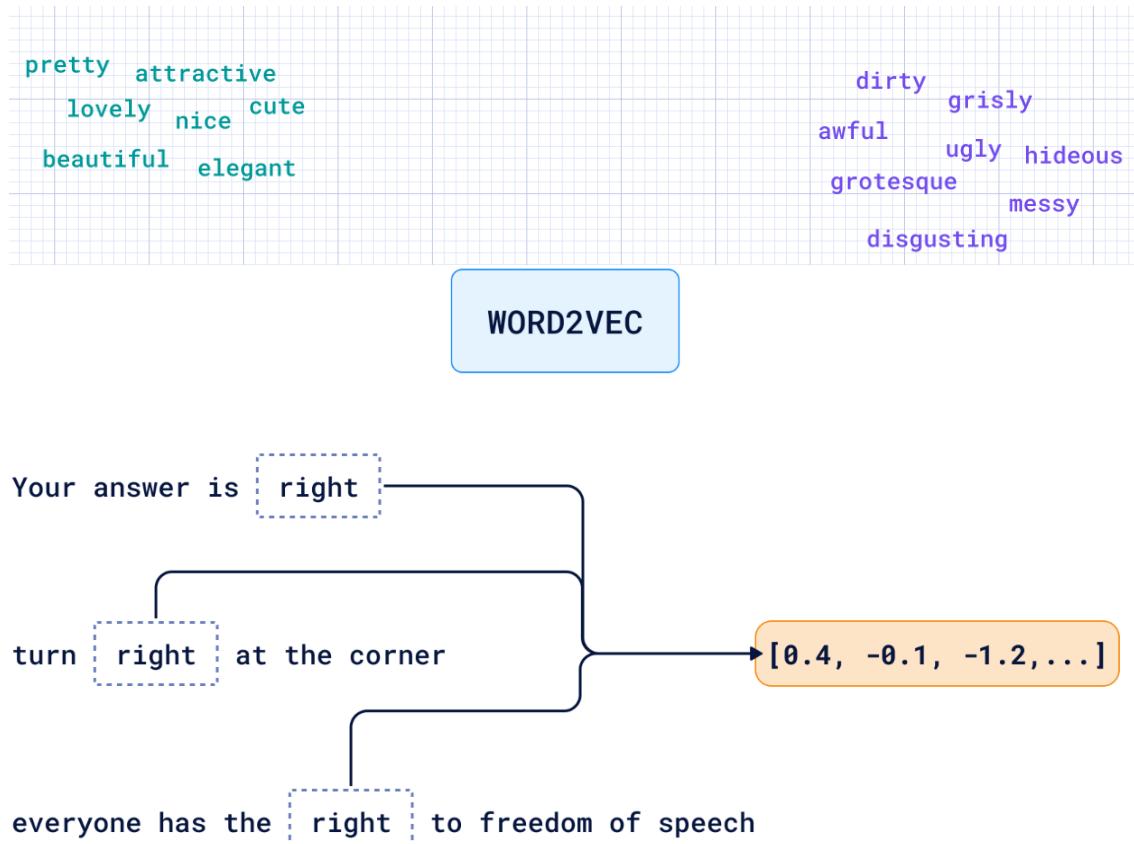
□ 解决方案：人工特征工程→表示学习

- 从原始数据中自动提取/发现其特征；
- 学习结果：高维连续且稠密的向量；
- 学习结果可以输入到分类、回归等下游任务中。

空间数据具有不规则的结构，需要更独特的表示学习方法。



表示学习：一个直觉化的认知

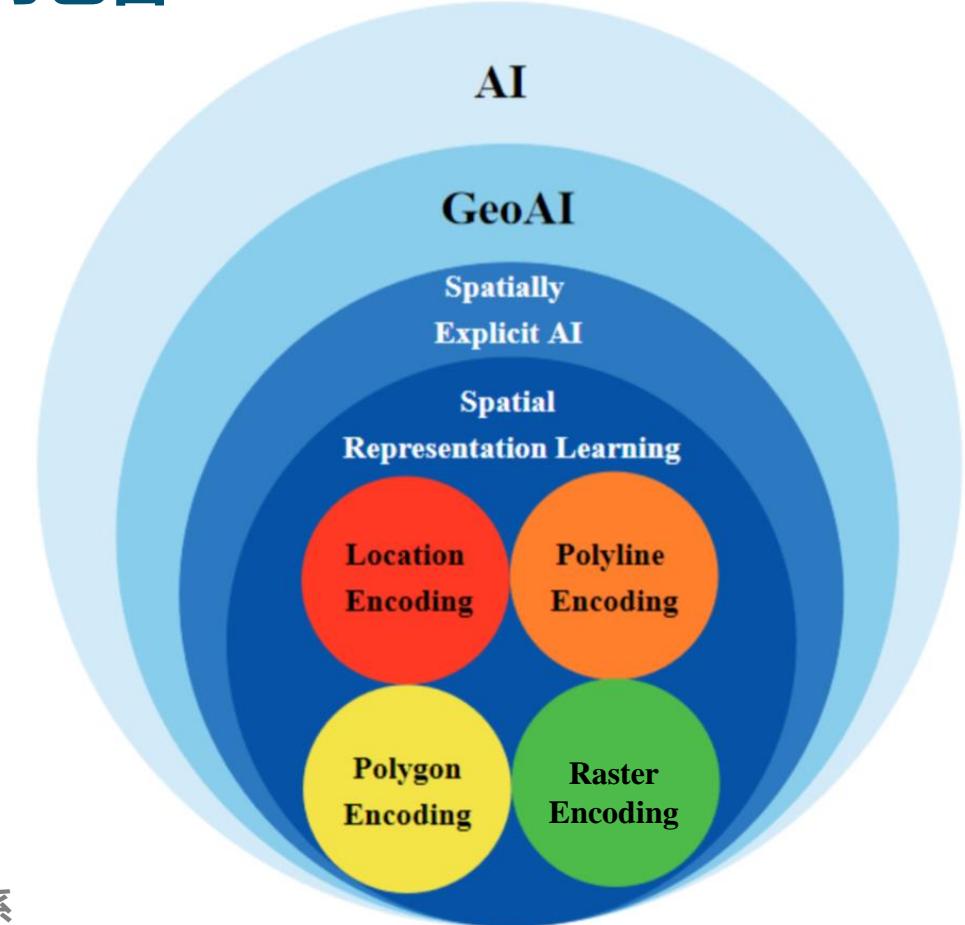


通过表示学习将原始数据嵌入到连续且稠密的向量之中

两嵌入向量的夹角代表了两个单词（轨迹点）的相似性

按照地理空间数据的分类，GeoAI中的空间表示学习包含：

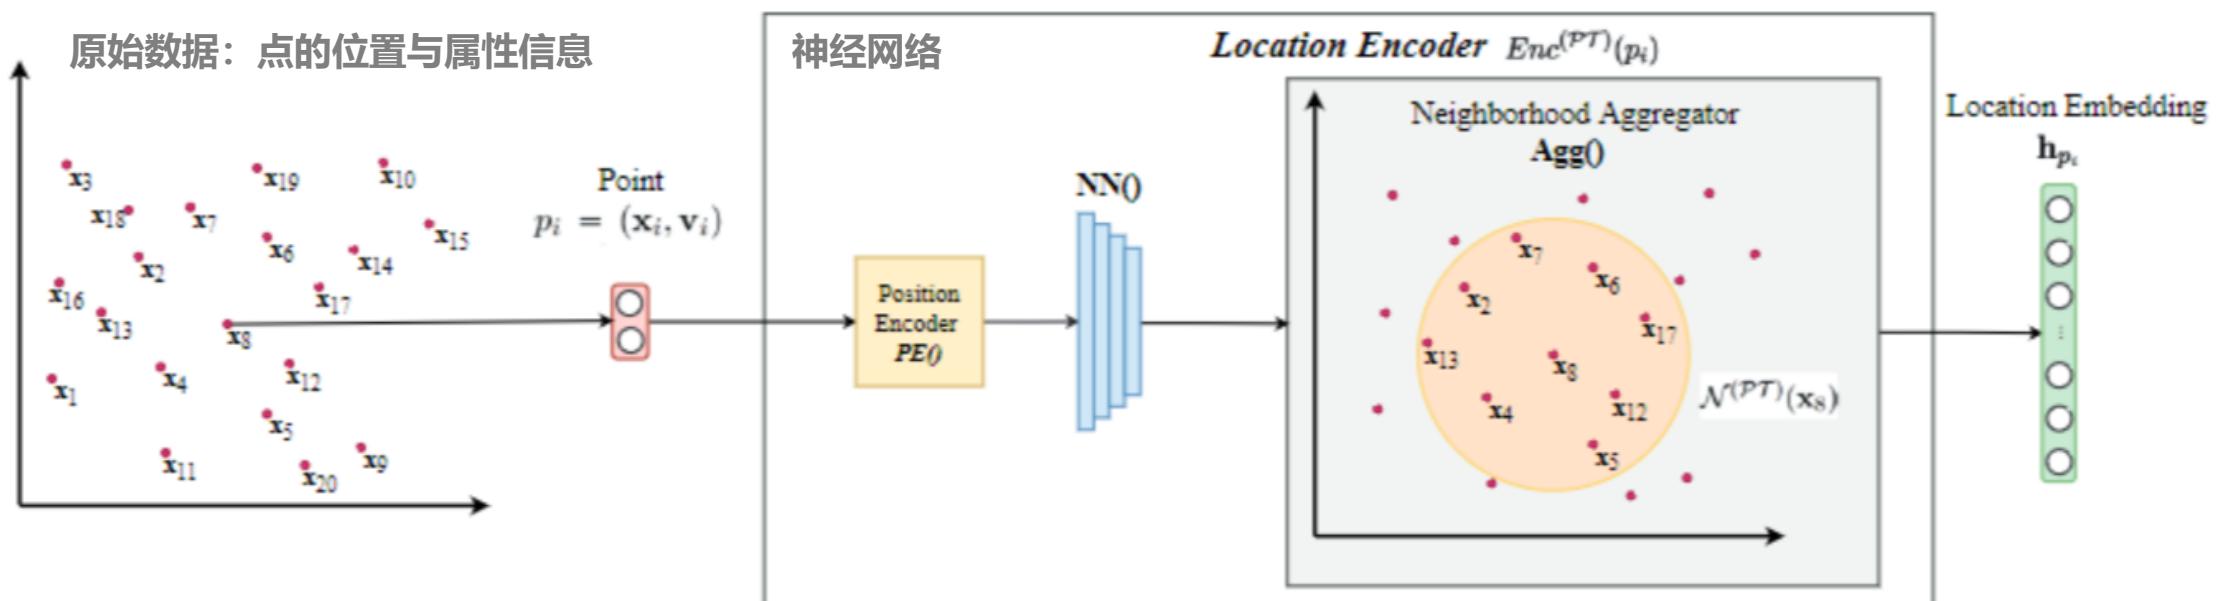
- 位置的表示学习 (Location Encoding)
- 多段线的表示学习 (Polyline Encoding)
- 面对象的表示学习 (Polygon Encoding)
- 栅格对象的表示学习 (Raster Encoding)
- 不规则对象的表示学习



AI、GeoAI、空间显式AI与空间表示学习之间的关系

位置的表示学习：如何让算法认识点数据？（兴趣点等）

- 可以规避以网格为基本研究单元而导致的MAUP问题，多用于3D点云处理与地理分布估计等领域中；
- 由于涉及到点的位置等空间信息，常常使用卷积神经网络（CNN）来捕获点数据的空间依赖：
 - 位置保留（Distance Preservation）与方向感知（Direction Awareness）



GeoAI 中对点位置进行编码的一般流程：采用神经网络架构将点的位置与属性信息直接表示为高维嵌入

位置的表示学习：有哪些位置表示方法？

□ Single Point Location Encoders

□ Discretization-based location encoder

将点数据离散化为空间网格，再用 One-Hot 编码；

□ Direct Location Encoder

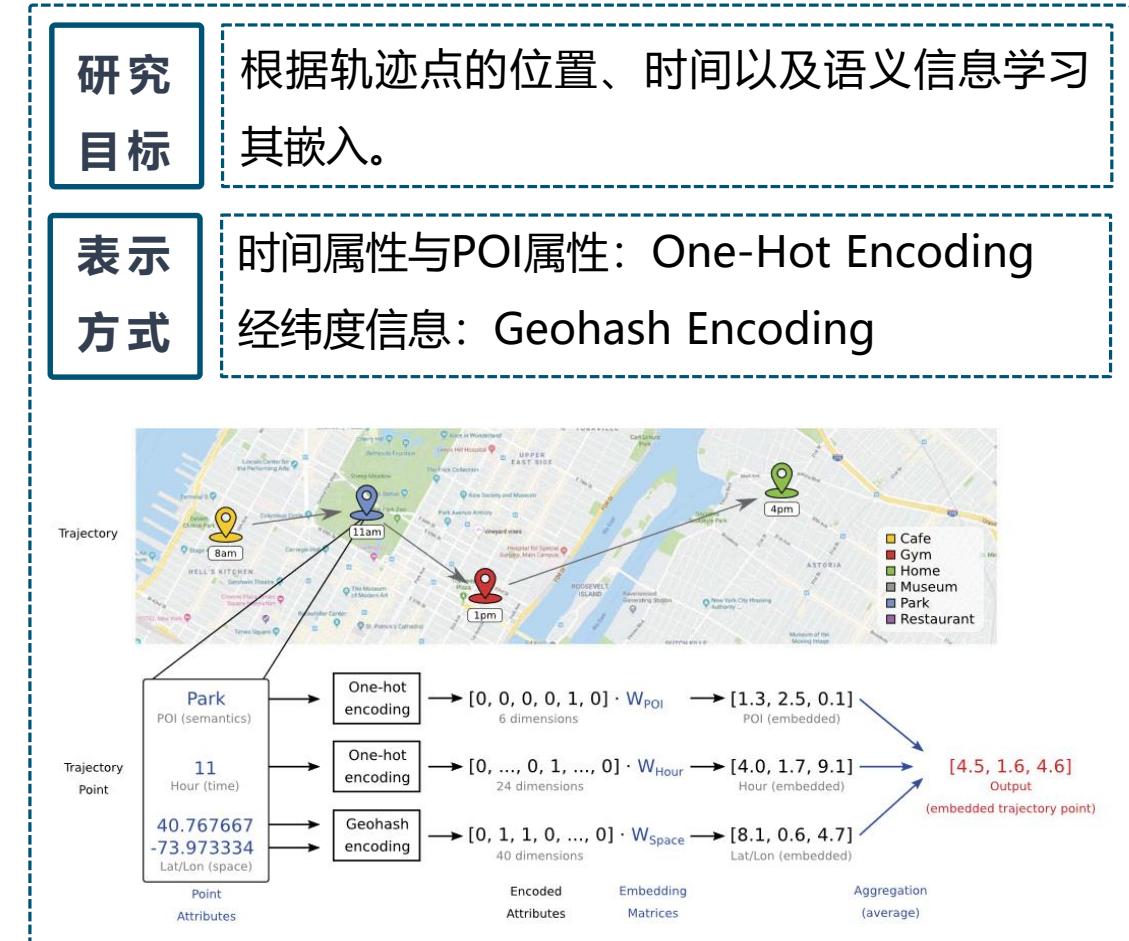
直接对输入位置的经纬度特征进行归一化/标准化；

□ Transformer-Based Location Encoder

□ Aggregation Location Encoders

□ Global Aggregation Location Encoder

□ Local Aggregation Location Encoder



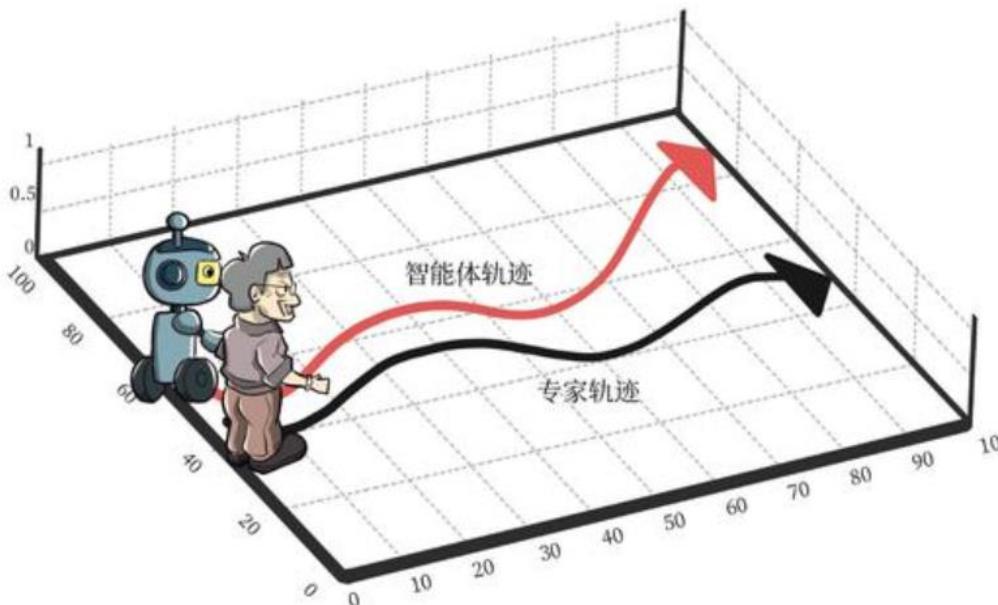
Mai, G., Janowicz, K., Hu, Y., Gao, S., Yan, B., Zhu, R., Cai, L., & Lao, N. (2021). A Review of Location Encoding for GeoAI: Methods and Applications. arXiv.Org.
<https://doi.org/10.1080/13658816.2021.2004602>

May Petry, L., Leite Da Silva, C., Esuli, A., Renso, C., & Bogorny, V. (2020). MARC: a robust method for multiple-aspect trajectory classification via space, time, and semantic embeddings. International Journal of Geographical Information Science, 34(7), 1428-1450.

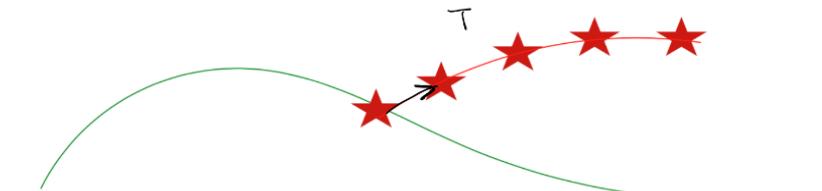
为什么要对多段线进行表示学习?

将轨迹点的表示拼接成一个向量作为轨迹的表示是否可行?

- 轨迹不定长;
- 轨迹点前后依赖。



Problem: Compounding Errors



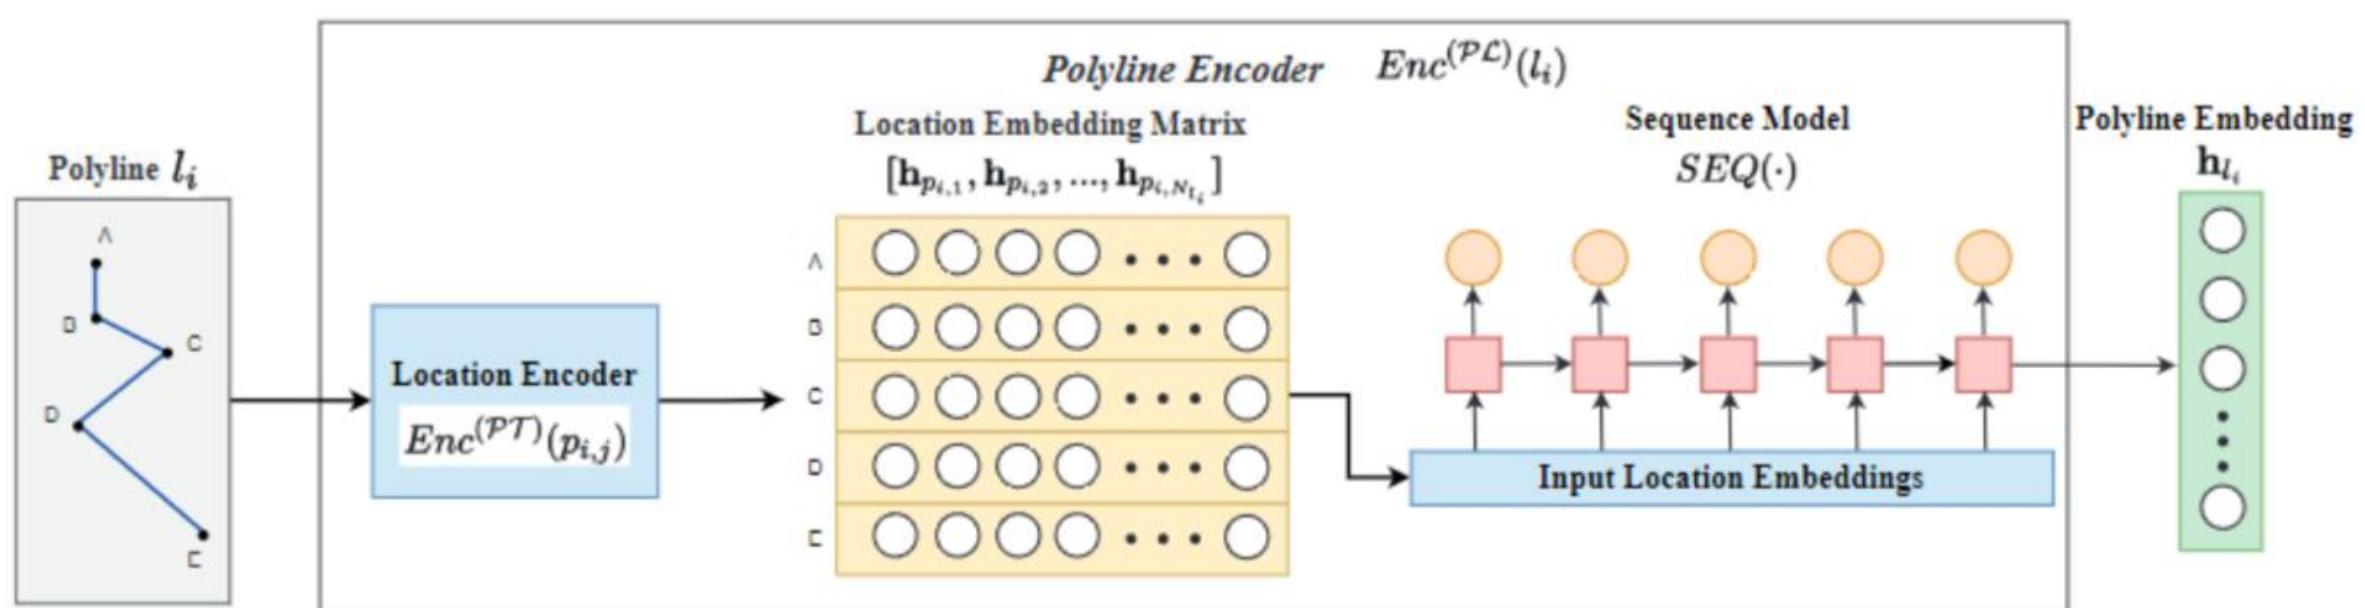
$$\text{Error at time } t \text{ with probability } \epsilon \\ \mathbb{E}[\text{Total errors}] \leq \epsilon(T + (T - 1) + (T - 2) \dots + 1) \propto \underline{\epsilon T^2}$$

A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning, Ross et al. 2011

模仿学习将车辆的行为视作离散的决策点，由于误差累积造成的复合误差 (Compounding Errors) 很容易导致车辆偏离道路

多段线的表示学习：如何让算法认识多段线数据？（轨迹数据等）

- 将多段线理解为有限采样点的集合，通过每个采样点的表示来构建整条多段线的表示；
- 利用多段线进行建模的数据往往包含时间信息，常常使用循环神经网络（RNN）等来捕获采样点之间的前后依赖关系。



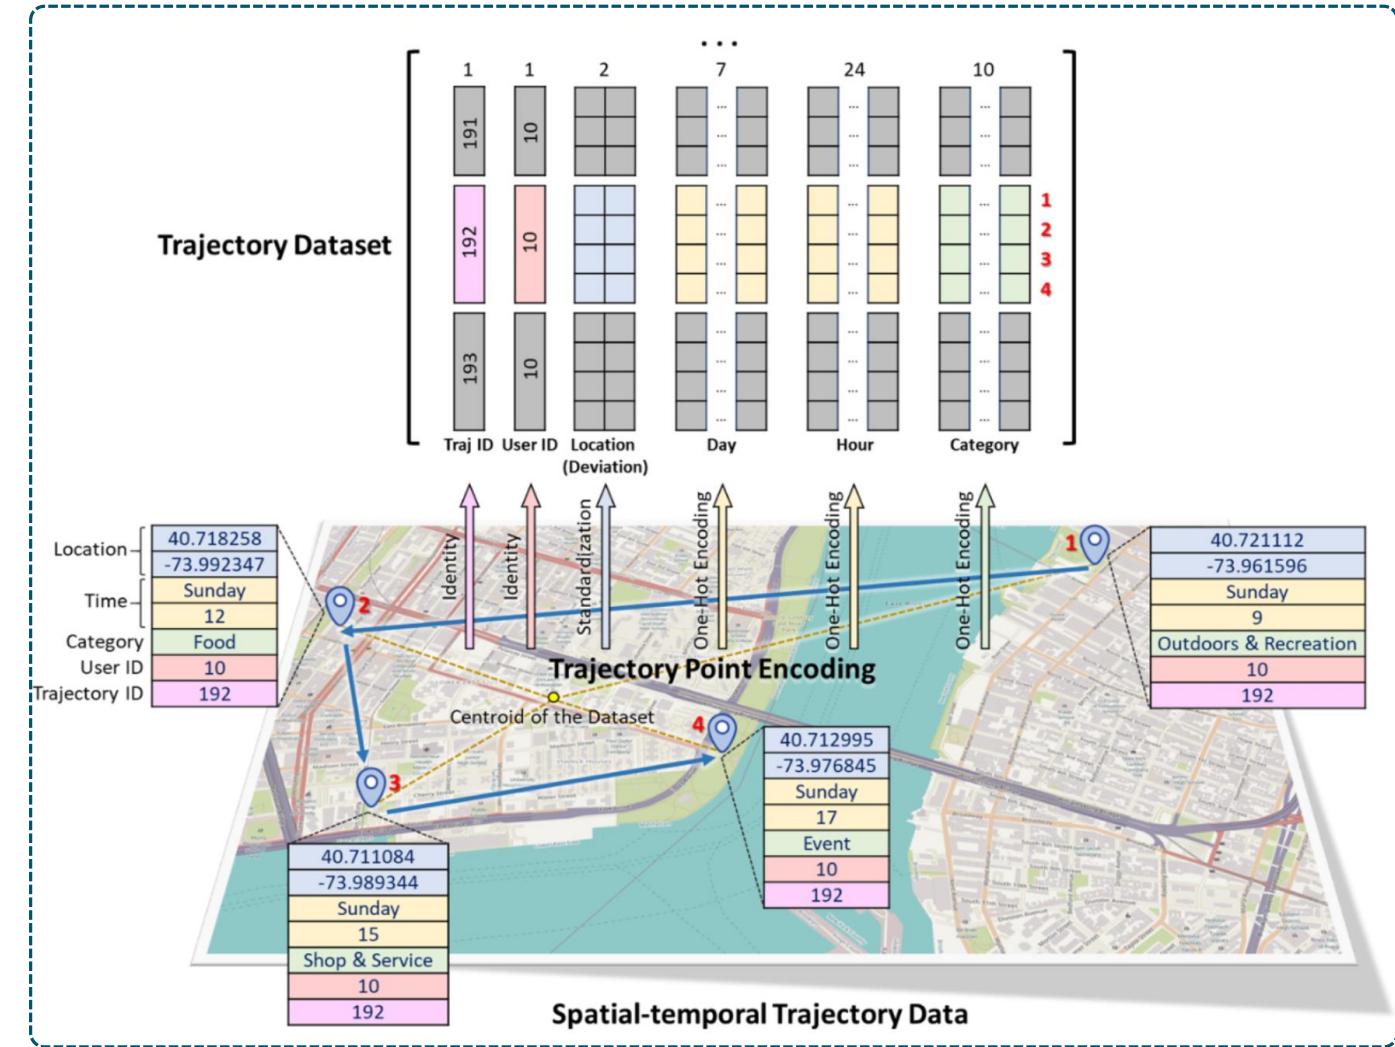
GeoAI 中对多段线进行编码的一般流程：采用神经网络架构将多段线直接表示为高维嵌入，一般包含顶点嵌入与位置嵌入两个步骤。

多段线的表示学习

多段线表示学习：一个案例

- 将轨迹数据中所包含的各种类型属性（轨迹ID、用户ID、位置、日期以及点的属性）转换为有效的数值，拼接成为特征向量以输入到神经网络之中。

轨迹数据嵌入示意图 (Rao et.al, 2020)



多段线的表示学习

研究出发点

- 不丢失信息的情况下对轨迹进行**标准化**；
- 捕捉多方面轨迹数据的**异构维度**；

研究内容

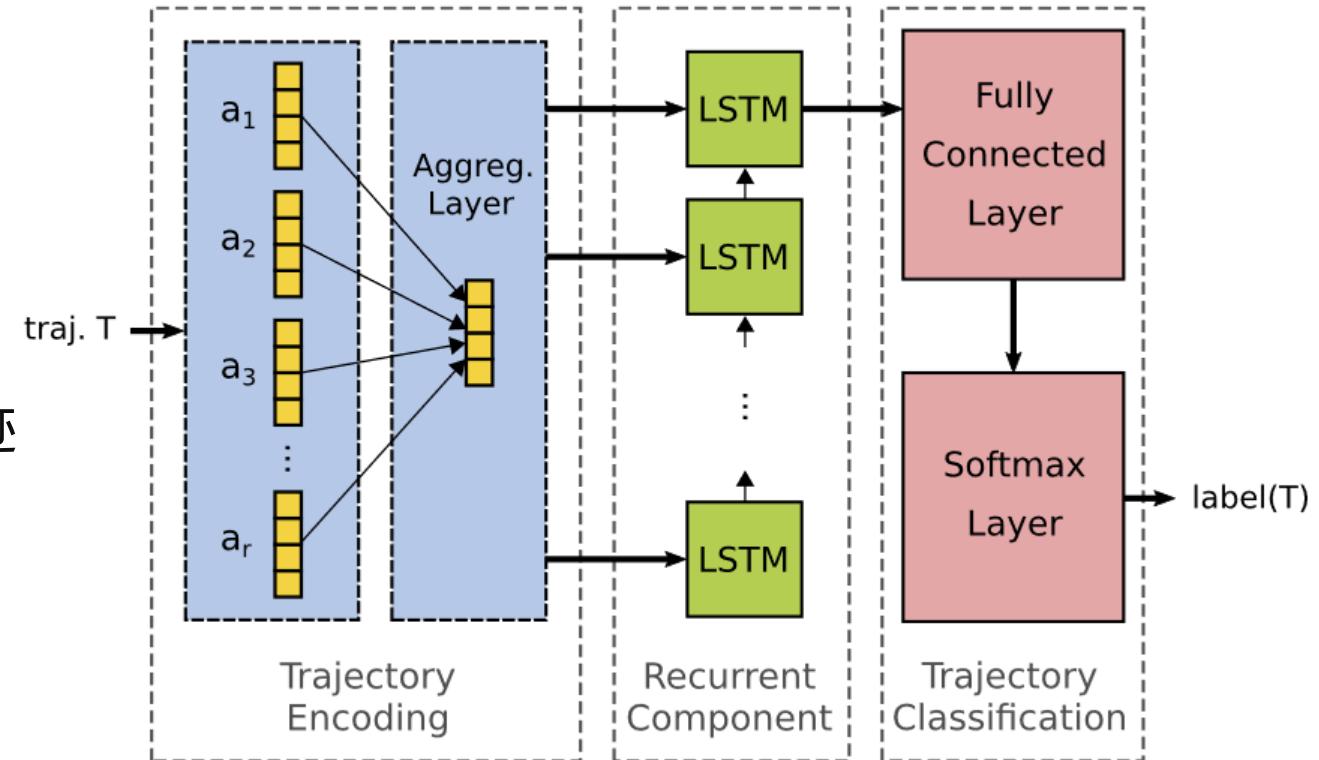
- 基于**属性嵌入与循环神经网络**对多方面轨迹
(Multi-aspect Trajectory) 进行分类；

研究方法

- 利用LSTM捕捉连续轨迹点的序列模式；

研究结果

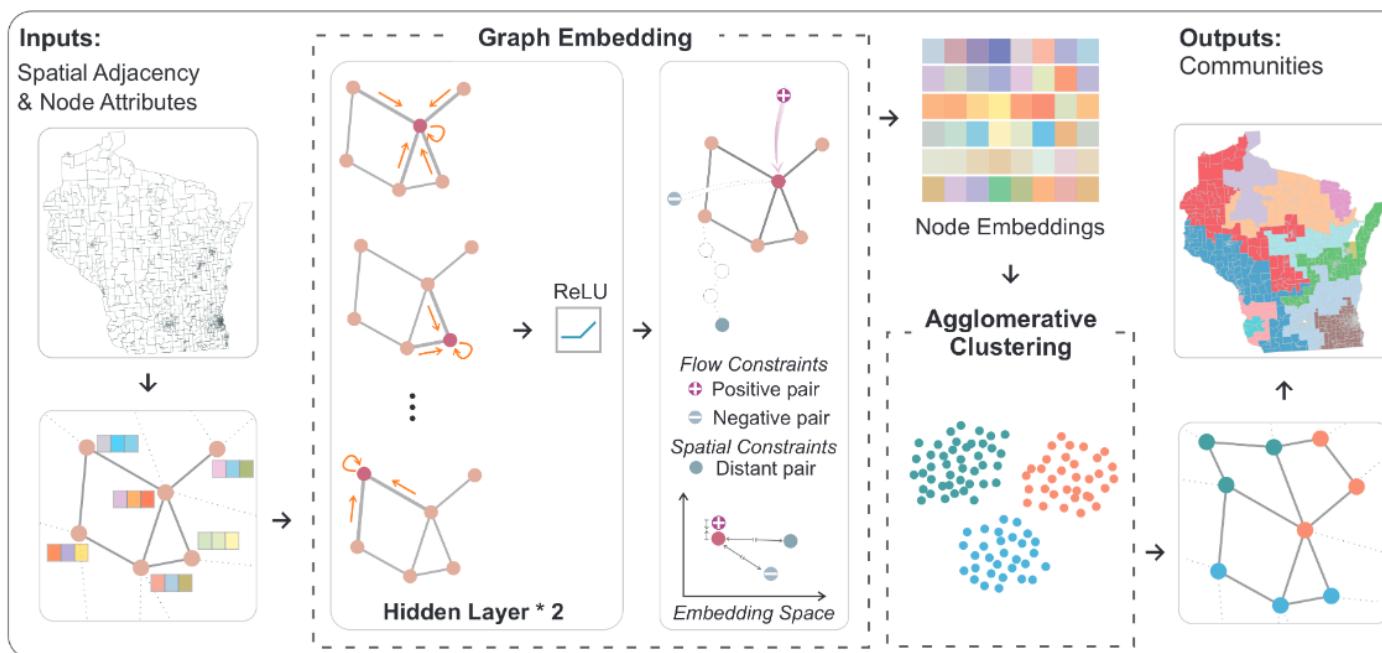
- 轨迹分类：交通模式推断、人群活动类型 ...



轨迹数据嵌入示意图 (May et.al, 2020)

研究出发点

- 空间网络 (Spatial Networks) 的特殊性：属性的相似性与空间交互强度；
- 识别空间网络的社群结构：基于图卷积的社区发现算法 Region2Vec；
- 将地理限制 (Geographic Constraint) 加入到损失函数的设计之中：空间邻近，属性接近，交互强。



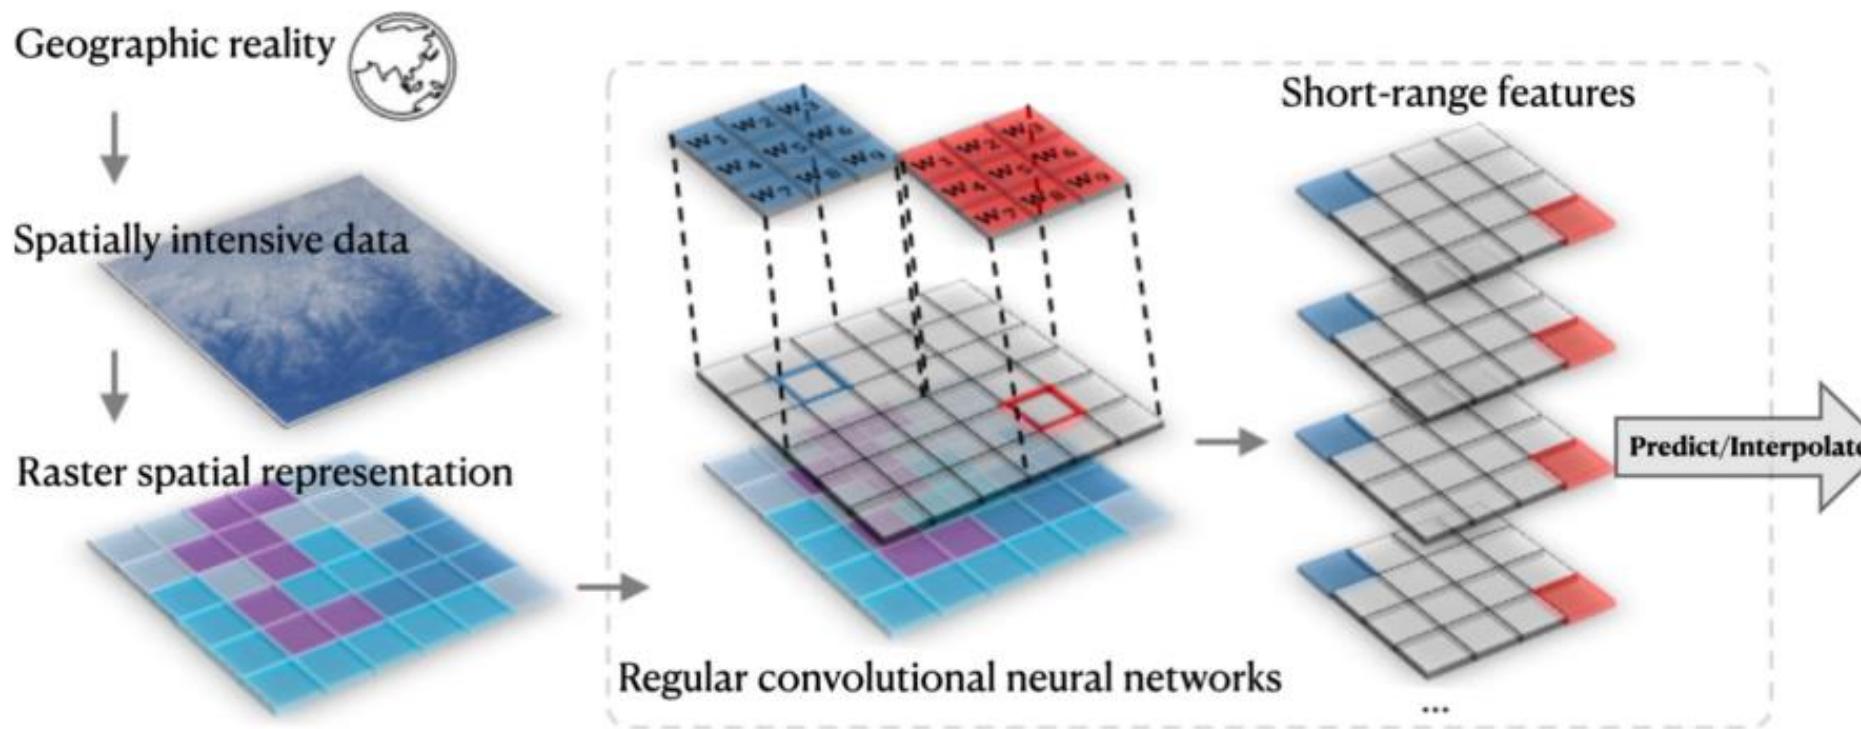
$$L_{hops} = \sum \frac{\mathbb{I}(hop_{ij} > \epsilon) d_{ij}}{\log(hop_{ij})}; Loss = \frac{\sum_{p=1}^{N_{pos}} \log(s_p) d_{posp} / N_{pos}}{\sum_{q=1}^{N_{neg}} d_{negq} / N_{neg} + L_{hops}}, \quad (2)$$

where hop_{ij} represents the hop numbers of the shortest path between v_i and v_j in the graph, and d_{ij} is the euclidean distance between the corresponding embedding representations. $\mathbb{I}(\cdot)$ is set to 1 if $hop_{ij} > \epsilon$, or 0 otherwise. Positive pairs and negative pairs of nodes are denoted by $pos_p, p \in [0, N_{pos}]$ and $pos_q, q \in [0, N_{neg}]$, respectively. Since the intensity of flow s_p has a large range of values, we adopt a log transformation so that the flow values will not get overwhelmed by the extremely large values. The pseudo

社区发现损失函数的设计

栅格对象的表示学习：如何让算法认识栅格数据？

- 利用卷积神经网络（CNN）学习栅格数据中的深度空间特征。



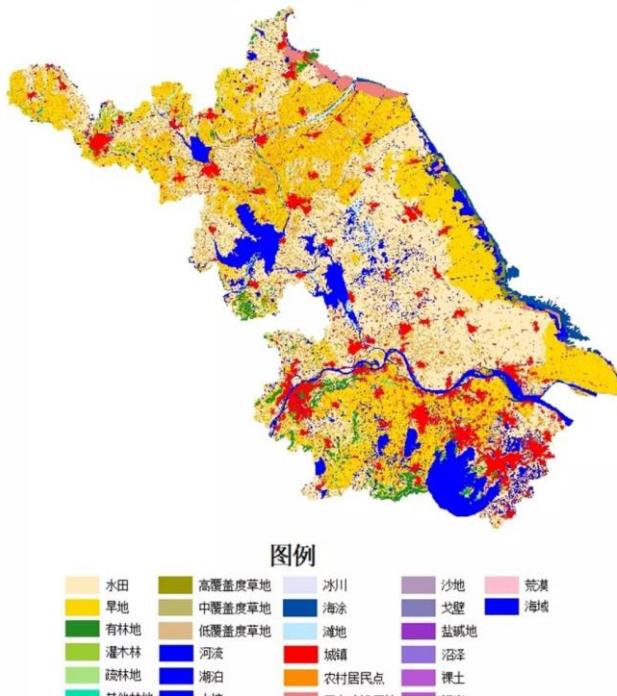
各种类型的分类与

预测任务

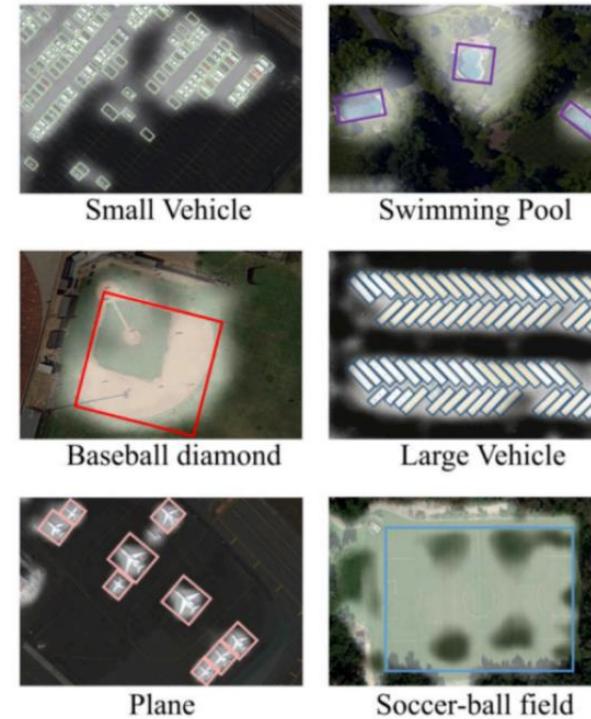
- 地物分类；
- 地物检测；
- 语义分割；
-

栅格对象的表示学习

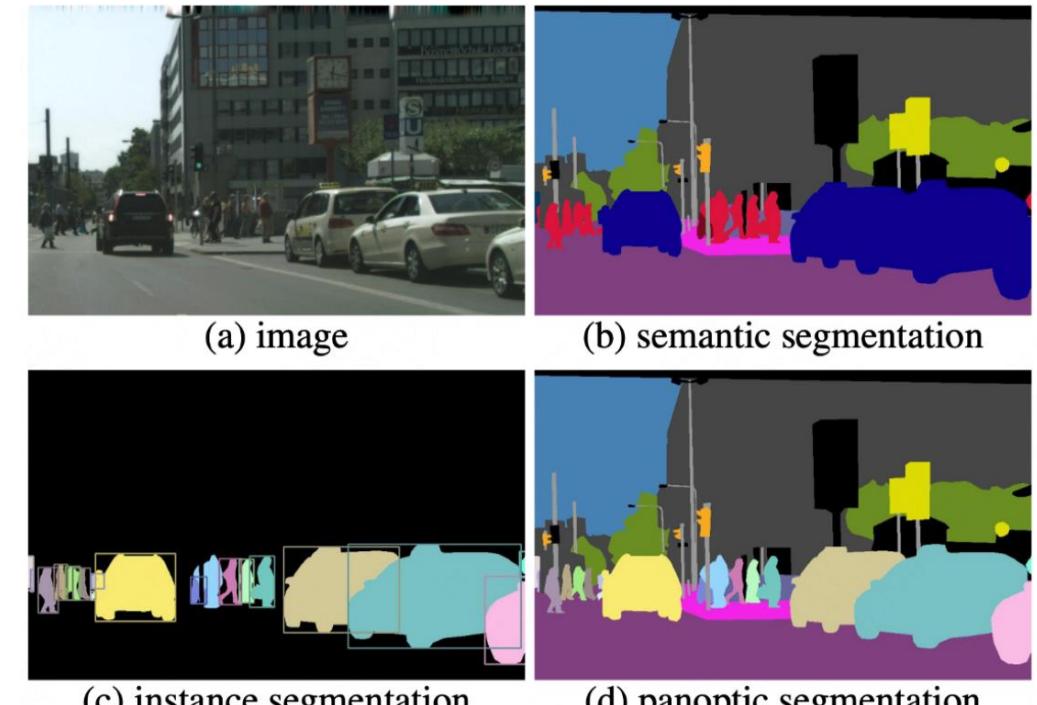
□ 通常将栅格对象表示学习的结果作为分类任务的上游输入。因此，此类任务常常被视作计算机视觉（Computer Vision, CV）领域的子任务。



遥感地表覆盖分类



遥感地物检测



街景图像的语义分割

出发点

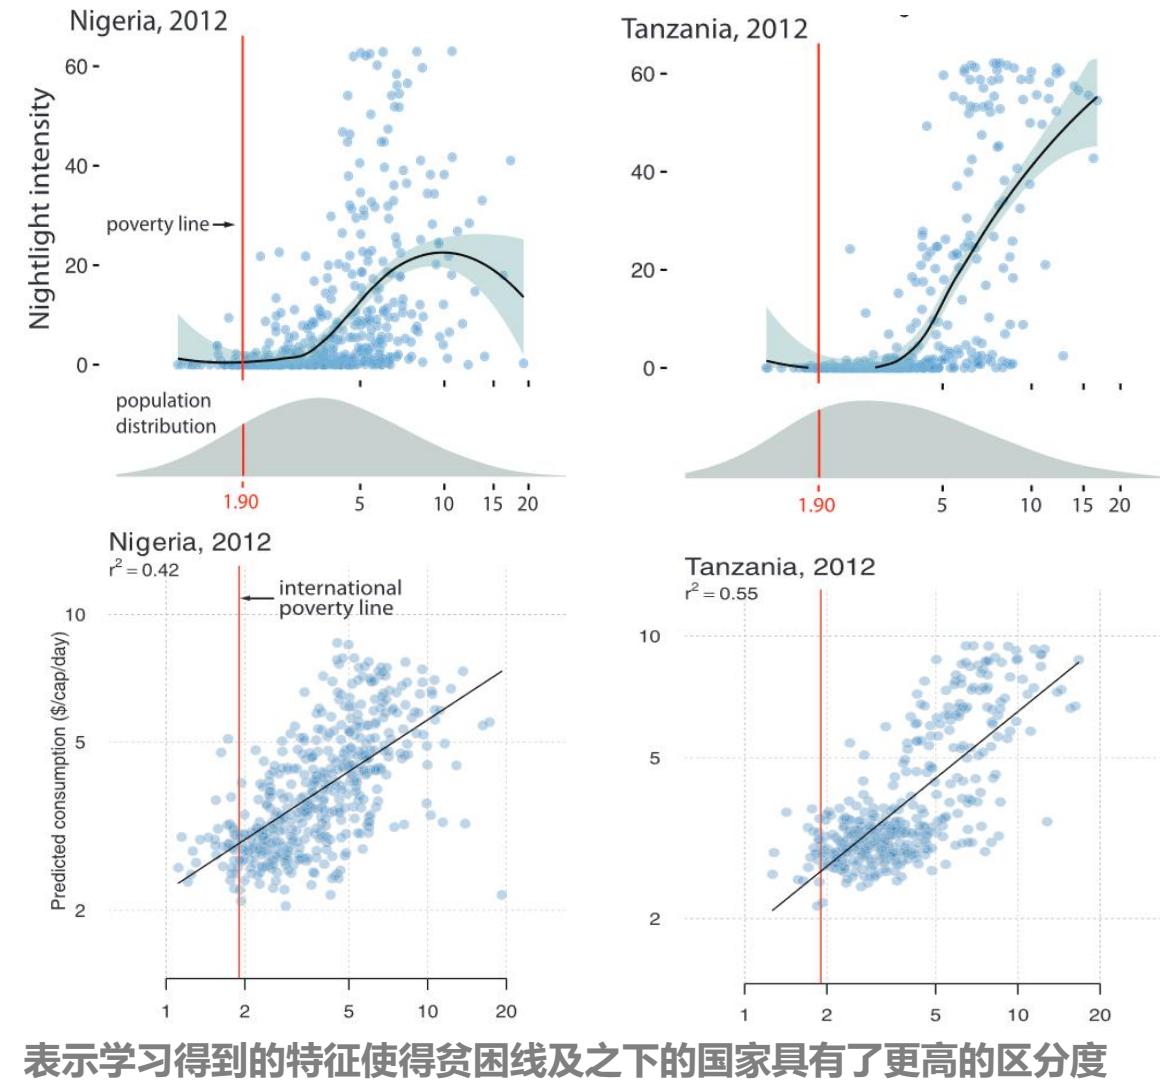
- 夜间灯光影像在区分国际贫困线附近及以下区域的经济活动差异方面表现有限；
- 手机信令依赖于特定数据集难以推广；

研究内容

- 提出一套可扩展的、用高分辨率的卫星图像估算研究区域的消费支出与资产财富的方法；

技术方法

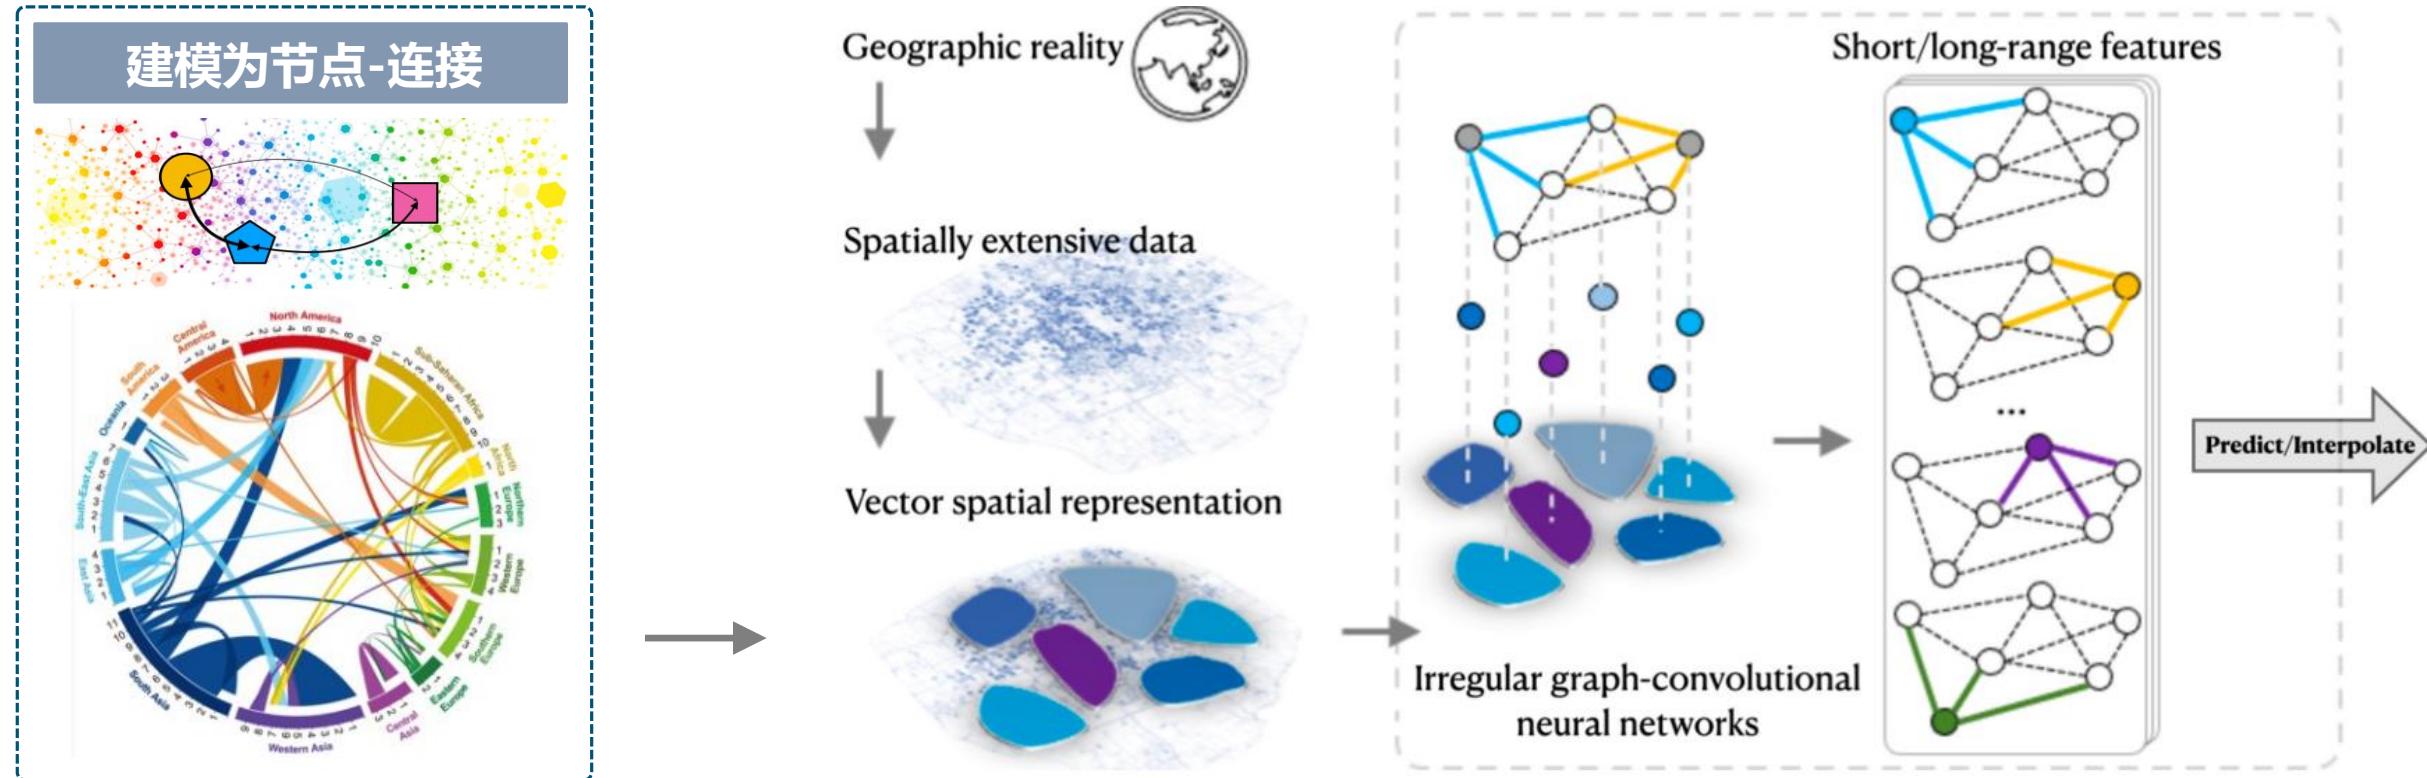
- 训练卷积神经网络识别图像特征，解释当地的经济变化。



不规则对象的表示学习

不规则对象的表示学习：如何让算法认识不规则对象？

- 利用图神经网络 (GNN, GCN) 学习不规则数据的结构。



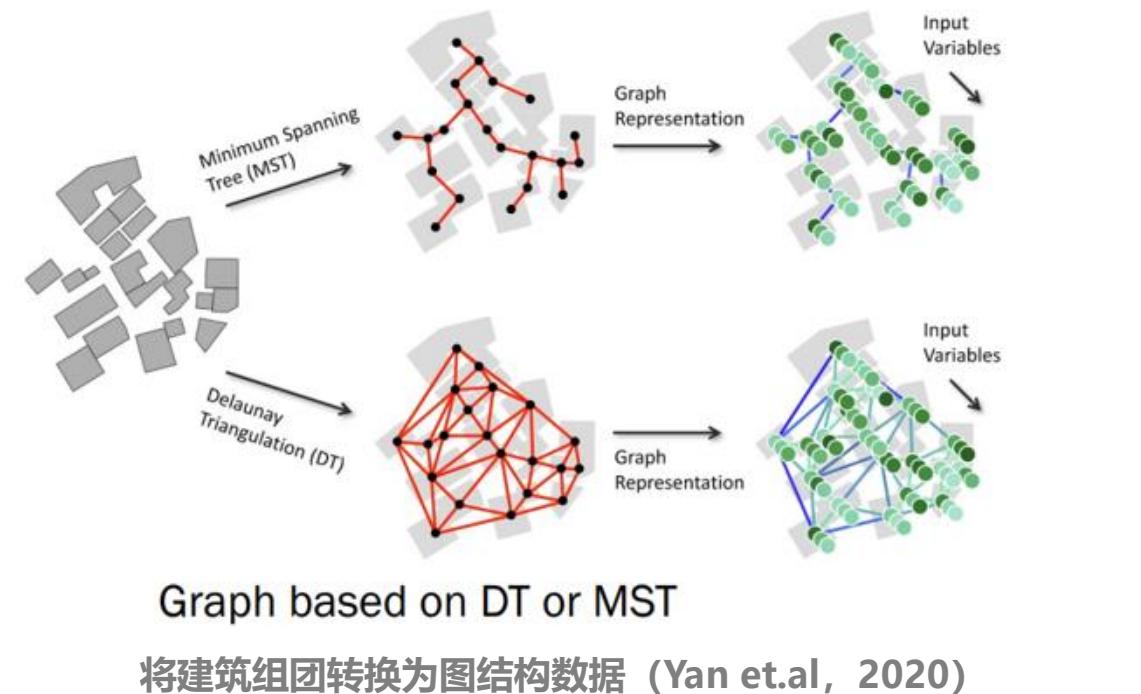
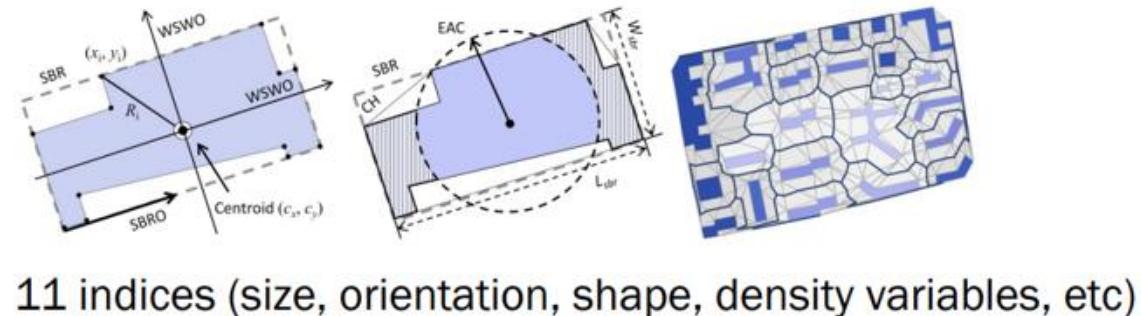
不规则对象的表示学习

研究目标

- 利用图神经网络识别建筑组团；
- 需要首先将建筑组团转换为网络结构数据。

研究方法

- 选择特定区域的建筑群构建网络：
- 每个建筑为网络的**节点**；
- 分别采用最小生成树（MST）与德洛内三角网
构建建筑之间的**连接**；
- 选择包含建筑面积、角度等在内的11个指标作
为节点的**属性**。



GeoAI中的异质性感知学习

□ 如何让算法理解地理现象中的空间自相关与空间异质性?

- 空间问题在理论上无法通过具有一组参数的单一模型来逼近;
- 空间坐标不应该被简单地添加为机器学习/深度学习的输入特征，否则很有可能因为过拟合而影响到模型的泛化性;
- GeoAI 中异质性感知学习的分类：
 - 表现驱动 (Performance Driven)
 - 公平性驱动 (Fairness Driven)

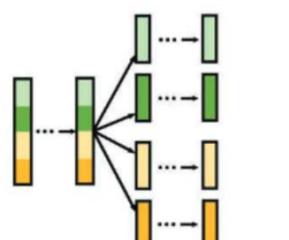
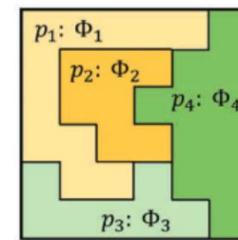
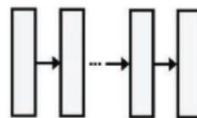
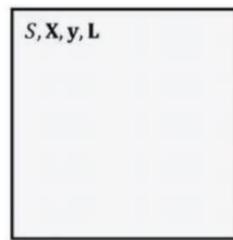


裸地 林地

研究上述区域的鸟类分布情况：
从直觉上来讲，林地与裸地的鸟
类分布有所差异，不能用同一套
参数进行建模。

表现驱动 (Performance Driven)

- **目标:** 此类学习范式侧重模型的整体预测质量;
- **结果:** 空间划分。每个子区域属于同一个数据生成过程，可以共享相同的参数 θ 。



(a) Input: Study area

(b) Input: Deep network F

(c) Output: Space partitioning

(d) Output: Spatialized network F_p

表现驱动的异质性感知学习框架

公平性驱动 (Fairness Driven)

- **目标:** 减少研究区域内部不同位置的预测质量的变化。
- **结果:** 模型参数 θ ，对于整个研究区域中所有位置的数据样本来讲， θ 是相同的。

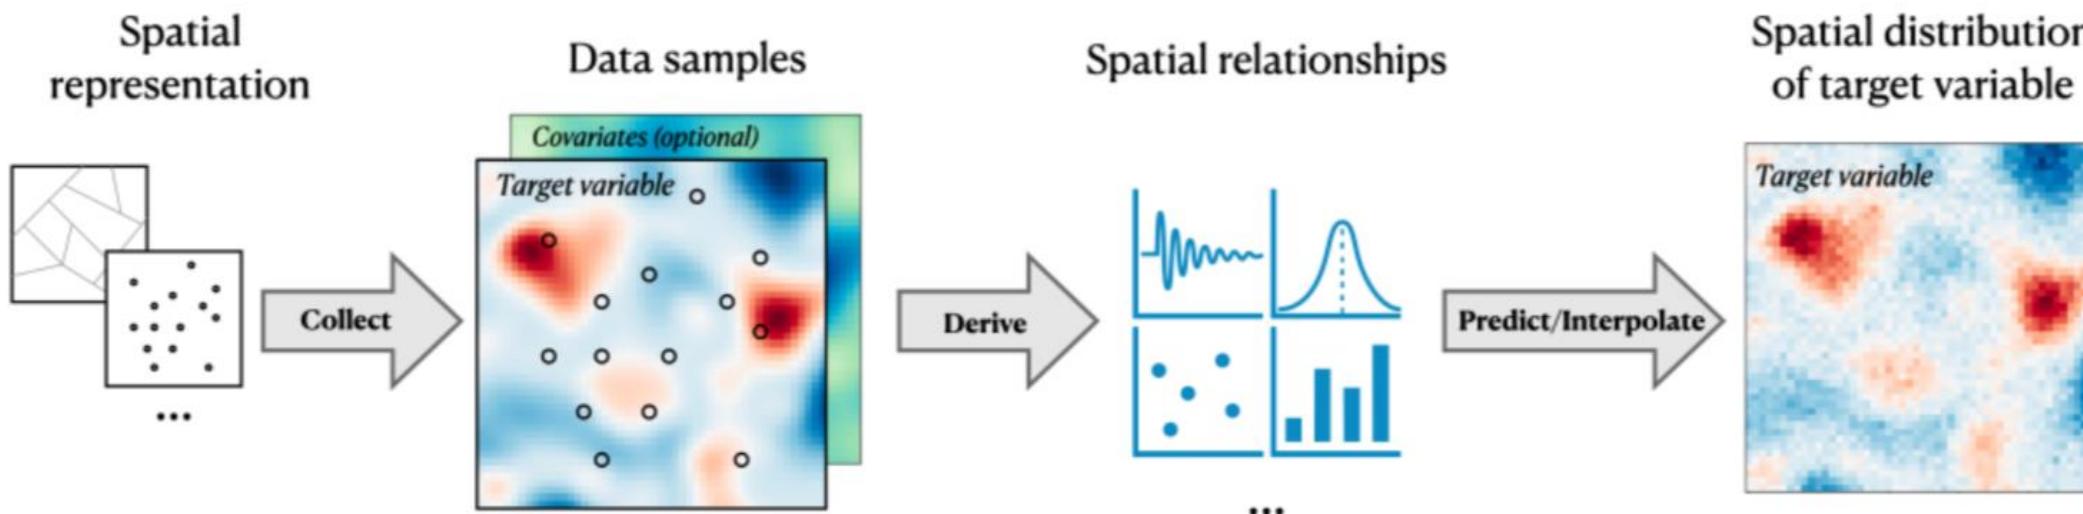
Accuracy	Spatially Fair			Spatially Biased		
Global	80%			80%		
Sub-regions	80%	80%	80%	100%	100%	100%
	80%	80%	80%	100%	40%	100%
	80%	80%	80%	100%	40%	40%

公平性驱动的异质性感知学习

GeoAI 中的地理现象建模与地理趋势预测

经典研究议题：空间预测，即利用采样位置的观测来估计未知位置的目标地理变量。

- 首先，基于给定的空间表示在感兴趣的区域上选择一组采样位置；
- 其次，定义这些采样位置的空间结构，然后分析在这些位置收集的空间样本以导出空间关系，该**空间关系**描述了目标变量的值与空间中的采样信息如何相关；
- 最后，这些关系被用于预测变量的值，包括未观察到的值。

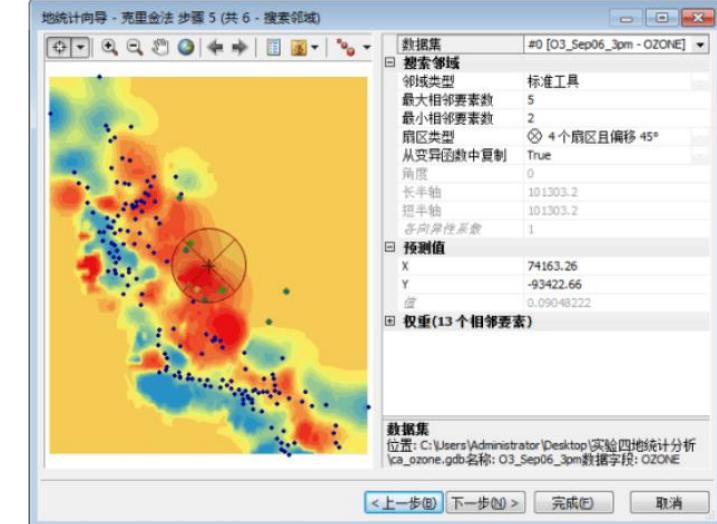
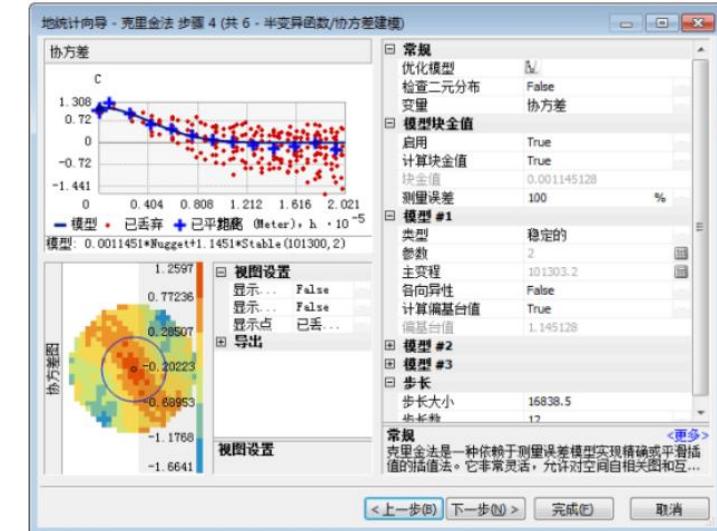


地理现象建模与地理趋势预测

- 空间预测的成功与适用性的关键是**描述空间关系所采用的基本假设**以及在**模型中表征这些关系的方式**。**现有的大部分方法**遵循经典统计原理、先验领域知识与经典计算范式，**而空间依赖性与异质性的本质要比经典统计模型要复杂得多。**
- **针对经典研究议题提出的解决方案：**将机器学习与深度学习纳入到**地统计学与空间回归**之中，并澄清这些集成对空间预测与地理知识发现的影响。

地统计分析方法

- 地统计分析方法：以区域化变量理论为基础，以变异函数为主要工具，研究那些在空间分布上既有随机性又有结构性的现象。
- 地统计方法在建模空间依赖结构与量化空间估计的不确定性方面相当有效。
 - 大部分地统计方法都假设空间变化可以用简单的距离函数来建模，并且空间模式在整个研究区域是固定的。这些假设使得这些方法在观察结果规则分布、研究区域同质的情况下表现较好。
 - 当面对复杂空间模式的异质情况时，相应方法的效果相当有限。
 - 基于深度学习的方法擅长从高维数据中发现错综复杂的模式，其应用为复杂地理空间模式的预测提供了相当有前景的范式。



地统计分析方法研究案例：空间数据的尺度转换

□ 目标：通过尺度转换后获得目标尺度的信息，以满足模型与应用的要求

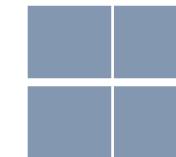
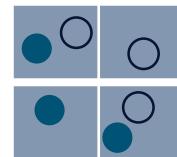
□ 获取目标尺度的数据

□ 获取目标尺度的空间分布或者总体估计结果

□ 满足模型尺度的需求

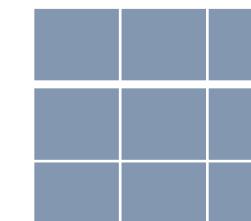
□ 满足应用尺度的需求

样本点



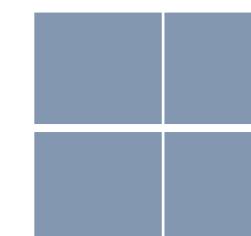
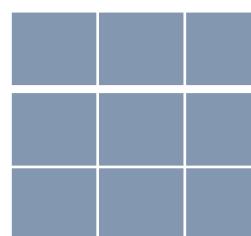
面数据

低分辨率



高分辨率

高分辨率



低分辨率

研究目标:

- 比较传统Kriging 方法与深度学习方法在空间降尺度任务中的表现。

研究数据:

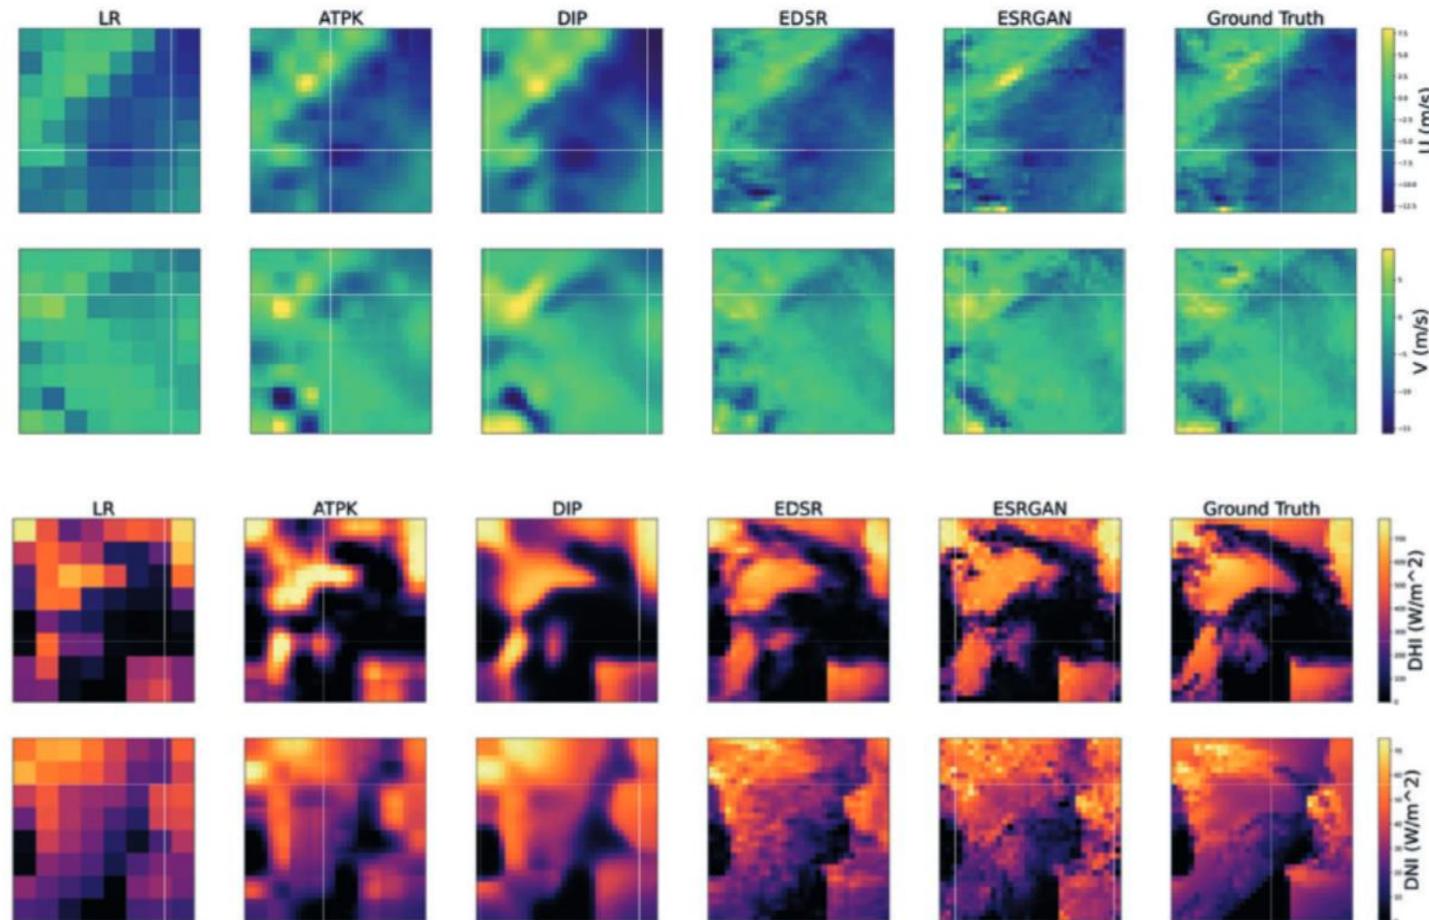
- 风力栅格数据与太阳辐射栅格数据；

研究方法:

- 利用不同模型生成风力栅格数据与太阳辐射数据并比较其真实程度。

研究结论:

- 深度学习模型显著改善了图像生成的质量，学到了数据空间分布模式。



上图为利用不同模型生成的两波段风力，下图为利用不同模型生成的太阳辐射。其中，最左侧是待尺度转换的数据，最右侧是地表实际数据，中间则是模型生成的结果。

空间回归分析方法

□ **空间回归分析方法**：对样本的空间自相关性与空间异质性进行建模。

□ **经典的空间计量经济学范式**：

1. **使用空间连续性或者权重矩阵表示空间依赖性**；

2. **指定一个包含潜在空间效应的回归模型 (Specification) ；**

□ 空间滞后模型 (SAR) ； 空间误差模型 (SEM) ；

□ 空间杜宾模型 (SDM) ； 地理加权回归 (GWR) 与多尺度地理加权回归 (MGWR) ；

3. **估计模型中的参数 (Identification) ；**

□ 最小二乘估计 (OLS) ； 极大似然估计 (MLE) ；

□ 工具变量 (IV) ； 广义矩方法 (GMM) ；

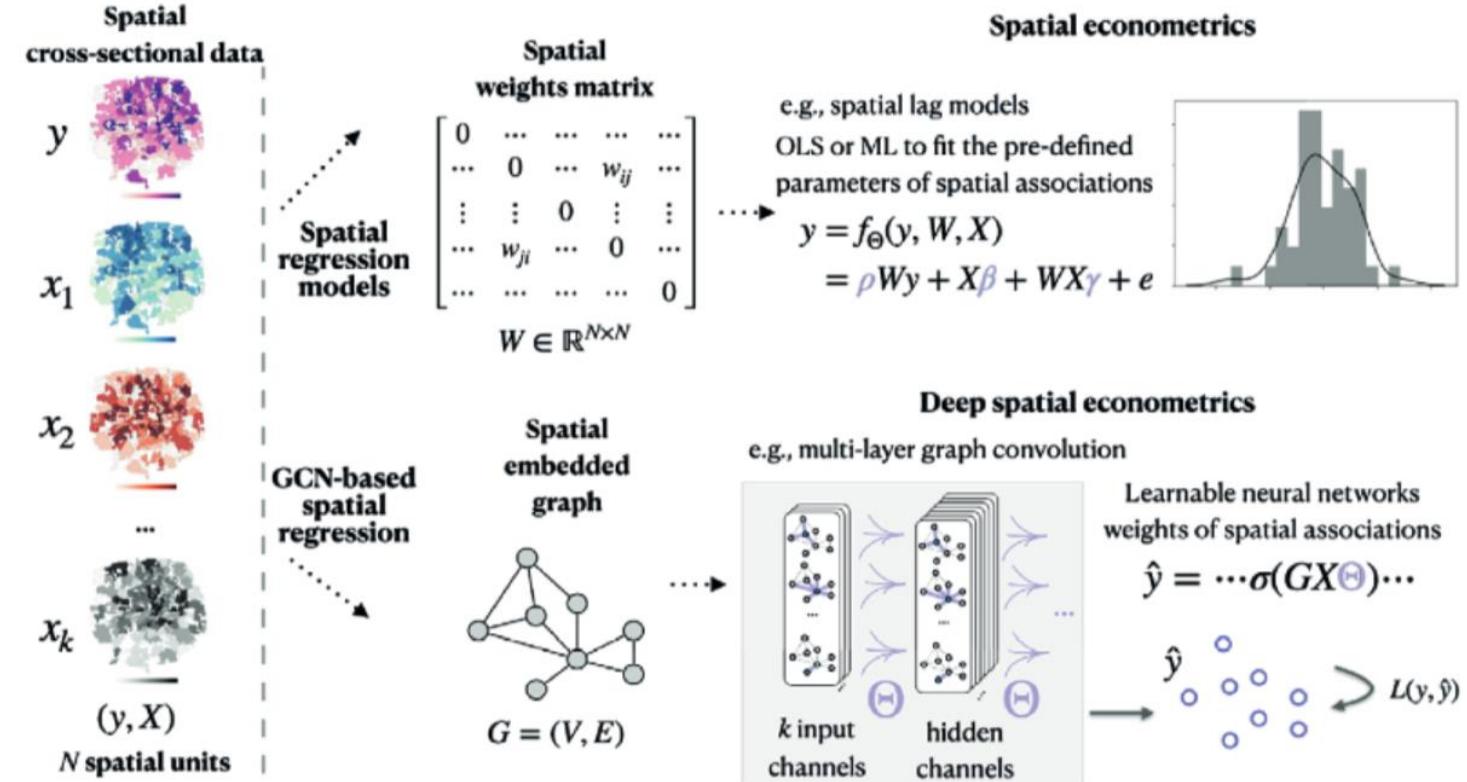
4. **利用拟合好的模型进行空间预测。**

传统空间回归分析方法的局限性

- 受到统计学范式与空间计量经济学的限制，忽略了空间关系的非线性本质；
- **高斯—马尔可夫定理 (Gauss-Markov Theory)**：如何使用 OLS 估计得到无偏最优的参数？
 1. 模型是线性的 (Linear in Parameters)
 2. 随机采样 (Random Sampling)；
 3. 不存在完全共线性 (No Perfect Collinearity)
 4. 不存在内生性 (Zero Conditional Mean)；
 5. 同方差性 (Heteroskedasticity)。
- 空间权重矩阵中包含的特定空间相关结构只能在观察到的自变量和因变量位置之间定义，而不考虑未观察到的因变量的其他位置。
- **上述条件使得空间关系的规范会向观测的位置集中，对缺失数据场景下的空间预测任务来讲，并非一个理想的方案。**

应对传统方法局限性而提出的人工智能方案

□ 利用图卷积神经网络 (GCN) 构建空间权重矩阵：GCN的传播机制、空间局部学习性质与半监督训练策略，天生适合为不规则分布的空间单元构建图结构与空间权重之间的概念映射。

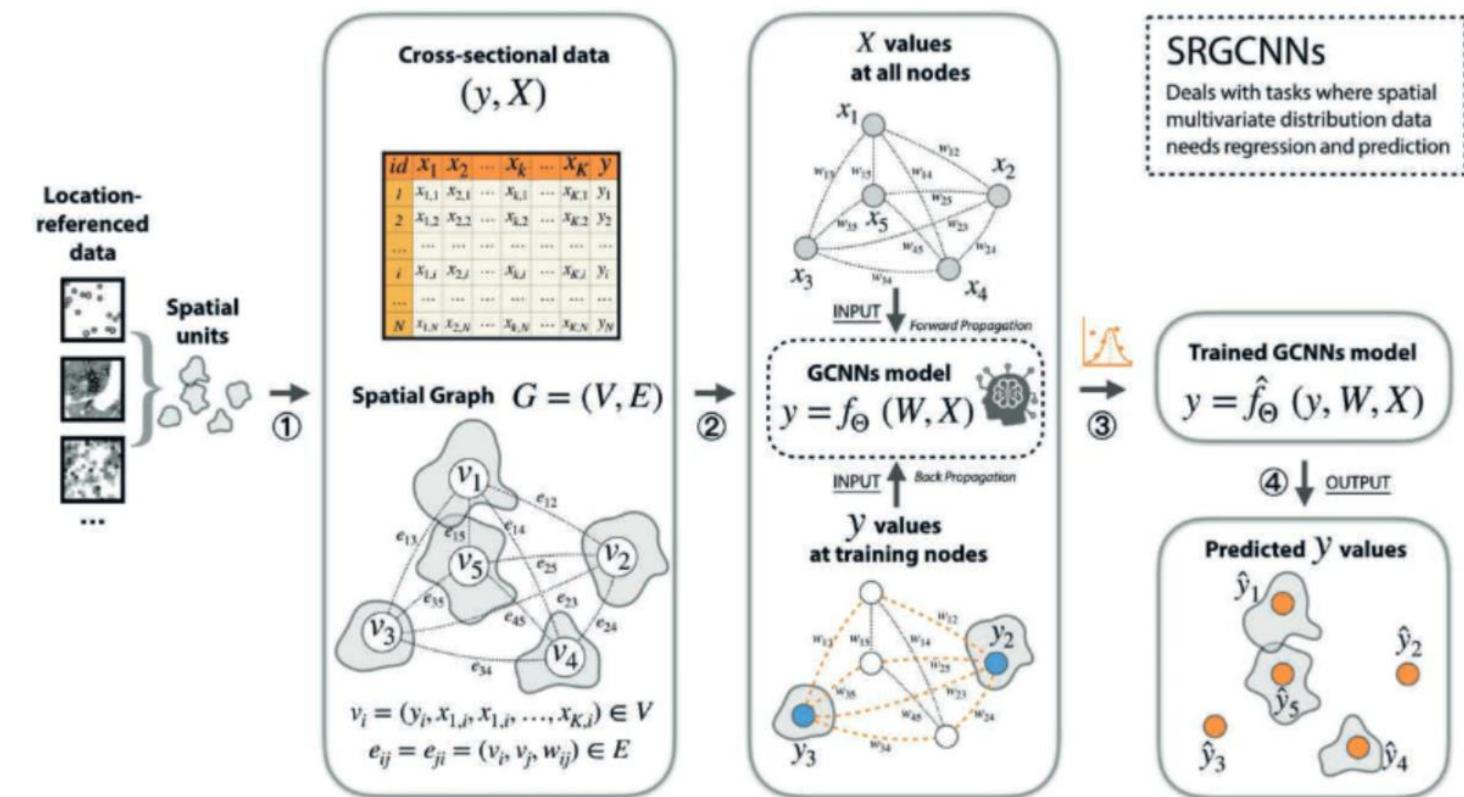


利用图卷积神经网络构建空间权重矩阵

应对传统方法局限性而提出的人工智能方案

空间回归图卷积神经网络

(SRGCN)：利用GCN模仿经典空间回归分析，使得研究者可以直观理解图卷积机制和空间回归模型关键概念之间的联系。



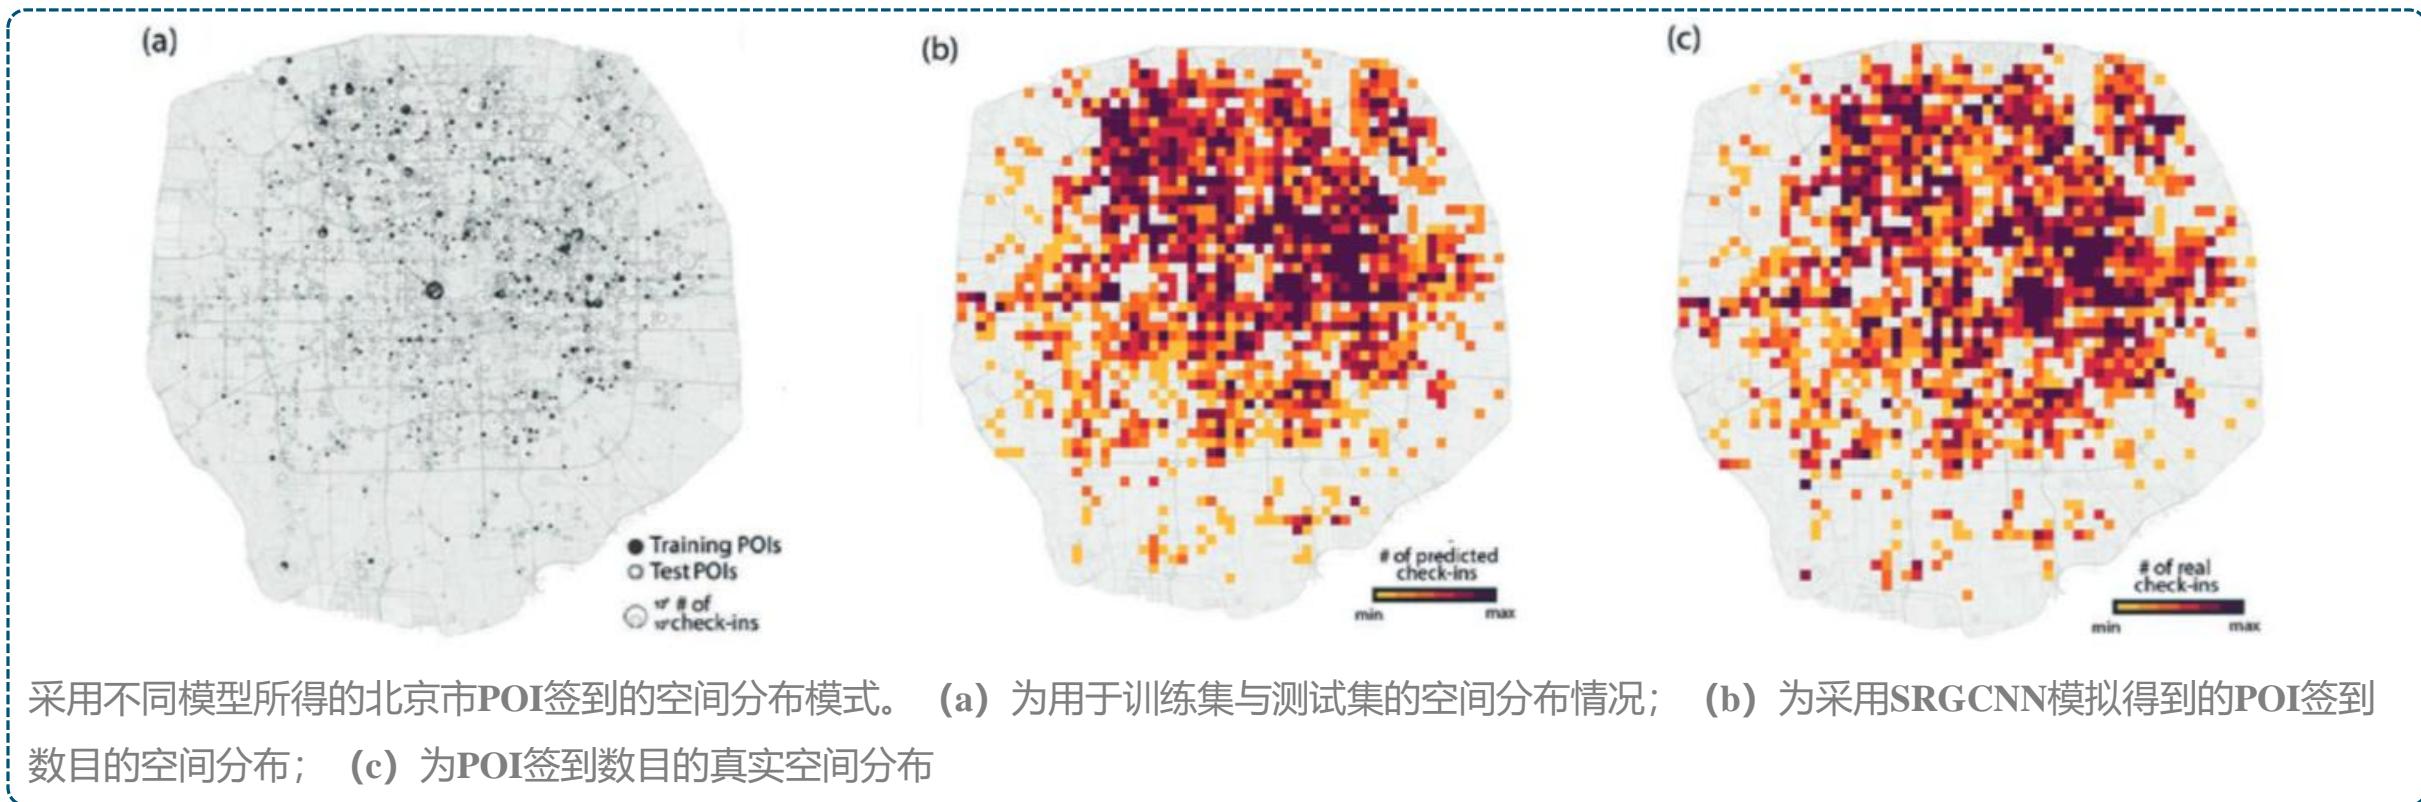
利用图卷积神经网络进行属性数据的空间预测

研究目标

- 预测北京市POI级别的微博签到打卡数目

研究方法

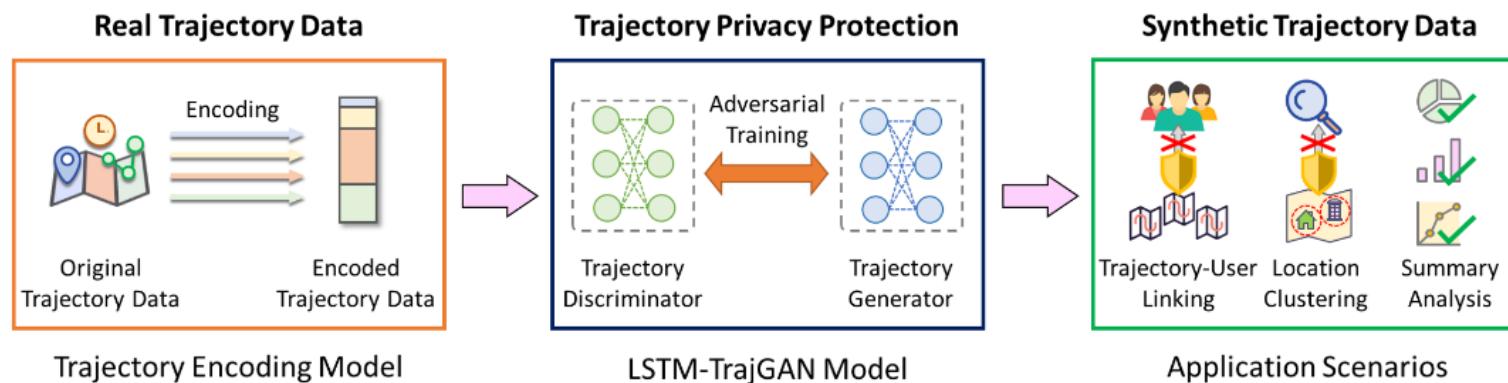
- 基础的SRGCN模型与融合了地理加权回归的SRGCNN-GW模型



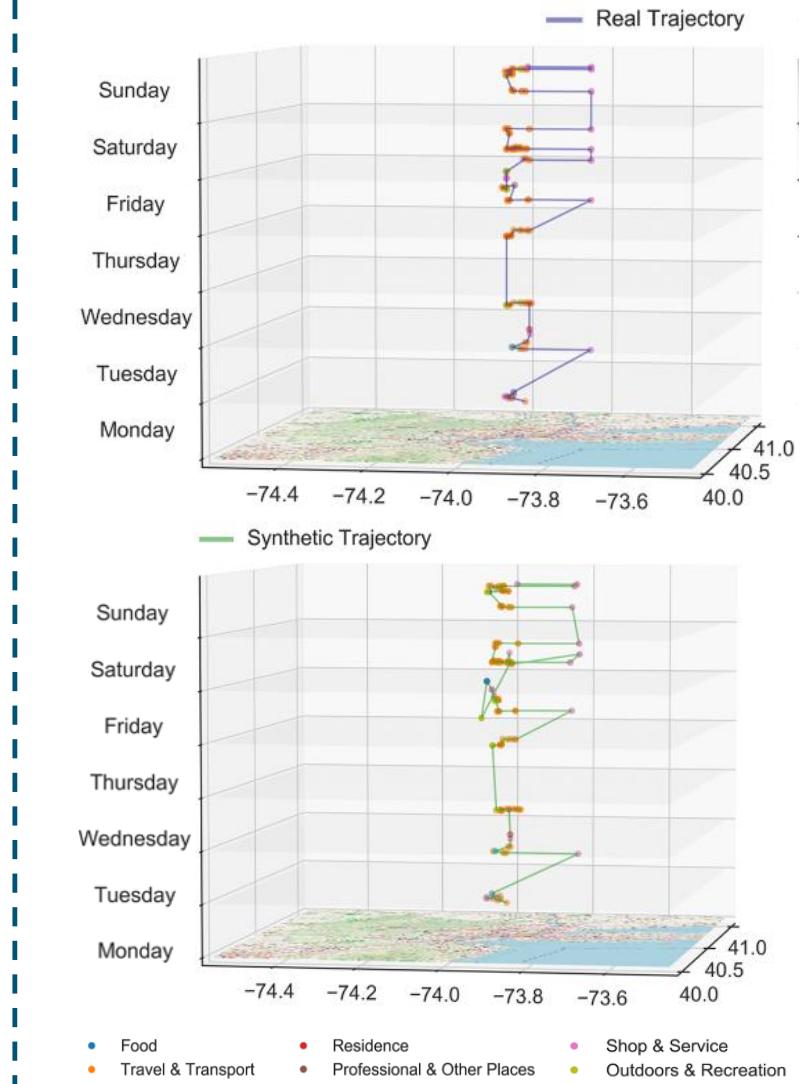
GeoAI与空间回归分析方法

GeoAI 在模拟方面的应用1：LSTM - TrajGAN

- 生成用于保护轨迹隐私的合成轨迹数据；
- 深度学习的黑箱确保了**隐私保护的有效性**；
- **合成轨迹的时空语义特征**：设计新的损失函数以衡量合成轨迹与真实轨迹的相似性。



利用 TrajGAN 模拟轨迹的技术框架



GeoAI 在模拟方面的应用2：Diff - Traj

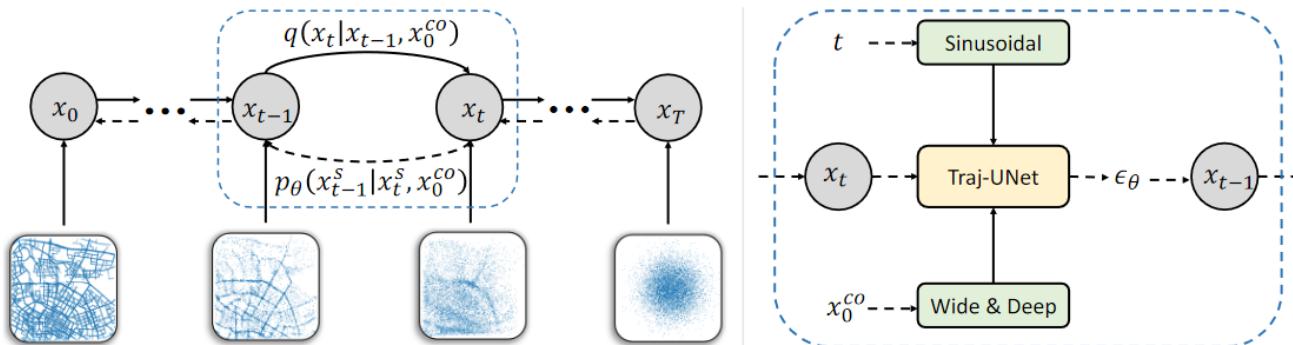
研究目标：基于时空扩散概率模型的轨迹生成方法。

□ 将扩散模型的能力与源自真实轨迹的时空特征结合起来，通过反向去噪的过程合成真实的轨迹数据；

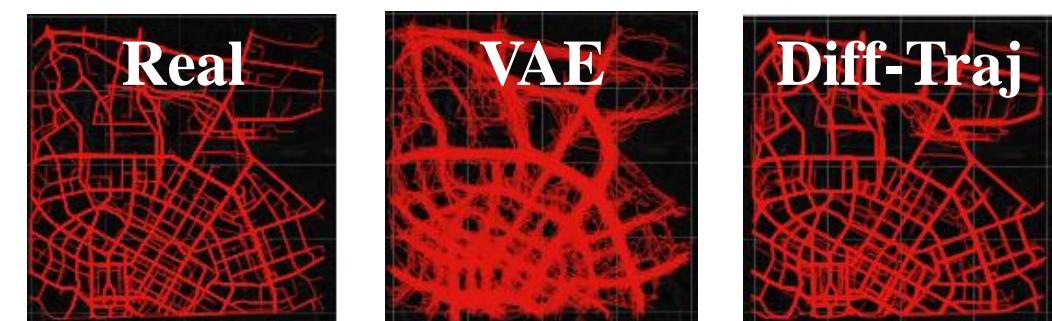
研究出发点：

□ 扩散模型从随机噪声中重建数据，更符合人类活动的随机与不确定性特征，适合生成GPS轨迹；

□ 扩散模型从随机噪声中重建数据，更贴近于隐私保护的要求。



利用 Diffusion Model 模拟轨迹的技术框架



数据拟合结果与真实结果之间的差异

□ 伴随着 GeoAI 的应用，涌现出的新议题

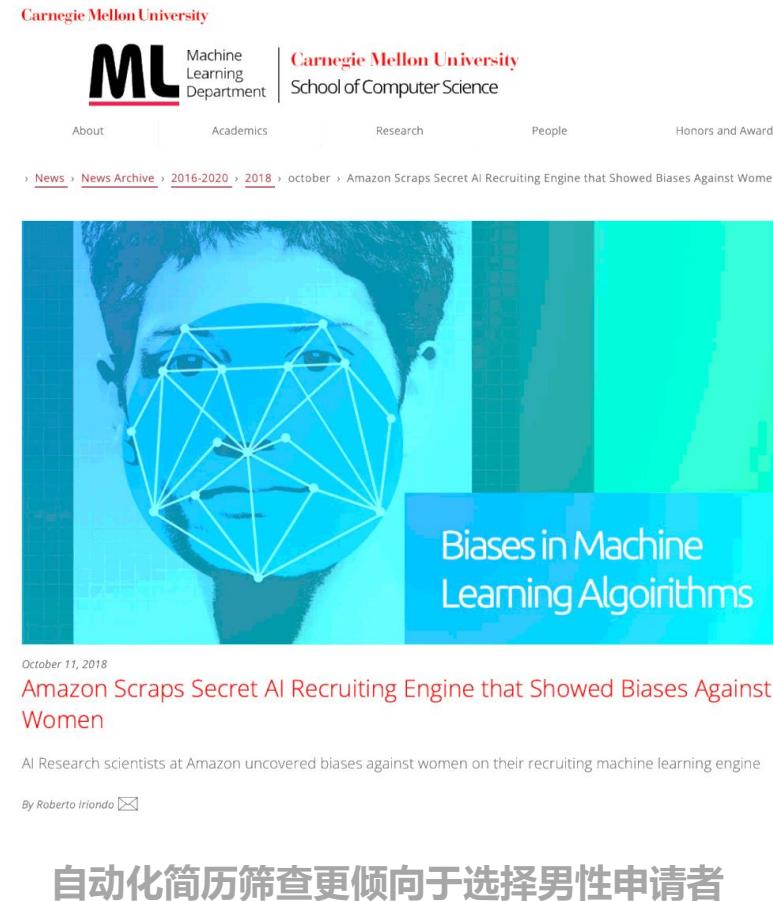
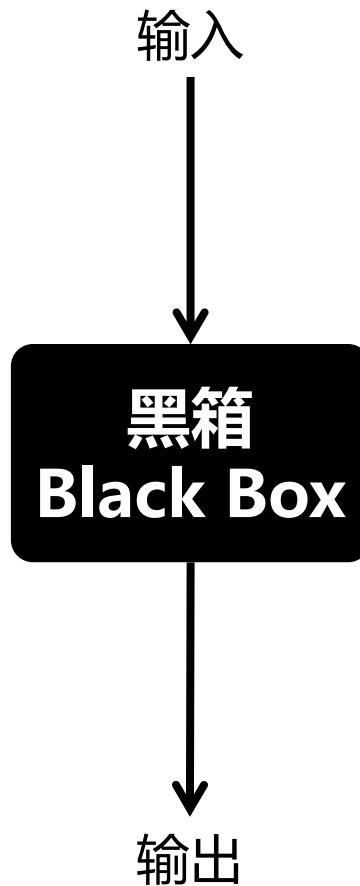
□ 模型的可解释性

- 模型解释的常用方法
- 应用案例
- 未来面临的挑战

□ 模型的泛化能力

- 交叉验证与空间交叉验证
- 应用案例

人工智能是一个黑箱：很难让人理解模型决策与预测的依据。



自动化简历筛查更倾向于选择男性申请者



某AI绘图工具绘制的“唐伯虎点秋香”

如何揭示人工智能算法究竟学到了什么？

- 将先验知识、传统方法与通用的人工智能模型相结合，从而设计**空间显式的人工智能方法**；
- 利用可解释人工智能（XAI）方法。



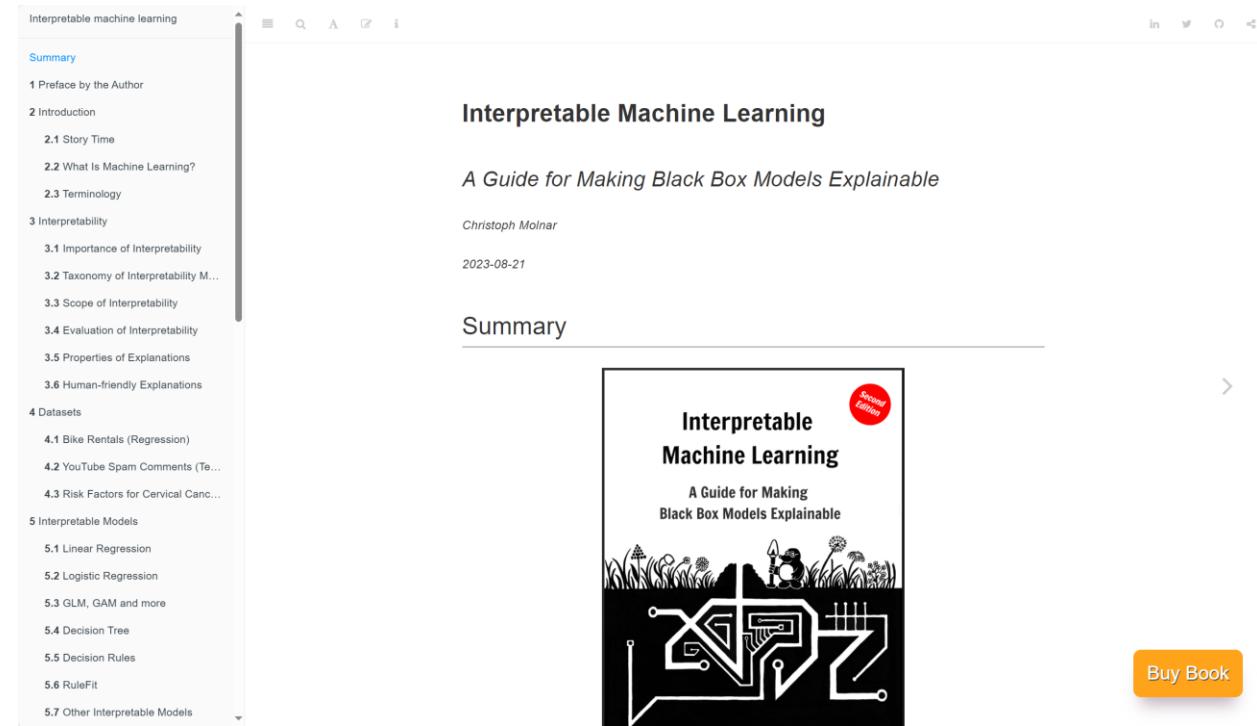
如何揭示人工智能算法究竟学到了什么？

- 将先验知识、传统方法与通用的人工智能模型相结合，设计空间显式的人工智能方法；
- 利用**可解释人工智能（XAI）**方法。

“**Explainable artificial intelligence (XAI)** is a set of processes and methods that allows human users to comprehend and trust the results and output created by machine learning algorithms.”

— IBM

Molnar (2020). Interpretable machine learning: a guide for making black box models explainable.
<https://christophm.github.io/interpretable-ml-book/>



XAI可以用来做什么？

- 帮助研究人员与用户深入了解模型决策方面的知识；
- 发现新知识。



□ 研究目标：

训练模型以对图像场景进行分类，左图是识别结果为停车场的图像样例。

□ 研究方法

利用**XAI**算法对模型的重点关注区域进行解译，其中颜色越接近红色则代表模型越关注该区域，即该区域在模型决策过程中扮演重要角色。

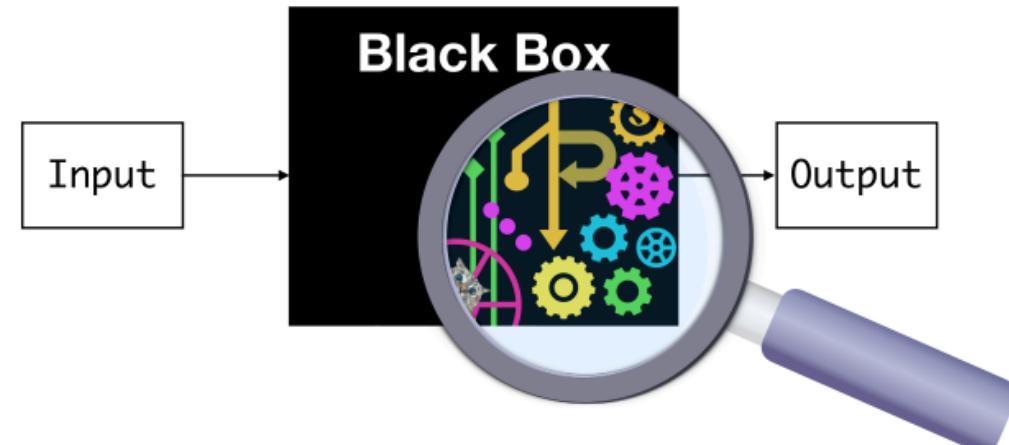
□ 研究结论

从直觉上，整齐的车辆是图像被归类为停车场的关键特征。然而在部分场景中，模型对通往停车场的路线等其他功能的关注是**出乎意料的**。

XAI的基本方法

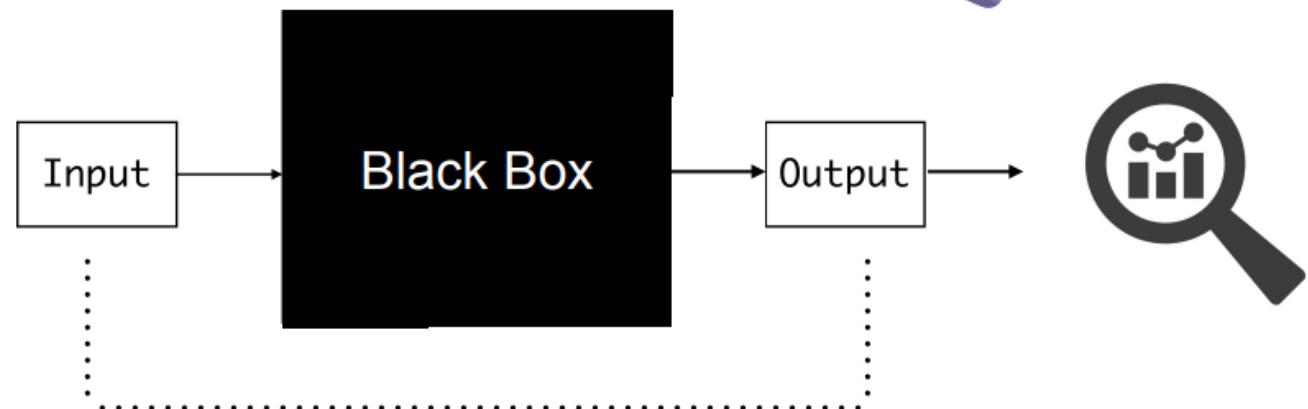
- 模型相关;
- 模型无关。

模型相关



Post-hoc

模型无关



两种XAI实现方法示意图 (Murdoch et al., 2019)

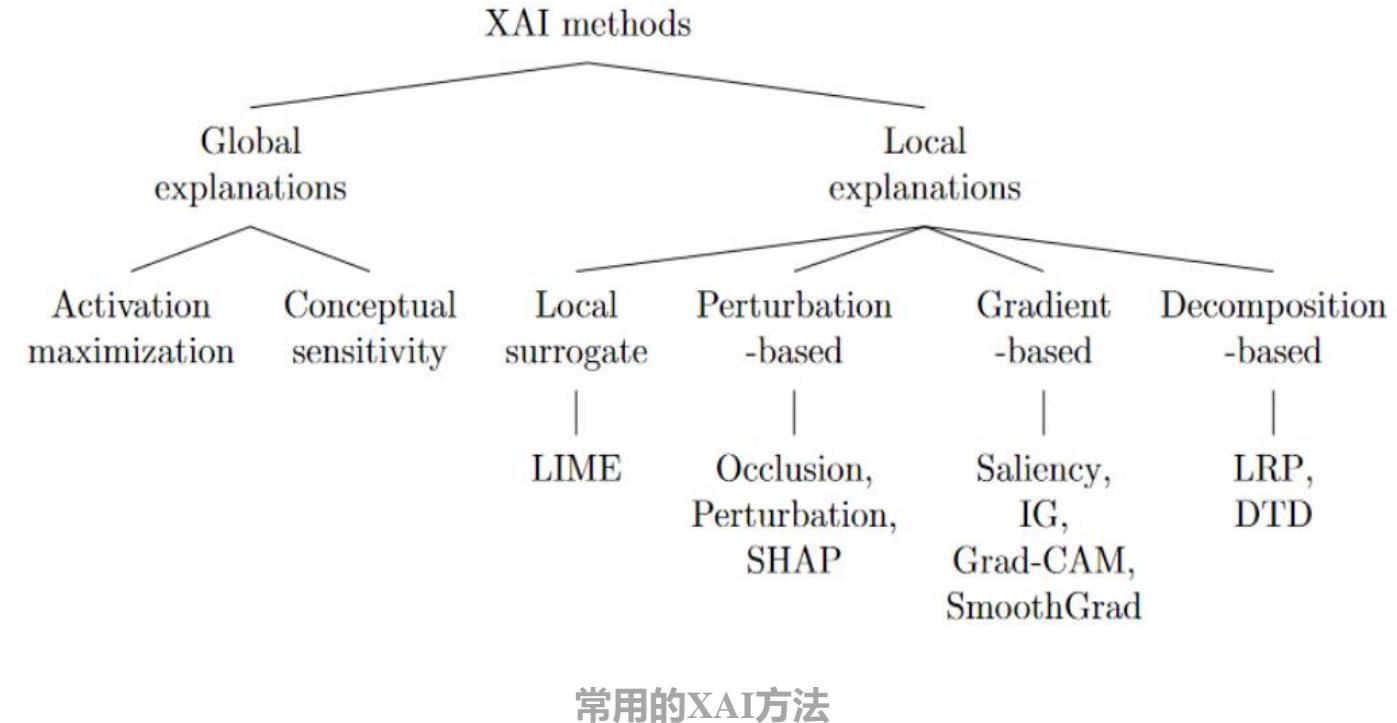
全局解释与局部解释

□ 全局解释（Global）：对于所有样本/预测值的解释

□ 举例：全局特征重要性

□ 局部解释（Local）：对于每一个样本/预测值的解释

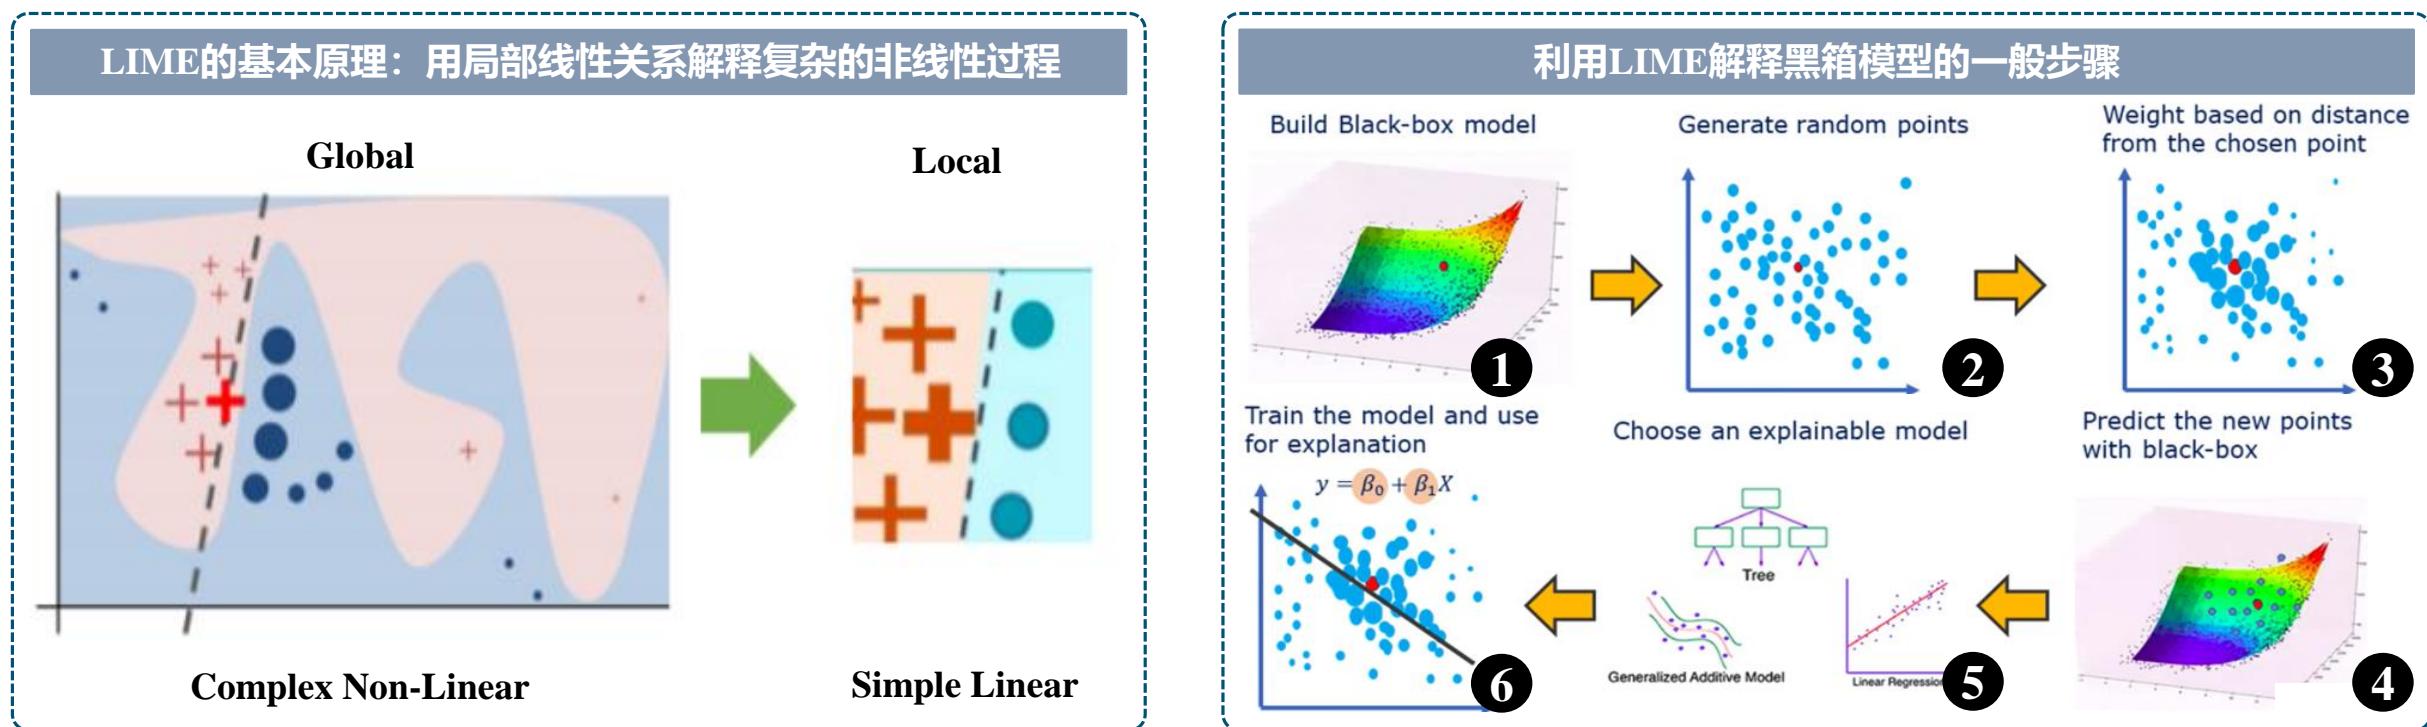
□ 意在揭示每一个个体决定是如何形成的



接下来，将对几种常用于城乡规划与地理学领域中的XAI方法进行简要介绍.....

LIME (Local Interpretable Model-agnostic Explanations)

- 复杂的非线性过程可以通过简单的局部线性关系所解释；
- 局部：随机取样本，根据距离进行加权，用黑盒模型进行预测，用线性回归等模型进行解释。



Shapley Value

Shapley Value | Shapley 值

- 一种基于博弈论 (Game Theory) 的机器学习可解释性方法；
- 含义：在一个游戏之中，每个玩家对可能组成联盟的所有不同排列组合的边际贡献的平均值。

$$\varphi_i(v) = \frac{\text{Possible permutations}}{\text{Marginal contribution}} = \frac{|S|! (n - |S| - 1)!}{n!} (v(S \cup \{i\}) - v(S))$$



Lloyd Shapley (1923-2016)
Nobel Prize in Economics (2012)

Shapley Value | Shapley 值

从一个简单的案例说起：学术影响力的计算

□ 假设我们有三个作者，他们各自写文章也有合作。每篇文章引用如下：

- | | |
|------------|--------------------|
| • Null: 0 | • {A + B}: 5 |
| • 作者A: 5 | • {A + C}: 120 |
| • 作者B: 10 | • {B + C}: 140 |
| • 作者C: 100 | • {A + B + C}: 150 |

□ 通过各个文章的引用以及作者的组合，他们各自的学术影响力是多少？

Shapley Value, SHAP

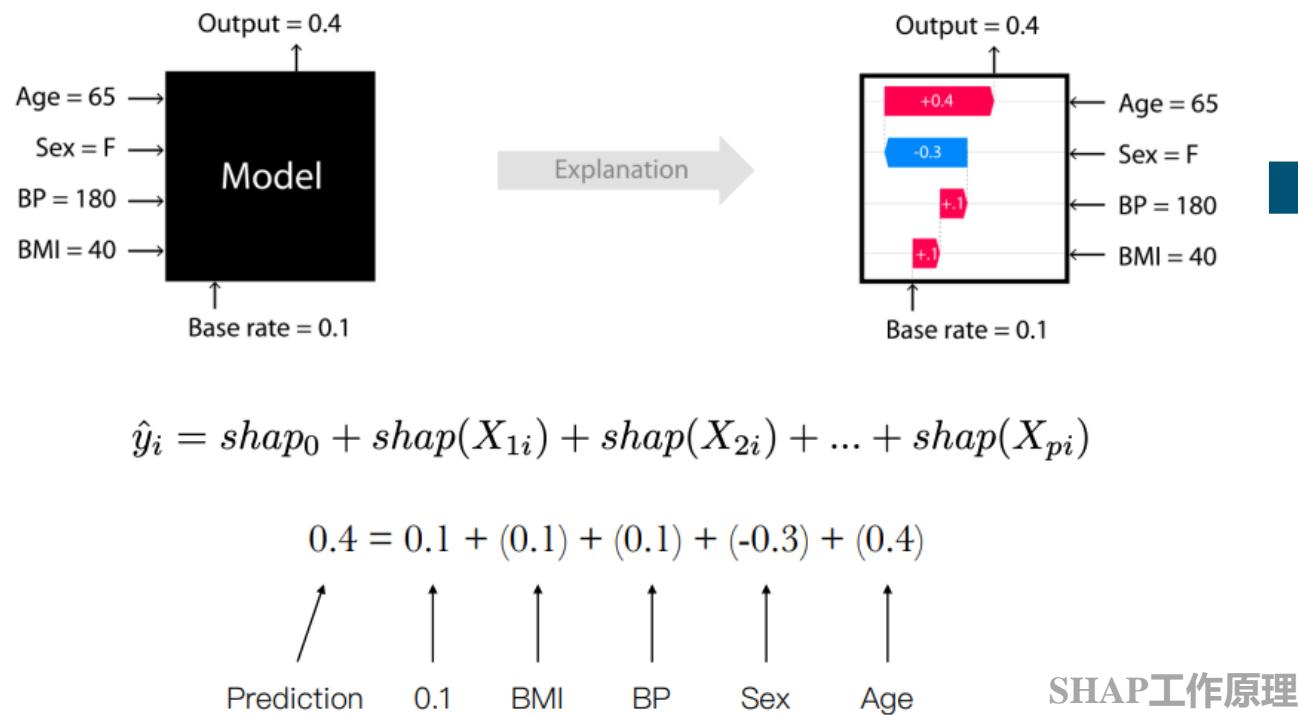
	A的边际贡献	B的边际贡献	C的边际贡献	概率	总和
ABC	5	(A+B) - A	(A+B+C) - (A+B)	1/6	150
ACB	5	(A+B+C) - (A+C)	(A+C)-A	1/6	150
BAC	(A+B)-B	10	(A+B+C) - (A+B)	1/6	150
BCA	(A+B+C) - (A+B)	10	(B+C) - B	1/6	150
CAB	(A+C) - C	(A+B+C) - (A+C)	100	1/6	150
CBA	(A+B+C) - (B+C)	(B+C) - C	100	1/6	150

	A的边际贡献	B的边际贡献	C的边际贡献	概率	总和
ABC	5	0	145	1/6	150
ACB	5	30	115	1/6	150
BAC	-5	10	145	1/6	150
BCA	10	10	130	1/6	150
CAB	20	30	100	1/6	150
CBA	10	40	100	1/6	150
Shapley Value	7.5	20	122.5	1	150

- 利用 Shapley 值计算三人的学术影响力的方法如左上表所示，计算结果如上右表所示；
- 在实际应用场景中，通过手动计算 Shapley 值以衡量各个要素贡献、解释黑盒模型的方式是不可能的（感兴趣的同学可以了解 NP-Hard 问题）；
- SHAP 提供了一系列有效的方式以估计 Shapley 值；
- SHAP 的 Python 包地址：<https://github.com/slundberg/shap>。

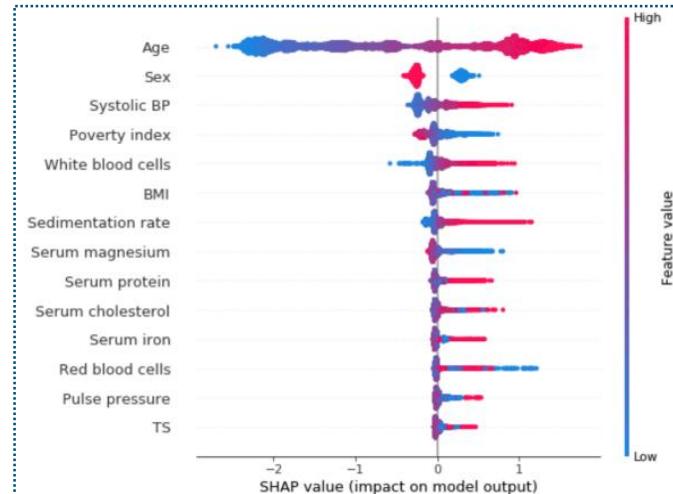
SHAP

- 用于解释机器学习模型的**工程解决方案**;
- 被Amazon、Google 等集成到其AI平台之下。



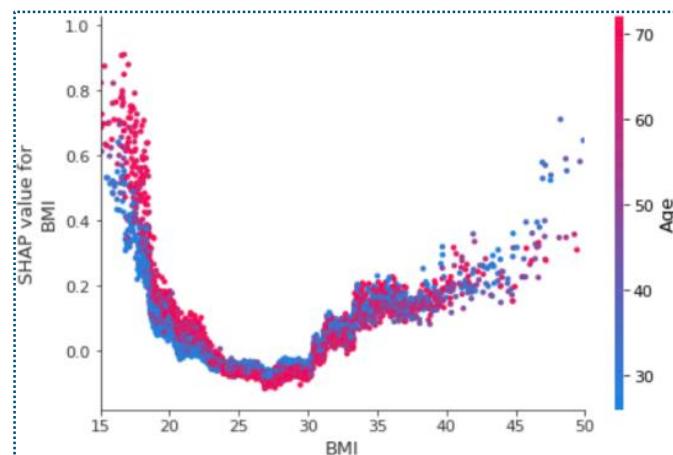
特征贡献

- 蜂群图
- 标识了每个样本、
每个特征、每个
属性 Shapley 值
的大小。



局部依赖

- 散点图
- 控制BMI不变时，
各年龄 Shapley
变化情况。



Grad-CAM (Class Activation Mapping)

- **类激活热力图CAM**: 通过热力图将模型认为最为显著的结果显示出来以解释模型预测的结果；
- **经过梯度加权的类激活热力图 (Grad-CAM)** 比之传统的热力图有着更广泛的适用范围。

□ 研究目标

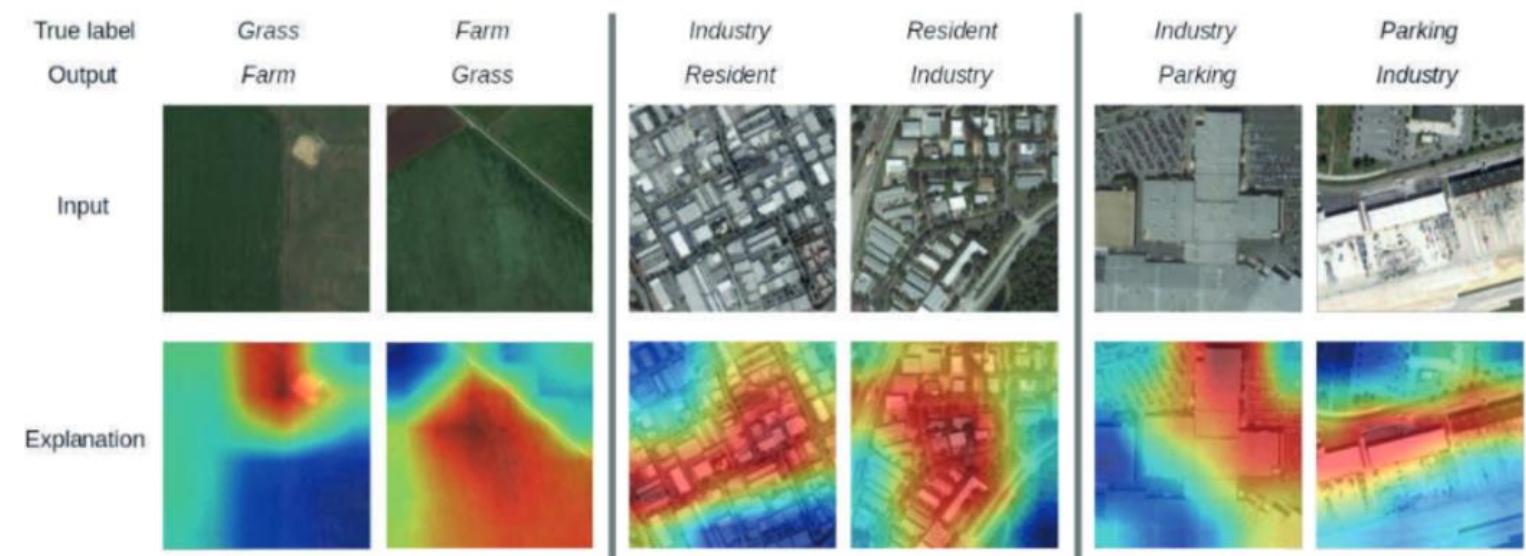
利用 XAI 解读遥感影像的分类结果并分析效果不佳的原因以改进AI模型。

□ 研究方法

引入Grad-CAM解释容易混淆的样本。

□ 研究结论

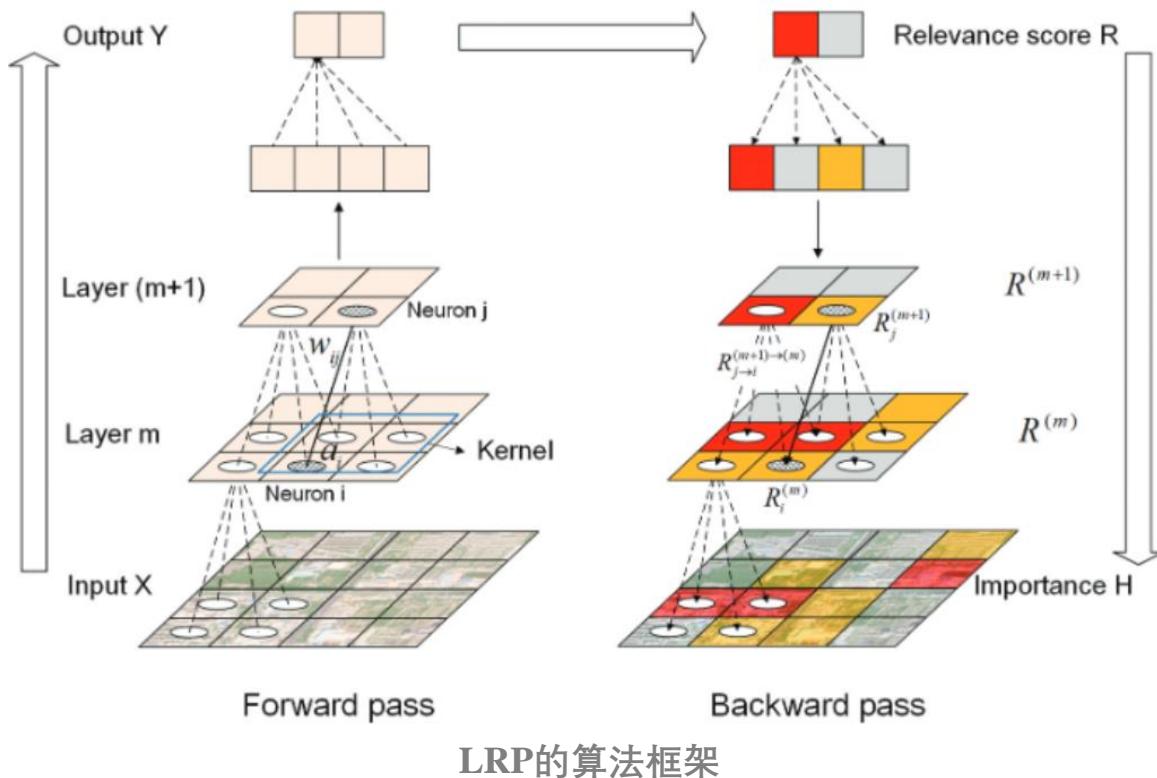
模型的低准确性可以归因于样本的混乱，需要更详细的标签重新标记样本，并重新训练用于多标签分类的模型。



错误分类样本的示例以及三对混淆类别的相应解释：
其相对更暖的颜色对应了对模型判断结果更重要的像素点。

LRP (Layer-wise Relevance Propagation)

□ 与CAM不同，LRP可以逐层提取各像素贡献值。



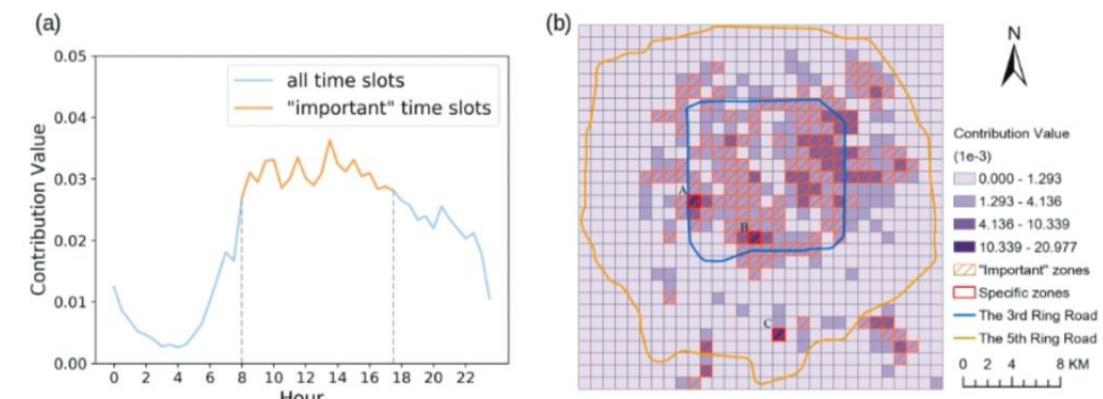
LRP 应用实例

研究目标

利用出租车出行特征与深度学习模型预测工作日与周末/节假日两个时段出发点流量。

研究方法

LRP 分析时首先将时空单元按照归一化贡献值从大到小排序，然后计算时空维度的累积贡献比例，累积到达60%以上的单位为重要单位。



时间 (a) 与空间 (b) 维度上的归一化贡献值：从时间上讲，“重要时段”与办公时间几乎一致；从空间上讲，“重要空间单元”与公共交通站点高度重叠。

Bach, S., et al., 2015. On pixel-wise explanations for non-linear classifier decisions by layerwise relevance propagation. PloS ONE, 10 (7), e0130140.

Cheng, X., et al., 2021a. A method to evaluate task-specific importance of spatio-temporal units based on explainable artificial intelligence. International Journal of Geographical Information Science, 35 (10), 2002–2025

另一个黑箱子：XAI 的可解释性

- 解释的准确度对反映模型的真实行为非常重要；
- XAI 模型更加需要透明度（Open XAI）。

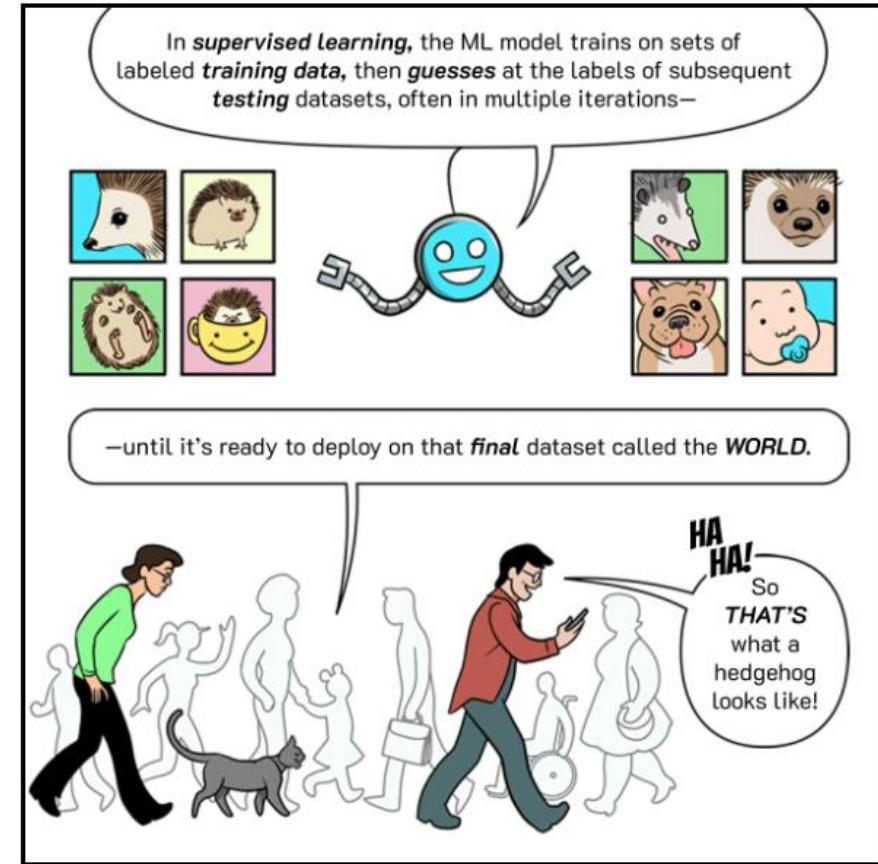


工程难题：大模型的可解释性

- 以 SHAP 的应用为例，Shapley 值的计算相当昂贵，既消耗算力，又消耗时间；
- 方案：
 - 缩减特征维度；
 - 注重地理知识的综合，设计更高效的算法 ……

如何评估模型的泛化能力？

- 采用交叉验证（Cross Validation, CV）的方式，将样本划分为训练集、测试集与验证集，利用训练集的数据拟合得到较理想的模型，利用测试集与验证集的数据评估模型的**泛化能力**；
- 传统随机划分训练集与测试集进行交叉检验的方式**不适用于存在空间异质性的地理数据**；
- **空间交叉验证（Spatial Cross Validation, SCV）**可以通过空间而非随机分割数据来解决传统方法应用于地理数据可能带来的评估误差。



想象一个图片分类任务：我们需要验证训练好的模型能否真正识别出各种物体，因此往往会观察模型在新数据（图片）上的表现，该过程被称之为泛化。

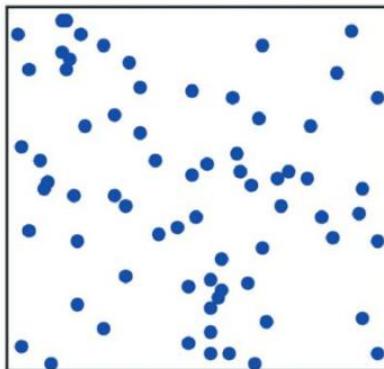
空间交叉验证



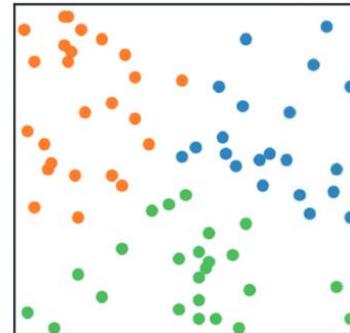
哈爾濱工業大學(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

常用的空间交叉验证方式

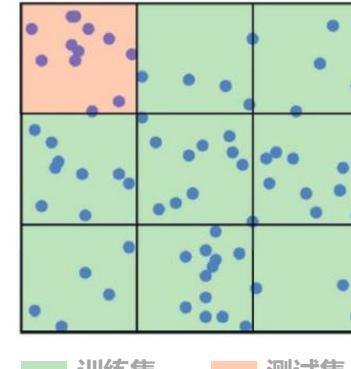
- **基于聚类的空间交叉验证**: 基于数据的地理空间坐标, 采用聚类算法将数据分割为多个子集;
 - **基于网格的空间交叉验证**: 将研究区域划分为若干空间网格, 并以此单位选择训练与测试样本;
 - **基于地理属性的空间交叉验证**: 按照地理属性定义的空间区域来分割数据 (E.g. 行政单元) ;
 - **空间留一法**: 留一法 (Leave-one-out) 的扩展, 在验证数据周边生成一圈缓冲区, 落入缓冲区的数据将不会被用于模型训练。



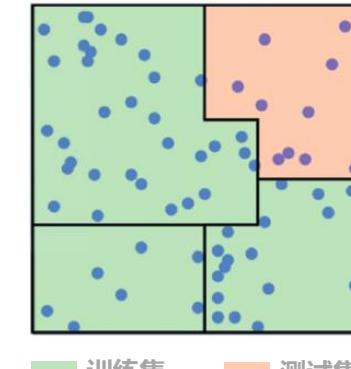
原始数据



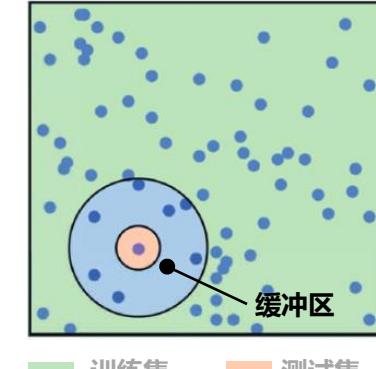
基于聚类的方法



基于网格的方法



基于地理属性的方法



空间留一法

口 研究目标

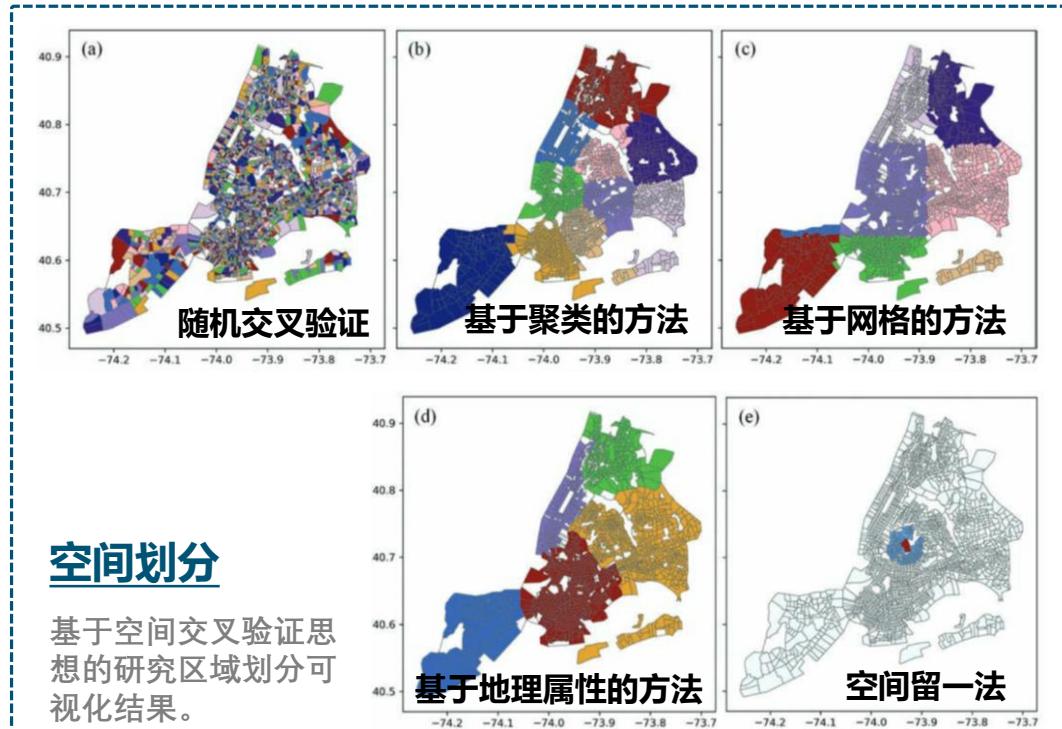
采用深度神经网络预测纽约市肥胖症患病率

口 研究方法

为了验证模型的有效性，分别采用上述四种空间交叉验证的方式对模型的结果进行评估，并将评估结果与随机划分训练集与测试集的结果相比对。

口 研究结论

模型在随机交叉验证时的表现要显著好于空间交叉验证：目标变量所具有的空间自相关性会对采用随机交叉验证时的模型性能评估指标产生显著影响，即采用随机交叉验证会高估模型的性能。



评估结果

CV method	R2	RMSE
<i>Random CV</i>	0.8692	2.1287
<i>Clustering-based spatial CV</i>	0.7244	3.0899
<i>Grid-based spatial CV</i>	0.7466	2.9624
<i>Geo-attribute-based spatial CV</i>	0.6613	3.4250
<i>Spatial leave-one-out CV</i>	0.8083	2.5766

地理空间人工智能： 城市应用

城市系统中的GeoAI

- 有研究者调研了2018-2022年共581篇应用空间显式人工智能的文献；
- 研究表明，GeoAI在城市系统中的应用集中在三个方面：
 - 场所感知与人类活动（Social Sensing）；
 - 城市发展与人群流动（Urban Dynamics）；
 - 城市内部的社会分异（Social Differentiation of Urban Areas）；

Table 1

List of the reviewed papers. (ANN—Artificial Neural Network; DNN—Deep Neural Network; CNN—Convolutional Neural Network; GNN—Graph Neural Network; CA—Cellular Automata.).

Paper	Methods
Urban Dynamics (urban development)	
He et al. (2018)	CNN+CA
Xu et al. (2019)	ANN+CA
Ou et al. (2019)	Autoencoder+CA
Lu et al. (2020)	ANN+CA
Zhai et al. (2020)	CNN+CA
Rana and Sarkar (2021)	ANN+CA
Gantumur et al. (2022) ^a	ANN+CA
Urban Dynamics (urban population flows)	
Zhang and Cheng (2019)	CNN
Huang (2019)	GNN
Yao et al. (2020)	GNN
Zhang and Cheng (2020)	GNN
Hu et al. (2021)	GNN
Yang et al. (2021)	GNN
Liu et al. (2021b)	GNN
Xia et al. (2021)	GNN
Li et al. (2021a)	GNN
Zhu et al. (2022) ^a	GNN
Social Differentiation of Urban Areas	
Gervasoni et al. (2018)	CNN
De Sabbata and Liu (2019)	Geoconvolution+DNN
Monteiro et al. (2019)	CNN
Zhang et al. (2021)	CNN
Social Sensing	
Zhu et al. (2020b)	GNN
Liu and De Sabbata (2021)	GNN
Zhu et al. (2021)	GNN

^aIndicates early access.

Liu, P., & Biljecki, F. (2022). A review of spatially-explicit GeoAI applications in Urban Geography. International Journal of Applied Earth Observation and Geoinformation, 112, 102936

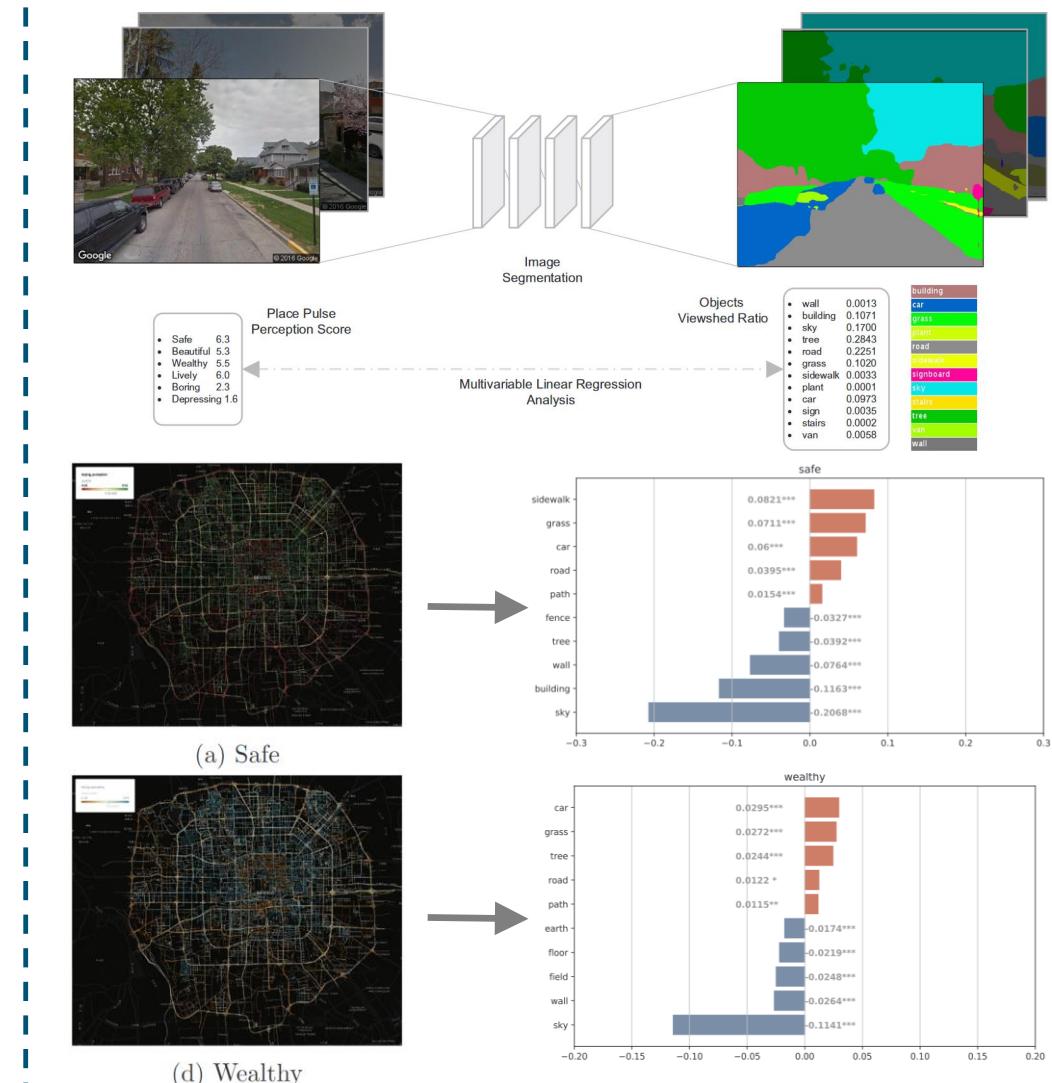
Casali, Y., Aydin, N. Y., & Comes, T. (2022). Machine learning for spatial analyses in urban areas: a scoping review. Sustainable Cities and Society, 85, 104050.

口 研究目的

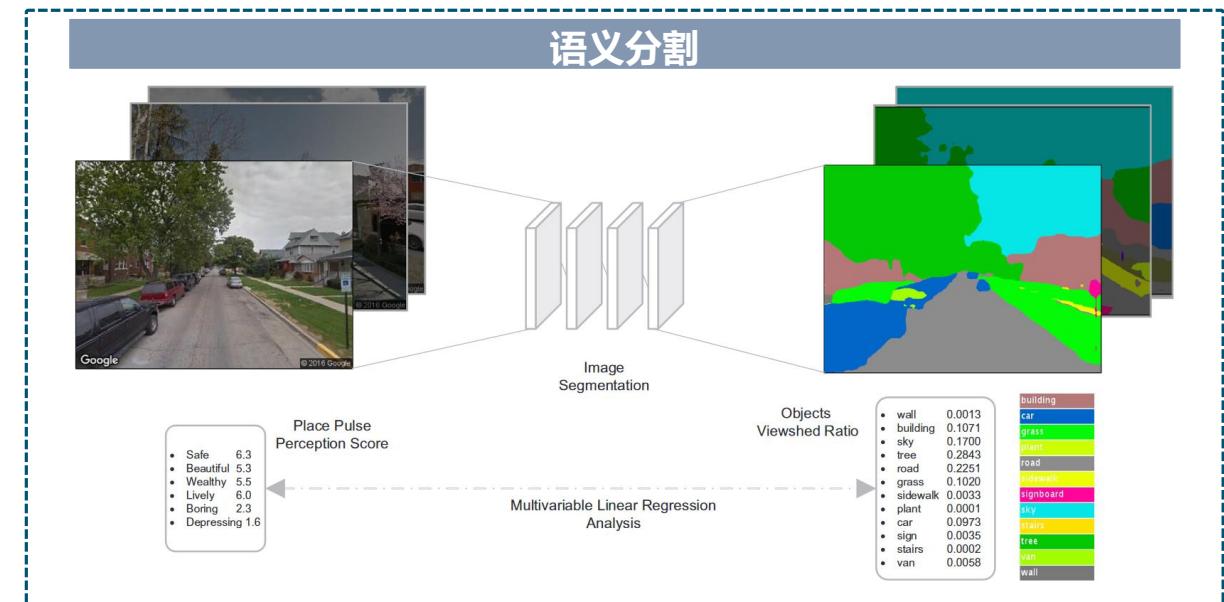
- 测量人类的场所感并量化影响人类场所感的建筑环境视觉特征之间的联系；

口 研究方法

- 以数据驱动的方式衡量人们如何感知大规模城市地区的某个地方。
- 具体来说，以数百万类人对街道图像的评分为语料训练深度学习模型，并将模型应用于预测人类对街景图像的感知。该模型对**安全、活泼、美丽、富有、压抑、无聊**六种人类感知指标的预测准确率很高。



- **数据标注：**采用问卷的形式对收集到的街景图像大数据进行感知评分（如左下图）；
- **语义分割：**利用深度学习将街景图像中的各类型建成环境视觉要素提取出来（如右下图）；
- **构建建成环境视觉要素与人类感知之间的关系：**以感知评分为响应变量（y），街景图像中的视觉要素为解释变量（x）训练机器学习模型，以预测未知街景图像的人类感知状况。



场所感知与空间认知



(a) Safe



(b) Lively



(c) Beautiful



(d) Wealthy



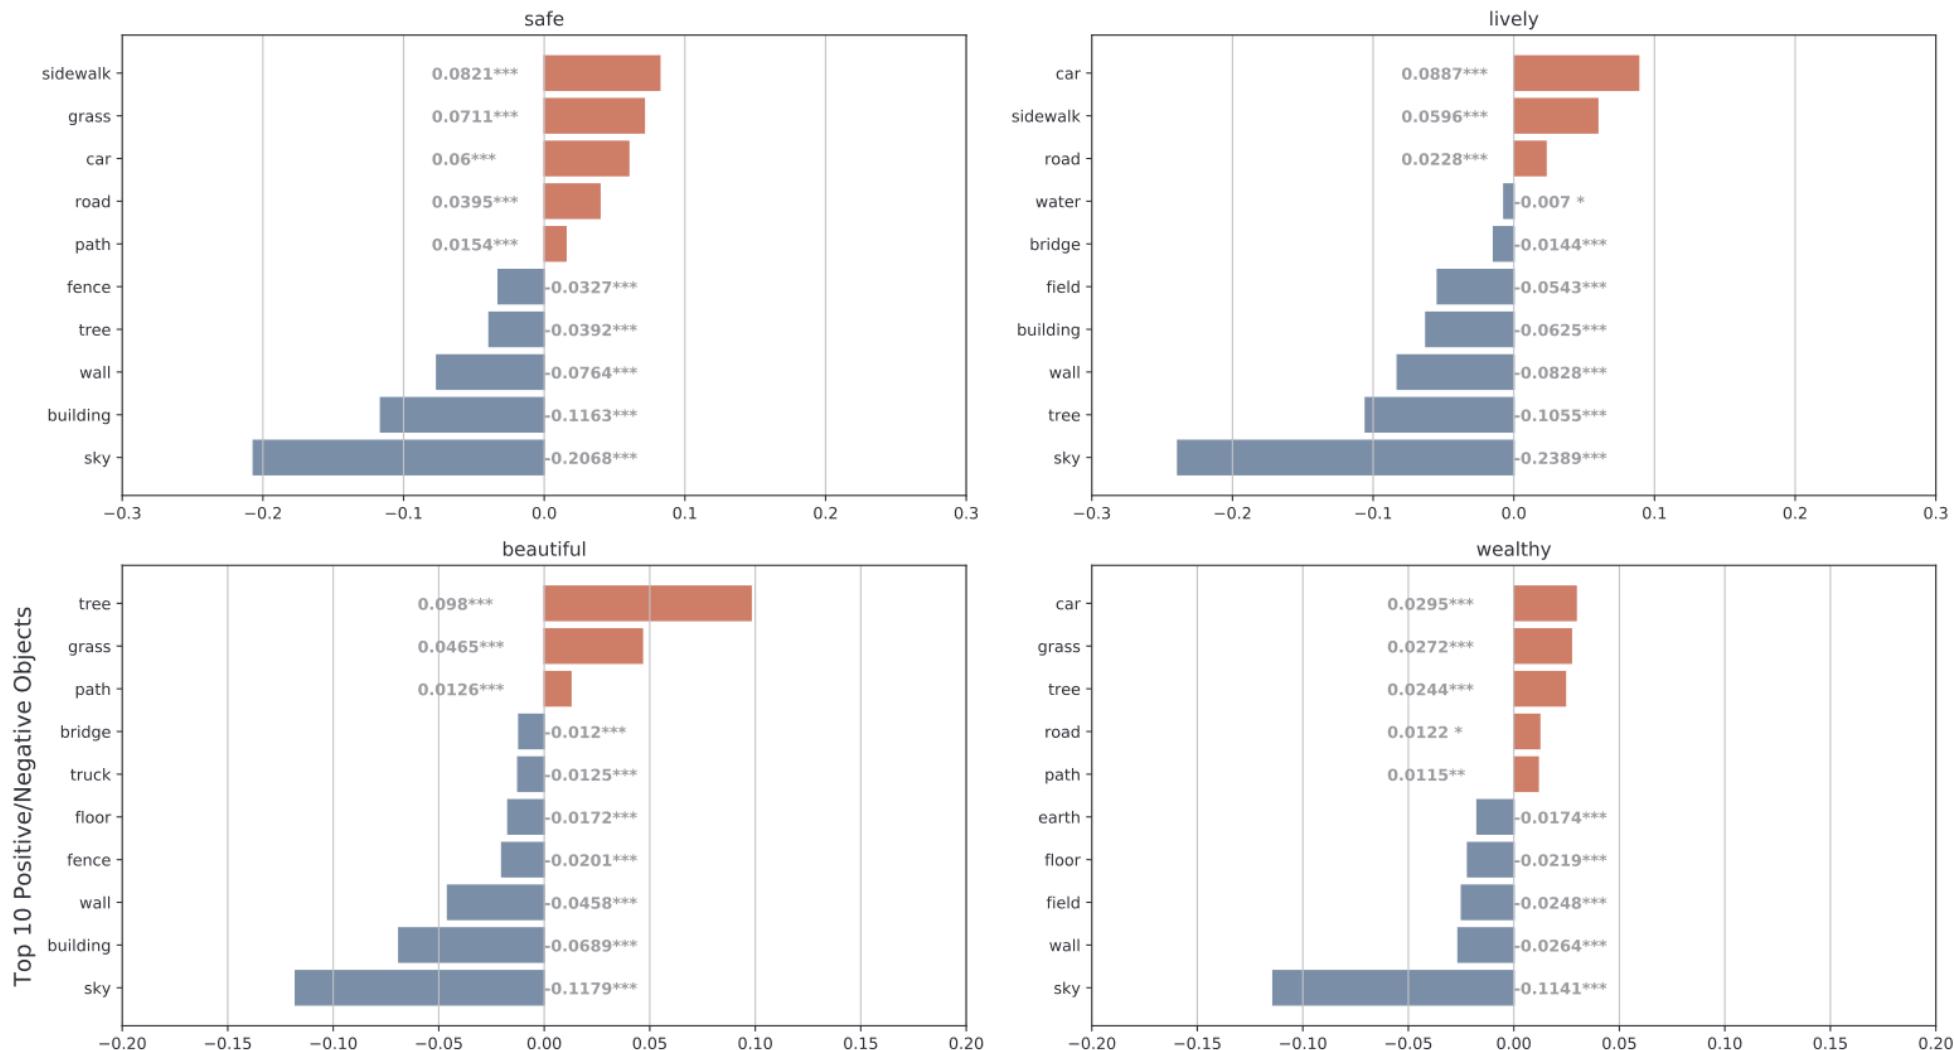
(e) Depressing



(f) Boring

人类场所感知的
地理空间可视化

场所感知与空间认知



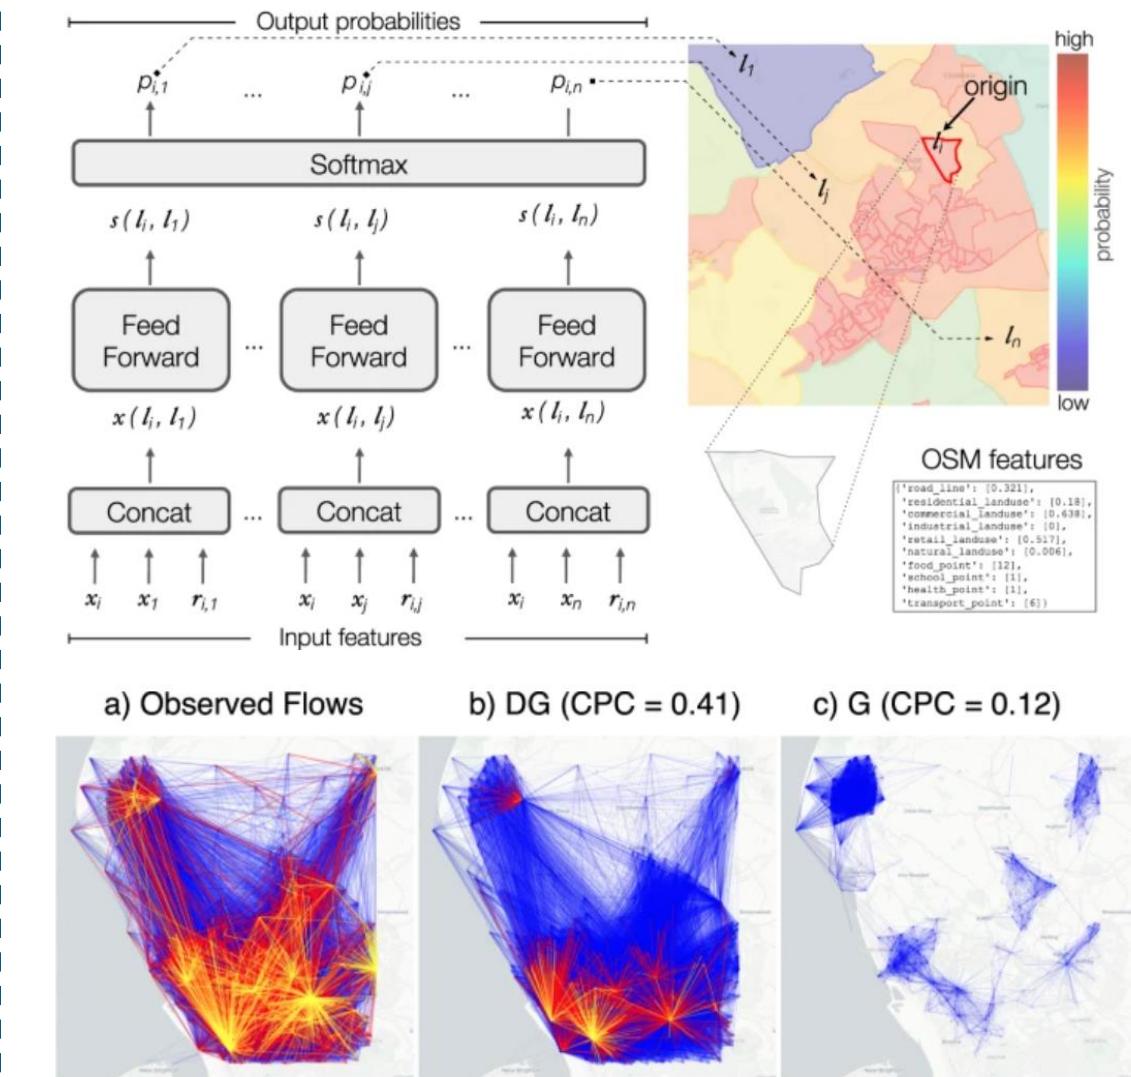
模型解释：各个视觉要素对人类感知的贡献大小

研究目标

- 将深度学习与重力模型结合，使得研究者能够在没有历史流量数据的前提下，实现两地人口移动流的生成。

研究方法

- 将人群在地点之间的移动视作一个分类问题；
- 特征工程：**出发点与所有可能目的地属性的拼接；
- 模型：**多层感知机 (MLP) (非空间显式的)；
- 优化目标：**使得两地之间形成流的概率趋近于真实概率，并用CPC (Common Part of Commuters) 评估模型的性能。



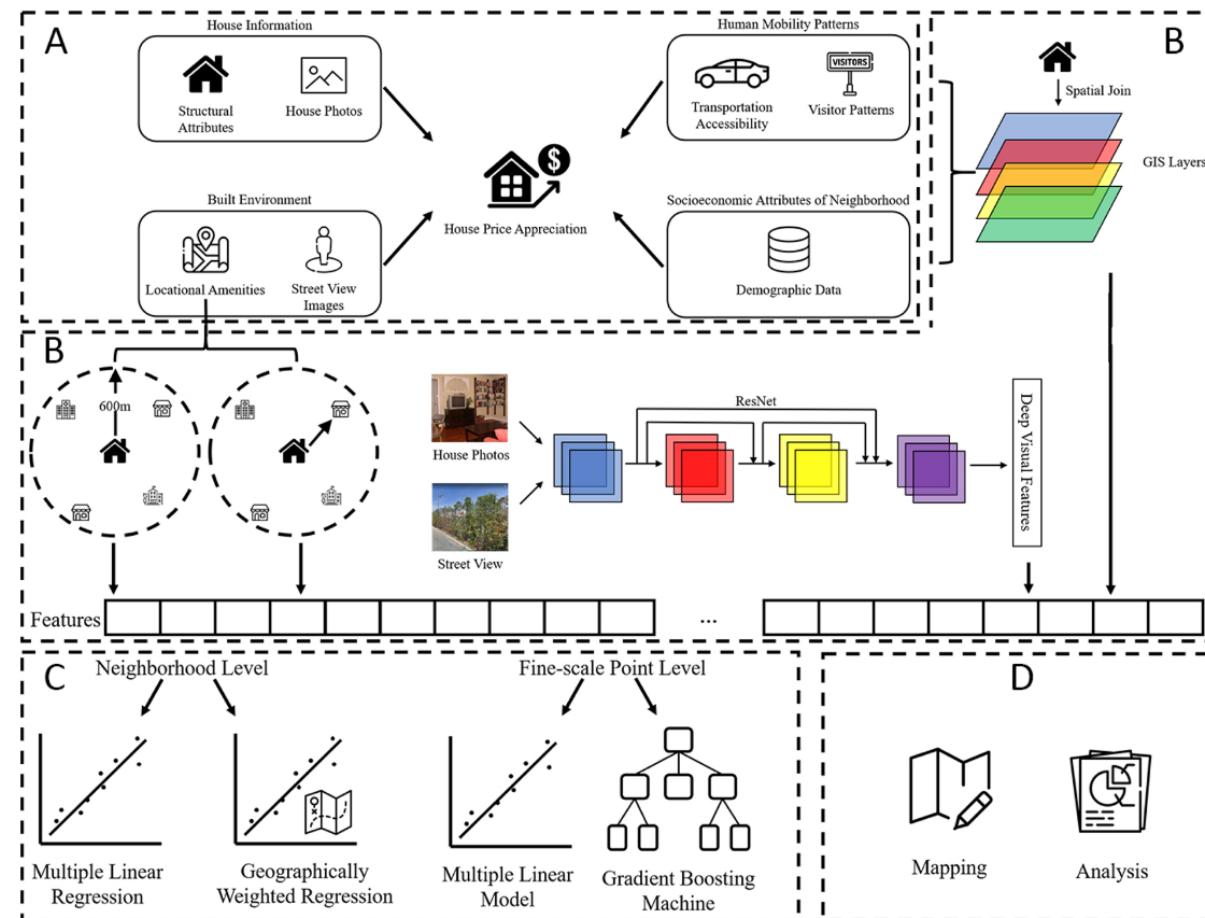
城市内部的空间分异

研究目标

- 通过多源大数据预测房产升值潜力。

研究方法

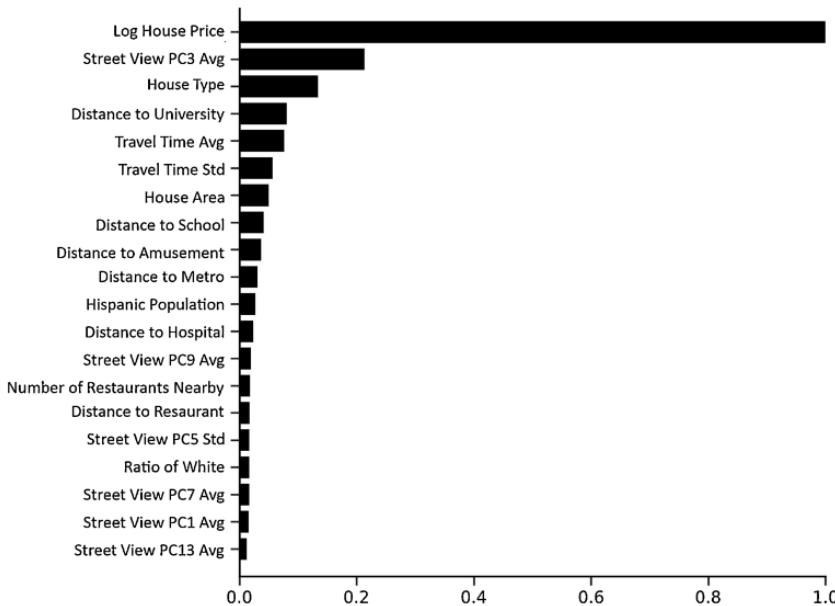
- 数据源：**房屋结构属性、房屋照片、位置便利设施、街景图像、交通可达性、访客模式和社区的社会经济属性；
- 特征工程：**使用深度学习模型从街景图像和房屋照片中提取深层特征；
- 模型：**机器学习模型与地理加权回归模型。



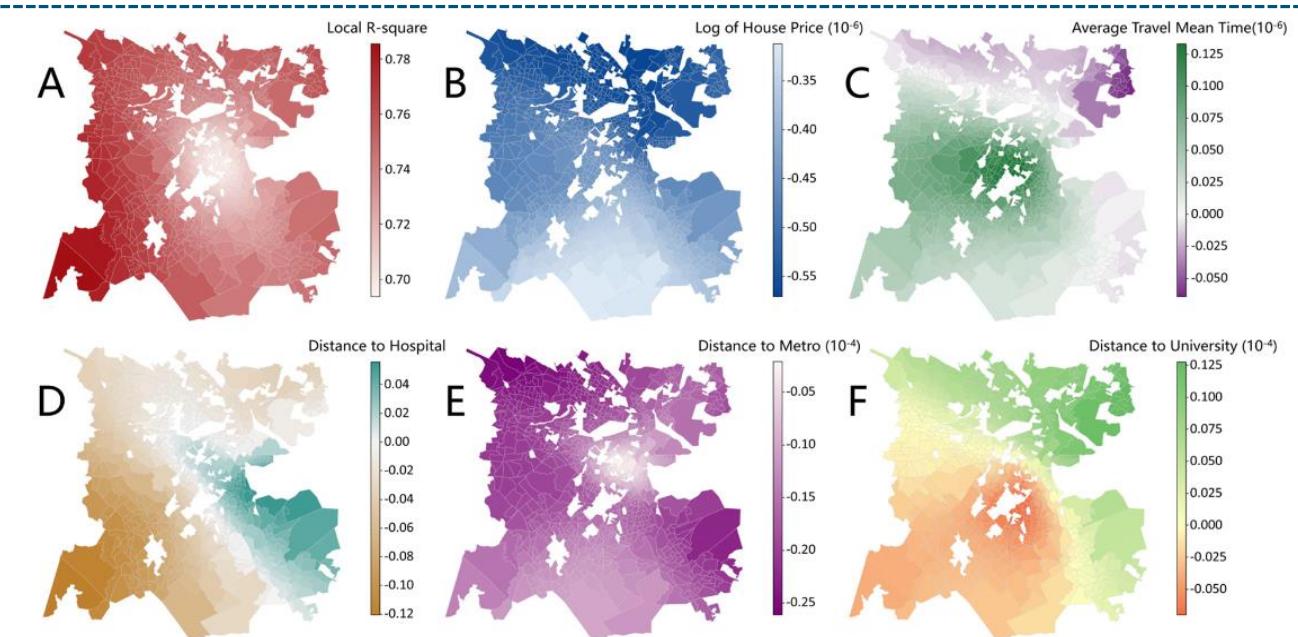
研究结论

- 机器学习模型的结果显示，房价低、房屋面积小的房子可能具有更高的房屋升值潜力；
- 地理加权回归的结果显示，不同要素对房屋升值率的影响存在空间异质性。

机器学习模型结果



地理加权回归模型结果



城市系统中的地理空间人工智能：

展望

□ AI for Social Science **VS** Social Science of AI

□ 数据

- 不确定性 (Uncertainty)
- 异质性 (Heterogeneity)

□ 尺度

- 公平性 (Fairness)
- 偏差 (Biases)
- 信度 (Trustworthiness)

□ 机理

- 可解释性 (Explain ability)
- 泛化性 (Transferability)
- 是否可复现 (Replicability)

□ 应用

- 责任意识 (Responsibility)
- 可持续性 (Sustainability)
- 隐私保护 (Privacy)

谢谢大家

2024年5月

1173450209@stu.hit.edu.cn



哈爾濱工業大學(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN